SMART CITIES & LOCATION SERVICES

任务分配实验

从四段计划到持续研究

实验二的真实人机互动、证据驱动派单研究与独立审核

姓名	吴博闻
学号	10245102410
课程	智慧城市与位置服务
日期	2026 年 11 月 5 日
材料	实验二（1）与实验三学生版

阅读说明

在本次实验中，我先把两套教师材料交给 GPT 讨论，随后纠正最初分成四个 Goal、缺少研究优化和可视化研发的执行方案。我要求先建立可信基线，再做丰富的控制变量试验，依据真实结果决定后续优化。最终，我明确批准一个完整长 Goal，交由 Codex 组织研究、运行、独立核验和提交。

本报告分成两条互补线索。**Part I** 保留我与 GPT 之间确实发生的任务设计和授权对话；**Part II** 以真实工程与实验记录解释长任务内部如何发现问题、比较单项与组合并合理回退；**Part III** 呈现我对数据许可、GitHub 审查和项目规则的后续判断。技术中的自主 Agent 行为按真实身份记录，不补写成我的即时人工操作。

截图采集说明。这次我提供了在 ChatGPT 网页中录制的真实滚屏视频 `QQ20261105-091814.mp4`；GPT 从该视频的原始解码画面提取 PNG 原帧并作无损矩形裁切，随后在 LaTeX 中叠加可编辑矢量箭头。原视频保存哈希和精确视频时间码；箭头、侧注与截图像素分离。视频帧属于录屏源，不冒称截图软件直接输出的无损原始网页截图。关键原话与视频一一核对，报告不通过模拟聊天补造历史。

目录

1 从既有分工到连续执行 1

2 真实独立上下文怎样参与 1

3 先把“比较什么”说清楚 6

4 进化优化怎样从端点不足走到有限组合 6

5 长期价值的收益为什么要拆开看 8

6 把结果变成可以审核的成果 10

7 本轮保留的认识 10

8 一次长任务给我的实际认识 14

PART I · WORKFLOW CONSTRUCTION PART I · WORKFLOW CONSTRUCTION

1 从既有分工到连续执行

1.1 继承共同基础，不重新编造起点

上一份已验收 Process Report 已经记录了我与 GPT、Codex 之间的分工、双报告、来源审核、证据与远程审查方式。本次沿用这套共同基础，不把实验一的算法、参数、结果和截图当成新实验材料。报告视觉继续使用 P2，科研图保留原生可编辑源；工作流和体系图提供 draw.io 及 SVG/PDF。

我先否定四段式独立 Goal 的安排，要求一个完整长任务承担实现、实测、诊断、修复与交付。GPT 据此把“先保证正确，再追求优秀；先做基础实验，再研究组合”转写进可执行的长任务规则。本次原生聊天录屏保留了这轮纠正、解释、再确认的真实 UI。研究目标、教师要求和关键评价不能由执行器随意改变，但范围内的普通参数、调试、控制变量和已有父项支持的组合可以连续执行，避免每一步都退回让我确认同一件事。

1.2 真正变化的是反馈和恢复责任

这次的难点不止是填完 TODO。教师材料把在线尾部体验、静态 Pareto 前沿与动态长期收入放在一起，既有算法语义冲突，也有数据分区和成本遗漏风险。我要求 Codex 先建立可信基线，再根据实际结果决定下一轮；普通缺陷必须修复、回归、重建受影响产物，然后回到未完成的父任务。合法方法没有收益时则保留负结果，不把它强行修成正结果。

执行上因此形成两条不同回路。工程回路处理实现或评价偏离：复现问题、固定新版本、使旧结果失效并重跑。研究回路处理效果和机制：读数、假设、单因素、父项、必要组合、取舍。前者的修复次数不是后者的效果提升次数。这一区分在 KM 指标、Double 随机流和主动调度中都实际发挥了作用。

2 真实独立上下文怎样参与

2.1 六类职责，四个实际上下文

本轮确实启用了原生子 Agent，而不是给函数换名字。主线程承担协调、基础在线实现与文稿集成；research_data 负责材料、来源和数据，随后独立核验进化分支；evolution 负责多目标实现与实验，随后独立核验 RL；reinforcement 负责 RL 和加分机制，随后独立核验在线匹配和交付边界。研究、设计、执行、核验、批判和制图六类职责按先后交接分配给四个实际上下文。

各角色能读写同一工作区，但任务合同限制可改对象：原始资料和批准合同保持只读，模块分工明确。重要交接包含输入版本、问题、允许方法、结果路径、验证方式及返回条件。对自己算法的检查只记作者自检，交叉核验者必须重新取原始输入和实际产物。

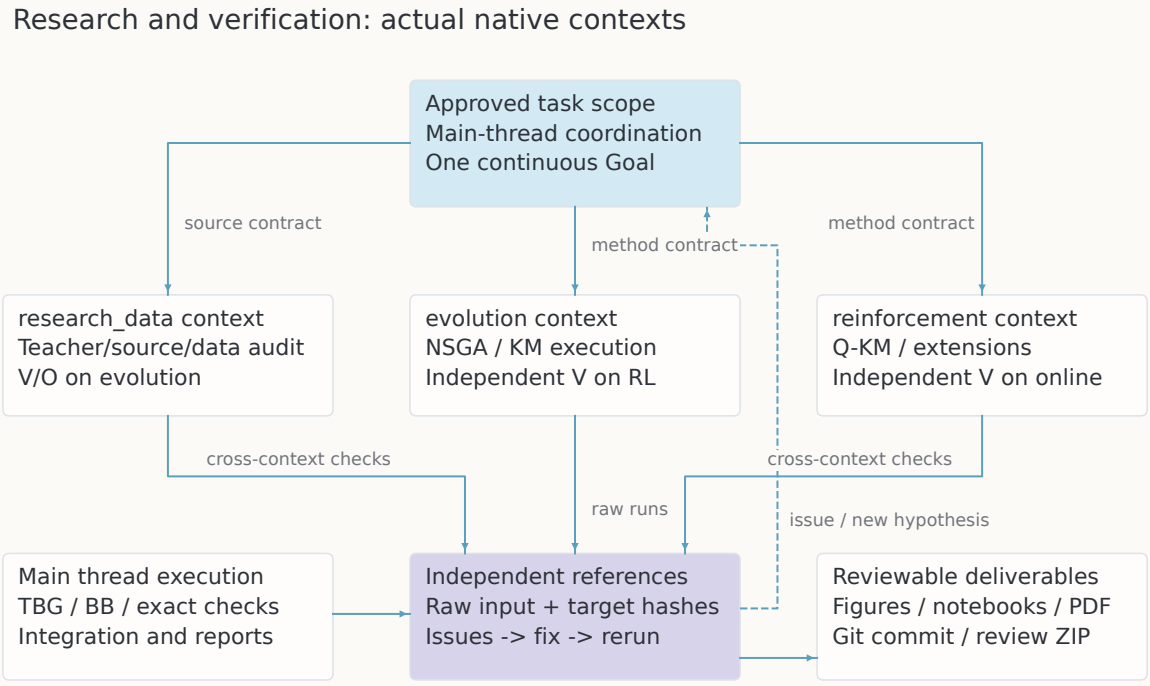


图 1 本次真实研究与独立核验职责。四个原生上下文分时承担六类职责；箭头表示任务合同、产物和问题反馈。图解释实际技术组织，不替代原始对话 UI 证据。

2.2 反馈并非执行者自己的 PASS

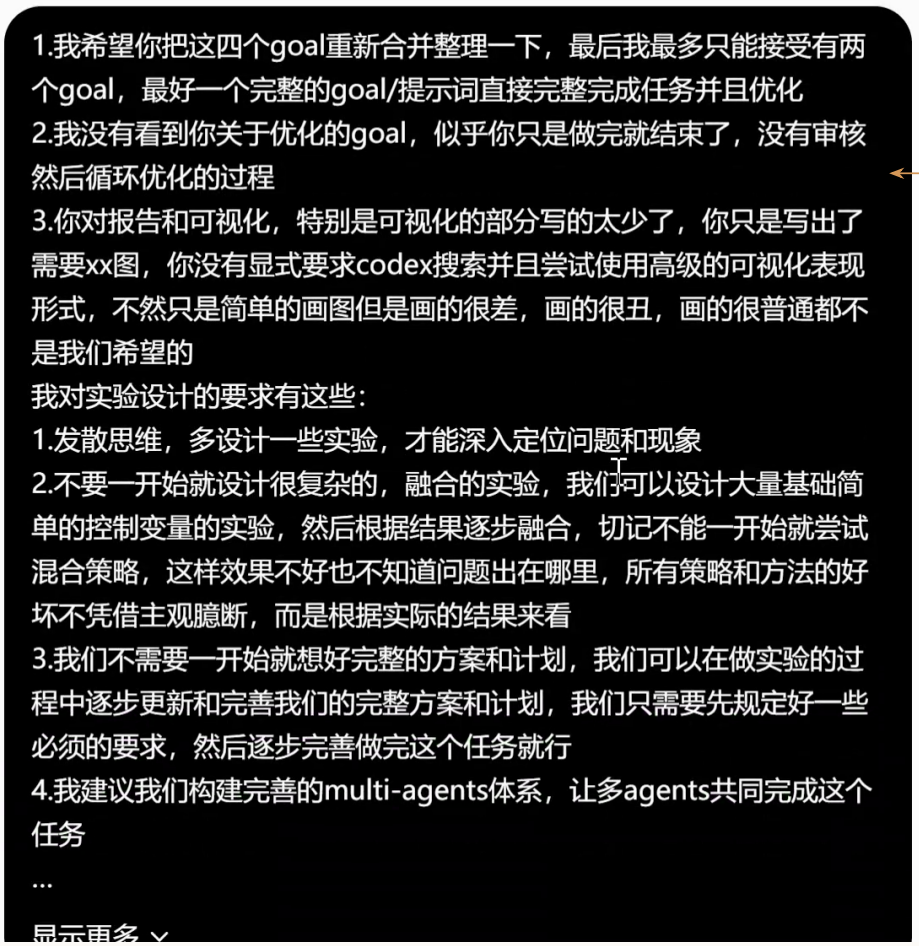
在线分支的核验者从输入与匹配记录重新算距离、等待、唯一性和离线目标，并另写小图参考。进化核验者从原批次重解码基因，再独立求目标与 HV；他发现 Spacing 包含了不应进入前沿的点，并提前发现初始化成本不在计时内。RL 核验者没有调用作者仿真器，而是按原订单和 trace 重建忙闲、移动和取消，再核对 Double 公式和动态 NSGA 选点。

交叉核验带回了可定位的缺陷与独立读数，主线程修复后恢复父任务。这里的四个研究上下文不等于每笔订单都调用 LLM；最终派单仍由实际优化算法执行。

E01 · 用户纠正 / 原始对话

不只缩减 Goal 数量，更要改变执行机制

录屏约 00:48—01:18：先保留我的原话，再看 GPT 如何将其转成研究合同。



我的第一项纠正

我要求最多两个、最好一个 Goal，并指出“做完就停”和缺少可视化研发的问题。

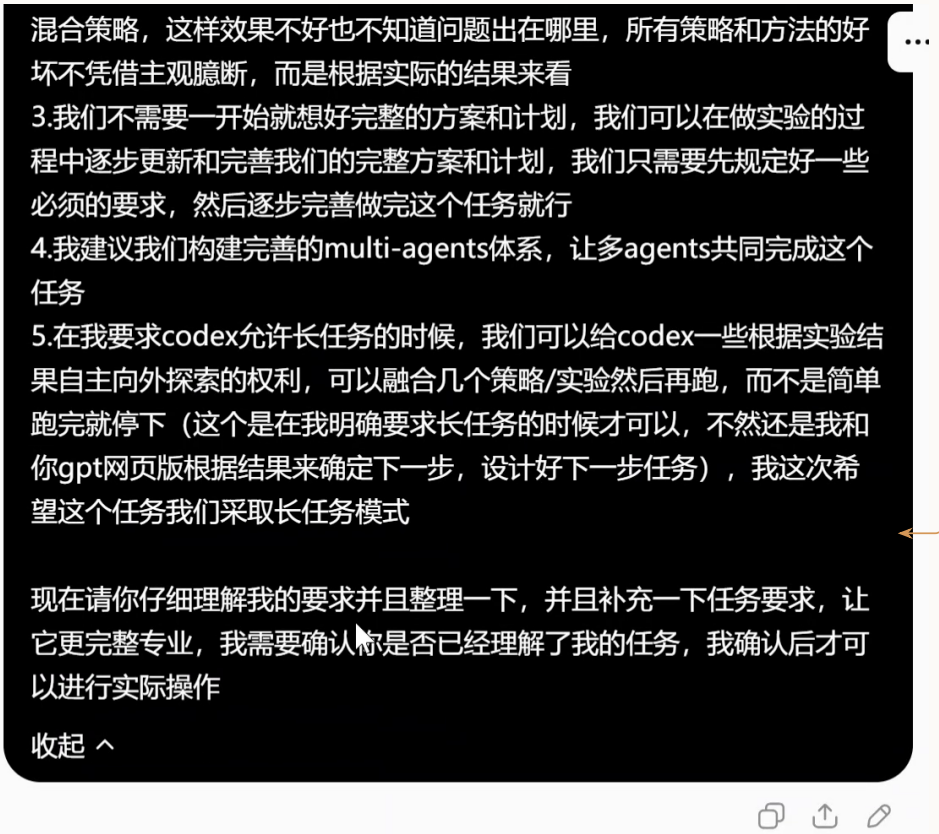
RAW VIDEO 00:48.500 · E01 / USER · 原句未经改写，截图末尾可见原生“显示更多”控件

我不希望只有“先把 TODO 跑通，然后给出一个完成状态”。这条消息还要求从多个简单实验入手，避免一开始混合策略时无法定位失败原因。GPT 在随后回复中重新区分了完成、研究与优化。

E01 · 同一互动续页

我批准的不是无界自动搜索

同一条用户消息的后半段；它说明长任务自主权成立的前提。



授权需要边界

我提出用真实结果持续扩展控制变量实验，允许有依据的组合；只有明确授权长任务时，Codex 才可自主推进。

RAW VIDEO 00:51.500 · E01 / USER CONTINUATION · 与上页同一消息，未重排成新用户轮次

我认为还需要补充两个要求：

第一，长任务必须有明确的自主权限边界。 既不能只执行预先列出的命令，也不能因为可以自主探索，就擅自改变算法定义、评价标准或实验目标。

第二，完成与优化必须分开判断。 完成教师任务是必要条件，但不代表研究质量已经足够好；反过来，优化也不是强迫所有指标一直增长。经过可靠比较后发现某个复杂方案没有收益，并回退到更简单的方案，同样是有价值的研究结果。

二、Goal 结构：一个完整的长 Goal

我的建议是，最终只向 Codex 发布**一个覆盖全部任务的专业完整 Prompt**，不再拆成四个独立 Goal。

该 Goal 的目标可以定义为：

完整完成两份教师材料的全部基础、拓展、思考和加分任务，构建参与真实实验的 Multi-Agent 研究工作流，通过结果驱动的持续实验与优化形成可信的派单方法比较，并完成可复现工程、科学可视化、双报告和多层审核。

GPT 的实质修订

GPT 将方案收束为一个父 Goal，并明确研究合同、运行中优化与最终验收分离。

RAW VIDEO 00:55.500 · E01 / GPT AFTER · “一个完整的长 Goal”

E01 续 / E02 · 完成授权

可视化进入研究职责，单长任务获得确认

从“画哪些图”到“怎样研究图型”，再到向 Codex 发出完整长任务授权。

六、可视化：必须成为正式研究任务，而不是最后画几张图

这部分我同意需要大幅强化。

你的要求不应该只写成“绘制 Pareto 图、收入柱状图和热力图”。

应该明确要求 Codex：

> 主动检索本任务相关的高水平科学可视化方案，理解其数据结构、视觉编码和适用条件，针对重要研究问题提出不同图型候选，使用真实实验数据制作样图，比较分析能力与视觉质量，再制作、精修并审核正式科研图表。

6.1 首先进行专门的可视化研究

需要查阅的资料至少覆盖以下方向：

研究主题	重点考察的可视化表现
时空匹配与网约车派单	动态空间匹配、供需密度、时序轨迹、OD 流向
在线算法公平性	ECDF、尾部风险分布、配对差异图、分位数比较
多目标进化优化	Pareto 前沿、Hypervolume 变化、三目标空间分布、平行坐标
强化学习	时空价值表、训练动态、状态价值差异、策略行为变化

可视化研究闭环

GPT 明确要求主动检索图型、比较候选、用真实数据试做、精修并审核；而非仅列出 Pareto 或热力图名称。

RAW VIDEO 01:18.500 · E01 / GPT AFTER · 完整图型筛选仍受真实数据约束

你这次的理解和计划完全准确，给我一份完整详细专业深入的可以直接发给codex的提示词，让它完全按照我们这次的要求和计划完整完成任务，审核，优化后再返回，同时上传github仓库并且返回给我们用于审核的材料让我们进行双重审核

我的最终授权

我明确确认本次理解和计划，要求一份能直接给 Codex、执行全部任务并在 GitHub 双重审核后返回的完整提示词。

RAW VIDEO 01:39.500 · E02 / USER · 同页随后进入真正执行 Prompt

你的完整职责是：

> 在严格遵守教师要求、项目研究协议、数据真实性和科研评价原则的前提下，建立可靠基线，开展丰富的基础控制变量实验，根据真实结果持续诊断和探索，在有依据时尝试优化与策略组合，通过独立审核与修复持续提高成果质量，最终完成完整、可信、可复现且具有高水平科研可视化表现的任务成果。

本次采用长任务模式。

你可以在本文规定的研究边界内，根据实测结果自主提出并执行合理的下一轮实验，不必为每个普通参数变化、调试动作或已有范围内的策略组合等待用户确认。

但你不能未经授权修改研究目标、教师强制要求、核心算法语义、关键数据定义、主要评价指标或正式结论依据。

不要在执行前把所有后续实验组合写死。

先建立可信基础，再通过实际数据和实验决定下一步。

条件性自动探索

得到批准后，Prompt 写明在方法、数据与评价边界内自主增加实验，不能改变核心目标，也不预设全部组合。

RAW VIDEO 01:43.500 · E02 / GPT AFTER · 长任务是授权内连续执行，不是无限试验

PART II · EXPERIMENT DECISION PROCESS

3 先把“比较什么”说清楚

3.1 材料审读先于正式计算

Codex 首先检查了已有仓库和两个新 ZIP，保留原件与实验一成果。中文文件名存在混合误解码，安全提取时记录名称映射、内容哈希和无意义元数据过滤；两城市数据在多个归档里各有三份，核对后确认是重复副本，不能增加统计样本数。两份 PPT 共 39 页、两份 Notebook 共 59 Cells 分别完整审读，教师九道进阶思考题及基础讨论逐项登记。

审读暴露了两个不能靠完成代码掩盖的问题。基础 Notebook 有实际 TODO5，但文字只说 TODO1–4；BB 的 Assignment 代码已经存在，真正的风险是把未匹配队列清空。课件还提瓶颈目标，Notebook 却用总成本 KM。Codex 没有任选一种解释覆盖另一种，而是分别保留 sum 和 max 实现及参考。这是当前提示词已明确要求的核验，不是后来为报告补造的争论。

3.2 低延迟曲线为何先看覆盖

首轮 55 个输入、1045 条方法指标中，教师场景短批次 discard 只服务 25% 请求，司机先到的场景甚至没有服务；回收版本则能完成可用的全部供给。这个读数使图型选择有了明确目的：如果只画已服务订单的分布，丢单可能看起来更好。

Codex 实际生成了完整分母 ECDF 和条件 raincloud 两种候选。前者让未服务质量保留在较低平台，后者虽能显示分布却必须另印覆盖分母。因此正式主图选择 ECDF 加覆盖/尾部对照，而不是因为某种图更复杂。统计单位仍是每个实例及其请求，不能把同 seed 内订单当作更多独立实验。

3.3 从兜底比例到阈值诊断

小阈值 0.5/1/2 有平均 17% 匹配留到 horizon，阈值 5 为 7%。Codex 据此提出机制假设：过小阈值阻塞早期匹配，过大阈值又容易成为局部即时选择。随后才在 3 种到达顺序、相同 5seed 上细化阈值 2/3/4/5/6/8/10/15，没有改变 TBG 核心或凭空增加 deadline 事件。

另一条负例也被保留：一个批次内最小最大成本的 BBmax，在 teacher seed13 全天最大延迟比 BBsum 高 2.162 min。独立核验确认实现与参考正确，因此它是未来司机选择带来的在线局限，不需要把算法改到每个指标都赢。最终独立合成 seed110–114 只用于确认，不重新回流选参。

4 进化优化怎样从端点不足走到有限组合

4.1 先比较基础预算，再引入初始化

进化分支先验证小图编码、解码、非支配关系与二维/三维 HV，然后运行教师 100 种群/300 代/5seed 基线。18 点开发批次中，NSGA-II 的 HV 为 1.090244，NSGA-III 为 1.077092，加权 KM 为 1.098977。这些读数与课件参考数值分开保存，高收入端差距触发下一轮，而不是预先决定复杂混合策略更好。

先增加种群或代数，只改变一个因素。NSGA-II 增种群比增代数更有利，而 NSGA-III 相反，说明同样约六万次评价的资源增加并非相同干预。之后才把真实 KM 匹配编码成初始个体，保持原 100/300 预算，避免把收益混在更多评价次数里。

KM 单项将 II/III 的 HV 提高至 1.111427/1.111494，并减小 seed 波动。接着测试它与种群 200 的一个有限组合，保留基线、增种群、KM 单项和组合四个父项。组合只比 KM 单项增加很小 HV，却增加约一倍 EA 评价、Spacing 变差，因此没有升级最终确认预算。五个未来代理批次上只确认冻结的 II 原预算与 KM 单项，五对 HV 差均为正，均差 0.031470。这是所测输入的支持，不是任意未来需求的理论保证。

4.2 独立审核修正评价，不掩盖旧结果

Research 核验者发现，KM 全部离散权重输出中有支配点，约 10^{-13} 求和差还会制造几乎重复的点。原始输出保持不变，报告指标统一规范去重再取非支配集，并做 8/10/12 位精度检查。此前 Spacing 不再作为当前有效评价，但旧运行没有被改写成从未发生。

初始化额外 41 次标量求解的成本则在正式 hybrid 运行前补入。这个修复影响公平预算解释，不是新增科研增益。NSGA-III 在球面 DTLZ2 上更合适，在三目标派单细带上的优势不明显，也没有为迎合“目标更多就更好”的故事而删去。

5 长期价值的收益为什么要拆开看

5.1 先修数据可见性，再训练

我要求保留真实数据身份，不能把签到代理称为真实订单。数据 Agent 重现教师 25,550 条 local-clock 代理后，Codex 主线程又取两端 UTC 复算，发现 12 对时间矛盾、6 对 UTC 倒序。Research 独立确认后，保留教师主基线，另外剔除副本做稳健性，没有偷偷统一纽约时区或重新定义原数据。

另一项更直接的修正是司机热点。原 Notebook 会读全量签到，本次开发只读 inner 签到，完整重训后也只读前 70% 日期。beta 扫描在验证池完成，未来测试池只在方案冻结后用于确认。300 回合是实际发生的模拟训练，不是 300 天真实运营；这一身份贯穿曲线、表格和报告。

5.2 Double 检验没有被简化为“修复成功”

beta1 下的收入下降伴随大量非正边权。Reinforcement 提出并执行 Double Q 手算、小例和五训练 seed 比较，再由独立 Evolution 核验。Double 提高了 beta1 相对收入，却降低应答，拒绝的可行边比例也未降低；所以没有把理论上的过估计修正直接写成业务效果全面改善。

过程中还发现了工程混杂：更新 coin 与行为探索共用 RNG，Double 多消耗随机数会改变后续行为流。执行器暂停受影响进程，保留旧 Double 身份，分离随机流后重跑；Q-only 数组逐项 bit 等价的旧结果继续按原身份引用。这个闭环由真实问题触发，不是为了让过程报告看起来更曲折。

5.3 从无成本调度到移除边权的回退

主动调度首先完整模拟了相邻移动、距离、时间与忙时，司机没有瞬移。无门槛版本虽然增加 gross 收入，却产生约 5000 km/模拟日的额外空驶。看到这一负结果后，Codex 才提出扣除 λd 的移动门槛，并单独比较 0/1/3/5，说明价值/公里的教学量纲，不假定它是真实能源价格。

原 Q-KM 边权与价值调度组合并未自动形成最强策略。五训练 seed 下，移除边权 LT、保留同一个 learned V 做移动，gross 收入反而每次都更高，因此冻结 KM 即时派单 + 门槛 3 的调度作为 gross 候选。更省空驶的门槛 5 保留为替代；Double 和 NSGA 的独立作用也没有被塞进这个组合中充数。

冻结后的首批 5 日，候选相对 Q-KM 的 gross 差为 640.81，但区间跨 0；随后预登记 20 个新采样 seed，仅确认同一冻结方法，差为 435.45。额外空驶 848.08 km 意味着按 1 单位/km 的情景，收入减额外调度成本之差为 -412.62，区间也为负。这条负结果改变了解释：可以说所测 gross 收入增加，不能说已证明真实净收益。

5.4 融合产生的是权衡，不是自动升级

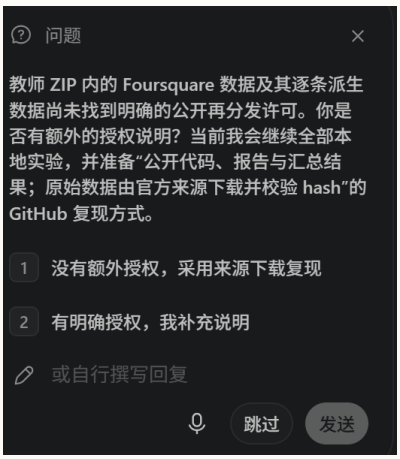
在独立 Q-KM 和 NSGA 成立后，才用长期边权与接驾构造前沿，并把固定膝点/约束选点带回完整仿真。约束方案降低了接驾，但收入和响应也下降；膝点更进一步牺牲服务。因此融合完成了教师加分的实测要求，却没有被称为最终全面最优。

我在执行提示词中要求保留没有收益的合法实验，这一要求在这里得到落实。具体采用、移除和停止是 Codex 在批准规则内依据实测作出的执行判断；没有补写成我看到每一条结果后都亲自选择，也没有把另一个角色的反馈伪装成新的人工质疑。

E03 · 数据许可 / 人工询问

我把数据发布边界交给 GPT 讨论

争议并非本地实验是否继续，而是教师提供的签到数据能否公开再分发。



原始 Codex 权限弹窗

弹窗提示 Foursquare 原始记录与逐条派生数据缺少明确再分发授权。我没有让 Codex 跳过这一问题，而是把真实弹窗交给 GPT 询问如何处理。

处理边界

在无法证明公开许可时，保留本地完整实验，公开可复现代码、输入校验和不泄露逐条记录的汇总结果。

原图：当轮真实上传附件（亦见视频 04:46 的缩略图），不是重绘的弹窗



RAW VIDEO 04:46.500 · E03 / USER · “这是 codex 的弹窗，如何回复”

同意采用选项 1，并补充以下要求：

1. **本地实验完整继续**：继续使用教师提供的原始数据，完整完成此前批准的全部基础、拓展、加分实验和持续优化任务。不得因为公开再分发许可问题减少实验范围、跳过真实数据实验或降低验收标准。
2. **GitHub 合规发布**：公开仓库保存完整源代码、实验配置、测试、可复现脚本、科研图表、双报告和不泄露逐条记录的汇总结果。暂不上传原始 Foursquare 数据、包含原始数据的教师 ZIP、可还原逐条签到记录的派生文件或其他无法确认再分发权限的数据。
3. **保证可复现性**：核验原始数据的准确来源、下载地址和 SHA-256。若能确认合法的原始下载渠道，提供自动下载或手动放置数据、校验哈希、运行实验和重新生成图表的完整说明。若下载渠道无法确认，则如实记录限制，不伪造官方链接，也不声称已完成独立数据下载复现。
4. **保留完整审查能力**：GitHub 上的代码、实验统计、评价器、测试、运行配置、关键结果和报告必须足以进行实质审核。不能以数据许可限制为理由只提供总结而省略可公开的技术证据。
5. **继续单一长 Goal**：这是已识别的公开发布边界，不需要重新规划任务。请继续执行全部已批准的本地研究、Multi-Agent 协作、实验循环优化、可视化制作、报告与内部审核。完成后按原要求 push GitHub，并生成对应固定提交的 GPT 二次审核包。

若后续发现其他真实授权或数据使用限制，仅暂停受影响的操作，保存证据并继续其余工作。

GPT 的回复方向

GPT 建议选“无额外授权，来源下载复现”；后续 Codex 按公开/本地分流发布。这里不冒称我曾逐字发送 GPT 所写的回复。

RAW VIDEO 04:48.500 · E03 / GPT AFTER

6 把结果变成可以审核的成果

6.1 图文和执行证据各自核对

正式制图实际比较了三目标 3D、二维投影与平行坐标，区域 V 的地图小倍数与时间–区域矩阵，以及在线服务 ECDF 与条件分布。图型依据问题和数据选择：真实第三维才用 3D；区域相邻移动需要空间关系；未匹配请求必须在统计分母中可见。不是把默认 Notebook 图换一种颜色就结束。

报告核验还检查图注是否对应真实样本、训练 seed、验证/测试身份、波动区间和图轴。独立审稿发现，某些图只使用一个训练 seed 的五模拟日，不能被文字写成五训练 seed；动态融合和静态前沿的预算也应分别注明。这些表述修复不重跑没有受影响的模型，但要重新构建真正的 LaTeX 源和 PDF。

两本完成版 Notebook 在干净 Kernel 执行，保留教师 Q/LT/Q-KM 原断言，默认 300 回合没有被样本运行替代。完整参数扫描与固定结果另由可重算脚本、当前有效索引和输入/代码/产物哈希追溯。Notebook 执行、重画图和报告编译是不同检查，任何一项不能冒充另外两项。

收尾时 Codex 把一个尚未解析命令行参数的评估入口当作支持`--help`的脚本调用，实际重放了冻结测试评估并覆盖部分文件。随后单独保存重放身份与可恢复检查点，独立 Agent 逐条确认 95 条 episode/trace 与原运行哈希相同，科学汇总及融合选择一致，仅运行耗时改变。未能恢复的旧逐日耗时字节如实登记；入口增加帮助参数和既存输出拒写检查。这个问题说明，命令行的无副作用行为也必须实际验证，不能靠脚本命名推断。

6.2 公开发布边界也是一次真实反馈

数据审计没有找到额外公开再分发许可。我把 Codex 的权限弹窗发给 GPT 询问，GPT 建议采用“无额外授权，来源下载复现”，同时保留完整本地实验并限制公开数据类型。后续 Codex 交付记录表明，公开仓库采用了该数据边界。现有视频不能单独证明我曾逐条向 Codex 发出那段完整建议，因此不把 GPT 建议改写成我当时的逐项原话。原始签到、含数据的 ZIP 及可还原的逐条派生保持本地；这没有降低教师任务和实验范围。

独立包审查进一步实测：匿名的匹配选单矩阵与多条总目标可以形成满秩方程，恢复单笔 fare。因此“删掉用户 ID”还不够，真实 EA 的 membership 记录也从公开投影中移除，保留聚合前沿、收敛、参数、耗时、哈希和独立审核。原始完整结果没有被删除或改写。

原作者的下载渠道经过真实获取和校验。早期转换出现极少坐标末位差异，Research 随后查明直接 Decimal 十位有效数字 ROUND_HALF_UP 和文件末尾无 CRLF 的规则，重新独立下载并转换后，两城市 SHA 与教师 CSV 逐字节一致。旧近似转换和失败诊断保留原身份；新输入重建仍准确标注作者来源，不倒写提供者，也不把输入一致扩大为任意环境随机产物 bit 一致。对数据许可的处理是发布范围控制，不是只剩总结而隐去实现。

7 本轮保留的认识

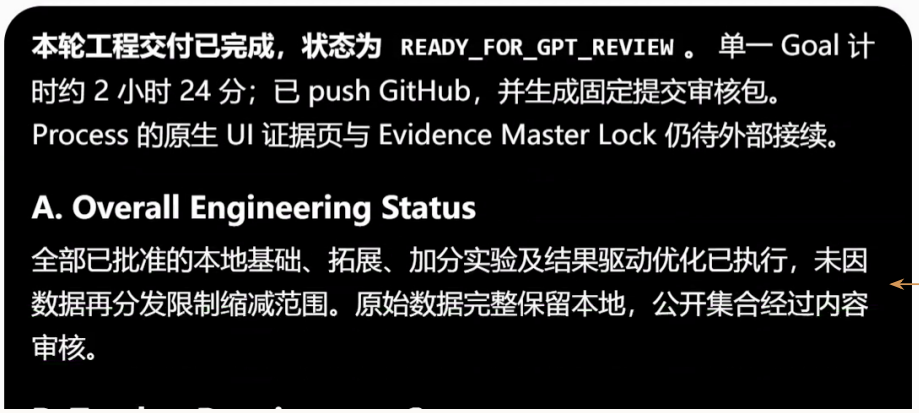
这次连续执行把我原先要求的“先保证正确”落实到具体对象：服务覆盖、相同目标的离线参考、共同 HV、真实可行动作和物理移动成本。算法跑通以后，仍需检查比较是否成立、效果代价是什么；方法没有新增价值时，回退也构成有依据的结果。

我随后要求网页端 GPT 对固定提交进行二审，并在下一组真实截图中区分代码与科学成果、Process 证据和最后提交的不同状态。

E04 · Codex 交付 / 外部审核请求

技术完成之后，我要求独立读取真实成果

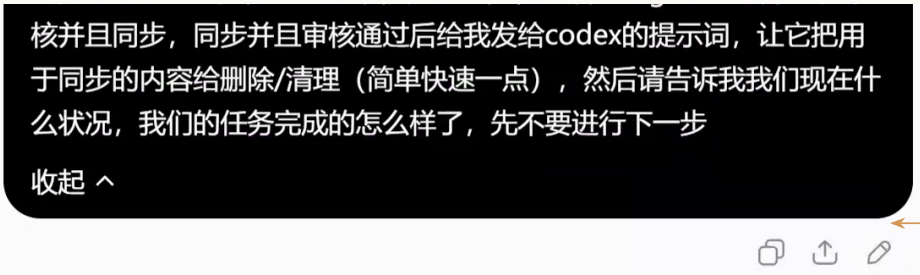
状态汇报是待核查的输入，不是已被用户验收的最终结论。



我转交的 Codex 回执

Codex 报告已提交固定 GitHub 版本，但 Process 聊天证据尚未补完；工程完成要另行核查。

RAW VIDEO 04:51.500 · E04 / USER 转交 Codex 文本；引号内容身份为 Codex 报告



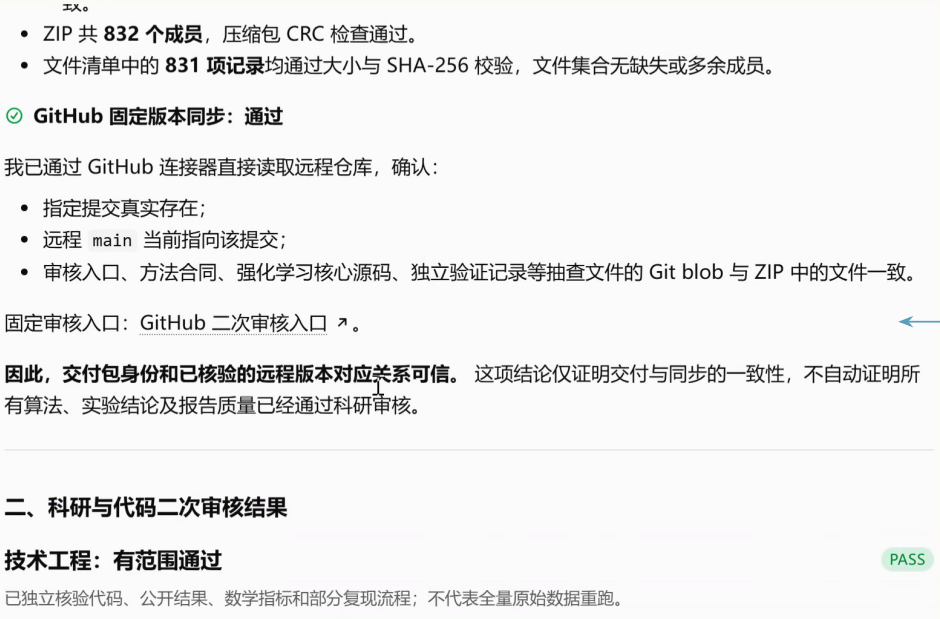
我的外部审核要求

我要求 GPT 从审核包和 GitHub 独立检查，同步后才给清理建议，并要求本轮先不进入下一阶段。

RAW VIDEO 05:05.500 · E04 / USER CONTINUATION · 审核请求与 Codex 报告在同一用户消息内

GitHub 版本身份与技术结论分别验收

先核对来源与版本，再独立复算关键指标；不把未运行的检查写成已核验。



GPT 外审证据

GPT 报告 ZIP 有 832 成员、831 条文件清单记录通过哈希验证，并直接读取固定 GitHub 提交。

RAW VIDEO 05:08.500 · E04 / GPT AFTER · 对应固定 commit: 3ff6353915fc…

第二次审核还包括独立数值复算：在线延迟、车队收益、主动调度成本情景，以及 125 条进化指标的 HV/Spacing。报告明确保留了原始数据全量重训不在本次外部复算范围内。

我们是否已经完成了除了process report之外的所有任务?

我的完成度追问

我继续询问“除了 process report 之外”是否完成，以区分技术成果完成、理解验收与教师提交。

RAW VIDEO 05:19.500 · E05 / USER · 新互动以用户原生 UI 开头



基础控制变量实验、参数敏感性	已完成
结果驱动的自主研究和持续优化	已完成，有真实迭代证据
单项、组合、消融、负结果与回退	已完成
Multi-Agent 实质协作体系	已实现并取得协作证据
科学可视化（22张数据图、2张 draw.io 技术图）	已完成并审核
Experiment Report（26页）	已完成并通过技术审核

GPT 明确区分三类状态

GPT 说明技术和实验成果已完成范围的核验，但 Process 原生 UI、理解验收和教师正式提交不能一起宣布通过。

RAW VIDEO 05:20.500 · E05 / GPT AFTER · 对完成度追问的直接回应

E06 · 任务后的工作流反思

一次实验使我重新审查长期规范

这不是实验中的新算法，而是我对协作机制执行成本与长期适用性的后续讨论。

我需要修改一些这个gpt项目的项目设置，我在这次的对话中提出了一些新的要求，你可以整理一下，然后我们讨论一下哪些是要作为持续性的设置更新进项目中的，以及我们之前的一些工作流和项目设置有些我这次也不够满意的
现在请你仔细理解我的要求并且整理一下，并且补充一下任务要求，让它更完整专业，我需要确认你是否已经理解了我的任务，我确认后才可以进行实际操作

我提出的元问题

我没有要求复制本次实验规则，而是要求回顾旧项目设置哪些地方不够好，并先整理讨论再修改。

RAW VIDEO 05:25.500 · E06 / USER · 本次工程完成后的独立长期治理讨论

E06 ・同一互动续页 / GPT 原始回应

《智慧城市与位置服务》项目设置与工作流升级：需求理解与讨论方案

我理解，这次你希望做的**不是简单地把实验二新增的要求复制进 Project Settings**，而是借助这次实验的实际执行经验，对我们整个《智慧城市与位置服务》项目的长期研究工作流进行一次系统性复盘和升级。

目标是让后续实验、课程设计、研究任务能够更高质量、更自主、更高效地完成，同时减少你与 GPT、Codex 之间不必要的交接和反复确认。

而且，这次不仅要讨论新增规则，还要**主动审查已有规则中哪些设计不够合理、执行效果不好、约束过多或约束不足，决定保留、强化、修改还是取消。**

GPT 重新界定审查

GPT 将任务定位为长期规范与执行工作流复盘，强调不直接把实验二特有参数固化进项目。

RAW VIDEO 05:25.500 ・E06 / GPT AFTER ・同一时刻可见回复开端

E06 续・进一步审核

批准方案并不等于自动修改现行规则

审核、候选条款、正式源修改、GitHub 同步和 UI 更新都是不同操作。

这次的理解完全正确，请按照这次的要求和计划完整完成任务并且返回结果

我的后续明确要求

确认理解后，我要求完整完成系统审查并返回结果；这一步尚未授权偷偷修改 Project Settings。

RAW VIDEO 05:49.500 ・E06 / USER ・与上页同一长期治理主题，但为新一轮明确指令

《智慧城市与位置服务》项目长期规范升级审查

2026年11月5日 · 正式条款审查与升级建议 · 待用户裁决

一、审查结论

这次检查后，我认为：**不需要推翻现有工作流，但需要对研究规划、自主执行、Multi-Agent、可视化研发和审核机制进行一次实质性升级。**

现有规范已经具备严谨的研究基础，包括教师任务优先、公平实验、真实证据、双报告和 GitHub 复现。主要问题不在于缺少这些原则，而在于：

1. **研究计划过早冻结**：尚未充分区分需要固定的研究规则与可以随着实验结果调整的后续实验计划。
2. **自主探索授权不够清楚**：允许 Codex 自动裁决已有候选，却没有充分说明什么时候可以自主提出新实验、诊断或组合。
3. **Multi-Agent 的质量验收不足**：强调真实角色和工具行动，但还需要评价协作实际解决了什么问题。

分阶段治理的结论

GPT 指出旧协议已有严谨底线，重点应改造研究计划、自主探索、实质 Agent、可视化与审核方式。

RAW VIDEO 05:49.500 ・E06 / GPT AFTER ・根据实际时序发生在实验技术外审之后

8 一次长任务给我的实际认识

我在这次实验里最明确的修改，是不再要求 GPT 先写出所有后续实验的详细顺序。我仍要保留教师范围、数据语义、指标、预算和最终确认这些边界，但允许 Codex 在边界内根据真实结果安排必要的单项诊断、有限组合和回退。这种模式是否有效，不能靠“单 Goal”三个字证明，而要看真实实验、错误修复和独立检查的记录。

实际执行留下了相互支持也相互限制的结论。TBG 阈值提高可以降低平均延迟，却未保持最大延迟的优势；KM 混合初始化在已测输入上改善前沿，但扩大预算的附加收益很小；Q-KM 在不同车队规模下有正有负；主动调度的 gross 增益要与真实产生的空驶量和成本假设一起读。这样的结果使我更明确：**完成算法、支持效果、适合采用和整体交付，是四种不同判断**。

我也看到了工作流自身需要保持的边界。Codex 内部审查是真实工程证据，却不能替代 GPT 读取固定 GitHub 版本的二审；Agent 自动提出和执行的候选，不能在 Process 里写成我逐项追问；录屏提供的 UI 是人的真实要求和回应，不能把后来形成的专业术语倒写成最初的自然语言。正因为这些边界被记录下来，报告才能同时展示我的判断与自动研究的实际贡献。

下一轮项目工作可以继承这种做法，但不能直接继承本次的批次长度、车队数量、参数扫描或长任务授权。具体研究合同仍应由我在任务开始时确认；在工作流本身没有必要的新增价值时，也不应为显示复杂性而制造新的 Agent、图表和流程层。