

实验一过程报告

我与 GPT 的持续交互： 改进工作流，完成实验一

本报告记录我与 GPT 通过持续讨论、质疑、修改和核验，逐步完善协作工作流并完成实验一的过程。我们从既有协作经验出发，围绕任务理解、方法比较、实验反馈和报告表达调整做法；明确的工程任务交由 Codex 实现和运行，结果再回到讨论与核验中，推动后续决定。

截图采集

文档中的所有对话截图，都是我在 ChatGPT 网页中通过 sharex 软件利用长截图一张一张手动截取然后再利用图片分割器功能一张张切割并提供的；在本次协作中，GPT 没有直接截取我的网页对话界面的功能。

吴博闻 • 10245102410

目录

先回看工作流的形成，再记录我与 GPT 推进实验一时的交互与决定。

Part I workflow构建

协作方式的起点	3
范围与研究判断	5
报告与视觉表达	9
可追溯交付与研究入口	17

Part II 实验一中的交互与决策

任务理解与研究起点	21
面向实验任务的 Multi-Agent 构建	24
执行与审核机制的落地和修正	31
共同评价下的实验与 AI 建议检验	46
方案组合、回退与最终确认	55
理解验收与报告表达的形成	64
整体 workflow 回顾	76

从既有协作经验开始

我先回看工作方式是怎样形成的。在《软件系统优化》课程里，我已经尝试让 GPT 帮我理解任务、设计工作和检查结果，再把明确的工程任务交给 Codex；与此同时，我要能自己解释代码和实验原理。

我提出分工，GPT 回应

我要重新和你制定一下流程，这些具体的从环境到代码实现等，都由 codex来完成，你只需要给我可以直接发给codex的提示词就可以，你负责告诉我这个任务是干什么的，以及验收codex的任务（你的提示词里要包含验收的内容，我会把codex的返回结果发给你），最重要的是！！
你要负责为我解释，让我能应付老师的验收，老师会问关于实验和我的代码实现的问题，我虽然自己不写代码，但是我得搞懂codex的代码在干什么，怎么干的等
现在请你仔细理解我的要求并且整理一下，并且在我的基础上帮我完善并且补充一下任务要求（我目前的要求都是简单的初步想法，你可以提出更好的方案和建议），让它更完整专业，我需要确认你是否已经理解了我的任务，我确认后可以实际操作

收起 ^

先明确执行分工

我把环境和代码实现交给 Codex，同时请 GPT 解释任务、设计工作，并在结果返回后帮我检查。

理解贯穿整个过程

我还要求把代码和实验原理讲到我能自己解释。后来，方法复盘和理解验收沿着这一要求继续展开。

我的回看

这段经验给了我一个可用的起点。进入新课程后，数据、参数和 AI 建议的判断又提出了新问题。

思考了 36s >

我已经理解你的目标。你不是要我直接写代码，也不是要我一步一步教你在终端执行；你希望建立一个明确的三方工作流：

Codex 负责实际工程执行，我负责研究理解、任务设计、Codex 指挥、独立验收，以及把 Codex 做出来的东西真正教会你。 你主要负责把我的提示词交给 Codex，再把 Codex 的返回结果发回来，并最终能够自己应付老师的现场验收。

这个分工是可行的，而且我建议比你目前的初步设想再严格一些。尤其是这门《软件系统优化》，老师很可能

同一回答的后半段

Codex 回复“全部完成”
→ 我说“OK”
→ 直接进入 A2。

正确流程必须是：

老师任务 → 我解读 → 我给 Codex prompt → Codex 实做 → 你发返回 → 我独立验收 → 不合格则修 → 合格后我教你 → 口试检查 → 最终提交。

也就是说，我同时扮演三种角色：

****Task Designer:** **把老师要求转换成 Codex 能可靠执行的工程任务。

****Reviewer:** **不相信自报完成，以证据验收 Codex。

****Tutor / Viva Coach:** **让你真正理解自己的实验和代码，能够面对老师追问。

Codex 则只是 **Executor**，负责环境、代码、实验、测试、文档等实际工程生产。

你则不需要自己承担底层开发，但你最终必须成为能够解释这份成果的人。

迁移之前，先让真实任务检验旧经验

进入智慧城市项目后，我先让 GPT 判断旧课程的做法哪些可以借用、哪些需要重新设计。随后我把第一次正式任务发给它，请它按老师材料检查这些做法是否合适。

迁移请求与初步回应

星期四 10:11

我想借用软件系统优化这个项目里我们的一些要求和注意点，然后我接下来要新开一个智慧城市与位置服务项目，我需要把一些要求和注意点让那个项目也同时遵守，请先列出我们的要求，然后我告诉你那些我需要迁移哪些是专属于软件系统优化的注意点和要求
现在请你仔细理解我的要求并且整理一下，并且在我的基础上帮我完善并且补充一下任务要求（我目前的要求都是简单的初步想法，你可以提出更好的方案和建议），让它更完整专业，我需要确认你是否已经理解了我的任务，我确认后可以实际操作

我理解你的目标。这一轮只做“规则盘点 + 迁移设计”，不修改任何项目设置，也不创建“智慧城市与位置服务”的正式规则。等你确认后，我们再决定哪些规则迁移、哪些保留为《软件系统优化》专属，并最终整理成新项目的完整系统设置。

我建议不要直接把《软件系统优化》的整套规则复制过去，而是先拆成“通用工作原则”和“课程/工程专属规则”。这样新项目不会带入 GitHub、水杉、Codex、编译运行等无关约束。

我补充第一次真实任务

我给你看一下第一次的任务，你理解一下，然后可以根据第一次的实际要求和任务等融合我们的要求，现在请你仔细阅读我发给你的文件，理解我的要求并且整理一下，并且在我的基础上帮我完善并且补充一下任务要求（我目前的要求都是简单的初步想法，你可以提出更好的方案和建议），让它更完整专业，我需要确认你是否已经理解了我的任务，我确认后可以实际操作

思考了 1m 30s >

我已经理解了，而且看完第一次任务后，有一个很重要的结论：

“智慧城市与位置服务”不能直接复制《软件系统优化》的规则。

两门课有一部分通用原则完全可以迁移，但第一次作业已经暴露出几个本课程非常特殊的要求：时空数据真实性、参数依据、评估设计、AI 批判、基础任务与拓展任务分层，以及老师给的 starter notebook/助教系统优先。

这一轮我只整理规则和提出完善方案，不修改项目设置、不完成实验一、不写代码、不生成报告。

同一阶段：任务包的边界

但老师正式“作业细则”里，LLM 智能体是选做。实验一

因此我建议新项目加入一条非常重要的长期规则：

不能根据资料包的复杂程度反推任务范围。任务范围只能由老师正式要求决定。

文件可以属于：

按新任务调整做法

时空数据、参数、评价和 AI 建议带来了新的判断问题。GPT 据此补充了原有分工中缺少的研究环节。

分清材料的用途

老师材料用来确定任务，已有代码用来检查和复用，历史输出用作参考。本轮成果则需要通过实际处理和验证形成。

老师的选做要做，额外扩展另作判断

我把两类“多做一点”分开：老师列出的选做、拓展和思考题也要完成；GPT 额外想到的内容先说明价值，再由我决定是否加入。这样既能覆盖课程任务，也能控制额外工作的范围。

我的原始补充：第 1 点

我补充一些点：
1.所有的选做任务必须做，以及你可以适当提出额外的有用的比较好的想法和任务，然后我们来决定一下是否完成（或者我们可以根据完成后的结果选择是否把该额外任务加进去）

两类要求一起保留

我希望完整完成老师的选做内容，同时保留对额外想法的选择。GPT 随后把两者分别列入任务范围和候选增强。

GPT 把要求整理为任务层级

二、任务层级需要重新定义

你明确要求：

老师所有选做任务，我们也必须做。

所以原来的 REQUIRED / EXTENSION 分类需要修改。

我建议以后统一使用四级：

T1 - TEACHER_REQUIRED
老师明确必须做
必须完成

T2 - PROJECT_REQUIRED
老师标为选做，但我们项目规定全部完成

GPT 整理任务层级

我先用自己的话提出要求，GPT 随后用 T1、T2、T3 整理成分类，便于我们继续检查任务归属。

继续区分额外增强

T3
我们提出的额外实验

老师原本的评分说明是基础任务 60+、拓展任务 90+；我们自己的策略则是默认覆盖基础+全部拓展。

实验库！

三、额外任务不能直接擅自加入

这一点和“所有老师选做必须做”要严格分开。

我可以根据：

- 网络研究；
- 文献；
- 数据特征；
- 现有结果；
- 实验失败；
- 可视化发现；

主动提出额外任务。

但只能进入：

CANDIDATE_ENHANCEMENT

例如实验—未来我可能提出：

- 参数敏感性分析；
- 不同轨迹类型分层评估；
- compression-error Pareto frontier；
- AI 建议反例库；
- 留出轨迹验证；

查阅资料时，我还要知道它支持什么

任务范围理清后，我又要求在需要时主动检索并审核来源。我希望每个重要判断都有可回查的依据：找到网页以后，还要追到原文，看它究竟支持哪条结论。

我的原始补充：网络研究

5.智慧城市的任务和软件系统优化的任务不同，智慧城市需要我们先搜索网络上的资料，这一步需要加上去，并且你所有搜索的资料必须经过审核，所有链接必须真实可访问

关键判断要能回查

我要求链接真实可访问，关键内容经过核对。文献的标题之外，还要留下与当前问题有关的依据。

GPT 补充 Source Audit 与来源顺序

网络资料必须建立 Source Audit

以后搜索到一个网页不等于可以引用。

我建议关键资料至少记录：

- 标题
- 作者/机构
- 来源
- 发布日期/更新时间
- URL
- 访问状态
- 资料类型
- 它支持哪个结论
- 权威等级
- 是否存在替代原始来源

来源优先级：

- 老师正式材料
- > 政府/官方机构/标准
- > 原始数据发布方
- > 论文原文
- > 官方技术文档
- > 权威研究机构
- > 高质量行业资料
- > 新闻媒体
- > 博客/论坛/知乎等

对于关键结论，原则上尽量回到原始来源。

例如：

- 论文新闻报道
 - 找论文
- 博客解释某算法
 - 找论文/官方文档
- 媒体引用某城市统计数字
 - 找政府统计页面

把来源与判断对应起来

GPT 将作者、时间、来源类型和支持关系整理进 Source Audit；老师材料负责确定任务，外部资料帮助我们判断方案。

我的回看

这条要求后来直接影响实验一的检索：每篇论文都要说明怎样帮助处理轨迹问题。

不确定时，先比较候选，再让实验说话

面对有分歧的问题，我希望 GPT 先给少量有根据的候选，讲清各自的依据和问题。讨论后仍无法决定，就固定比较条件，让实验结果帮助我们取舍。

我的原始补充：第 3 点

3.这次的流程需要稍微更改一下，codex负责写代码和整理结果之类的，但是方案的产出改为由你（gpt）来做，你的所有假设和思考和方案等必须得经过我的审核，可以和我讨论，对于你不是100%确定的假设等，你需要列出2-3种最好的/最有可能性的假设，然后我们可以互相讨论，如果讨论后仍然无法确认，得把不同的假设并行做实验，然后根据实验结果选择最好的假设

把不确定性摊开讨论

我提出先看两三种合理方案，再判断是否需要实验。这样可以一起检查假设，也能看清每个候选的代价。

GPT 区分候选与未决问题

四、假设与不确定性机制需要正式建立

你提出的这一点我非常赞成，但需要稍微收紧，否则“不是 100% 确定”会导致几乎所有细节都列三套假设。

我建议只对会实质影响方法、结果或解释的关键不确定性触发。

以后每个关键判断分三类：

CONFIRMED

由统计、数据、官方资料或实验可以确认。

CANDIDATE

存在多个合理路径，需要参与选择。

UNRESOLVED

讨论后仍无法确定，需要并行实验。

为下一步确定依据

GPT 后来用 CANDIDATE、UNRESOLVED 记录不同情况：有合理候选时继续比较，讨论不足时转入公平实验。

同一回答：讨论不足时进入比较

如果讨论后仍然无法判断

则：

H1

H2

类型H3

↓

保持其他条件一致

↓

并行实现

↓

统一指标评价

↓

比较结果

↓

再决定采用哪个

这实际上就是一个小型消融实验。

而报告里这种过程非常有价值，因为它能清楚证明：

方法不是由 AI 随便猜出来的，而是人和 AI 提出候选、再由实验裁决。

我的参与体现在质疑、修改与选择中

我明确要求参与讨论和判断。重要假设、方法或结论有问题时，我可以质疑、修改、否决，也可以要求再验证；普通工具操作则按已经确定的规则继续执行。

我的原始补充：人的参与

4.这次老师会要求“人”（即我的参与），为防止全部由ai来完成，老师希望看到我与我ai的交互，所以关于我和你方案的讨论，特别是如果我驳回了你的某个点，这种必须截图放在报告中，总之把我们比较好的交互对话截图，然后放在我们的报告文档里（你可以返回给我截图，然后我放到codex的目录中）

我的判断能改变方案

我希望在关键问题出现时进入讨论，提出自己的看法，再和 GPT 一起决定怎样继续。

GPT 明确判断与执行的分工

用户：Human-in-the-loop 决策者

你的参与不是形式性的“确认一下”。

你负责：

- 提供正式材料；
- 审核我的方案；
- 对关键假设提出质疑；
- 接受、修改或否决方法；
- 参与无法唯一判断的问题讨论；
- 决定哪些额外实验值得加入；
- 必要时参与结果解释；
- 保留有价值的人机讨论作为课程证据。

因此整个项目应该明确体现：

GPT 流程
→ 用户提问/修改/认可
→ GPT 修订
→ 用户批准
→ Codex 实现
→ 数据反馈
→ GPT + 用户再次判断

而不是：

把质疑落到具体依据

反例、单位、坐标和前后指标，让我们能够检验分歧。GPT 把这些内容补进了 AI 建议的核查过程。

AI 建议还需要证据

九、第一次任务还要求一种《软件系统优化》里没有的东西：AI 批判

这一点不能照搬原项目的规则。

《软件系统优化》中我们要求正式 README 不要出现：

ChatGPT
Codex
AI
Prompt

因为它们属于内部生产痕迹。

但是这门课程的老师明确要求报告里包含 AI 批判。实验一核心产出甚至写了：

实验过程报告（包含 AI 批判）。实验一

而且要求：

- 检查 AI 建议是否有事实或计算错误；
- 检查单位；
- 检查坐标处理；
- 检查无依据插值；
- 至少构造一个反例；
- 比较修改前后的指标；
- 说明哪些 AI 建议被拒绝；
- 说明拒绝原因；
- 分析 AI 建议的隐含假设；
- 可以反问 AI 它的前提是否成立。

分别记录最终结果与方案形成过程

随着讨论变多，我发现只保留最后结果会丢掉方案形成的过程。因此我要求两份报告各自回答问题：Experiment Report 解释最终方法、实验与结论，Process Report 记录我怎样讨论、判断和验证。

我提出两类文档，GPT 回应

智慧城市与位置服务

还有几处需要继续确认的：

1.老师要求文档除了最后的实验报告，还需要过程汇报（过程汇报就是我和ai的交互过程），也就是说要把这两个分开，而且我和ai的交互过程的有关内容需有更多的注意和权重

2.你不能直接截图我和你（gpt web）在网页端的ui截图吗？如果不能的话需要你主动告诉我截图哪次的对话，我这里给你一次我的截图（但是你看这次的长截图，尽管这么长了仍然截图不完），所以我们需要一些短的交互，用于截图，如果真的用我们的真实对话是不行的，我认为可以这样：比如你提出了方案a，我认为某个点不可以，然后我们认为这个很适合放在过程文档中，你就重新给我一个口语化，符合我风格的输入，然后你再简化一些输出，这个过程要把重要的点作为输入和输出，并且展示我们的交互和我的思考等，然后把新的我们的那个对话截图放进去（这样确实是我们的真实过程，只是稍微精加工了一下）

现在请你仔细理解我的要求并且整理一下，并且在我的基础上帮我完善并且补充一下任务要求（我目前的要求都是简单的初步想法，你可以提出更好的方案和建议），让它更完整专业，我需要确认你是否已经理解了我的任务，我确认后可以实际操作

收起

两份报告各有重点

实验报告帮助老师理解做法与结果；过程报告让老师看到这些做法怎样在互动和验证中形成。

保留改变方案的经过

我为什么改方案、什么证据改变了判断，是这份过程报告需要讲清的内容。

我的回看

同一事实可以进入两份报告：一处解释技术理由，另一处说明这个理由怎样在讨论中形成。

思考了 42s >

我理解了。你这次补充后，“过程汇报”应该从辅助材料提升为**正式核心交付物**，而且它和“最终实验报告”必须彻底分开。你给的这张长截图也验证了一个现实问题：它大约只有 153×2047 px，虽然非常长，但压缩后正文几乎无法阅读，所以“把完整长对话截图塞进报告”这条路不合适。

另外先明确回答你的第二点：**我不能直接截取你本机浏览器里的 ChatGPT Web UI。我看不到也不能操作你当前浏览器窗口，因此不能替你按下截图键、直接取得原始 UI 截图。我可以做的是：在值得保留的讨论发生时，主动告诉你哪几条消息值得截图、从哪截到哪儿。建议文件名和图注；你截完发给我后，我还可以帮你检查清晰度和是否适合放进过程汇报。**

你提出的“把重要长讨论整理成一次短而真实的确认交互”是可行的，但我建议稍微规范一下，避免最后看起来像事后伪造过程。

同一轮：过程报告的定位

我建议固定为：

A. 过程汇报 / Human-AI Interaction Report

核心回答：

我们是怎么一步一步形成方案的？人体做了什么判断？AI 的建议如何被审查、修改、否决和验证？

这里重点不是最终算法多厉害，而是：

- 我最开始怎么理解问题；
- 搜索了哪些资料；
- 我提出了哪些候选方案；
- 你为什么接受或拒绝；
- 哪些地方存在不确定性；
- 我们为什么决定并行实验；
- 实验结果如何改变我们的判断；
- AI 哪些建议有问题；

围绕关键决策整理分散的对话

一次决定常常跨越几轮讨论，中间还会有后补说明。我希望把相关内容放到一起，让读者顺着问题、回应、验证和取舍，理解这次决定怎样形成。

回引前页要求：保存过程记录

2.你不能直接截图我和你（gpt web）在网页端的ui截图吗？如果不能的话需要你主动告诉我截图哪次的对话，我这里给你一次我的截图（但是你看这次的长截图，尽管这么长了仍然截图不完），所以我们需要一些短的交互，用于截图，如果真的用我们的真实对话是不行的，我认为可以这样：比如你提出了方案a，我认为某个点不可以，然后我们认为这个很适合放在过程文档中，你就重新给我一个口语化，符合我风格的输入，然后你再简化一些输出，这个过程要把重要的点作为输入和输出，并且展示我们的交互和我的思考等，然后把新的我们的那个对话截图放进去（这样确实是我们的真实过程，只是稍微精加工了一下）

现在请你仔细理解我的要求并且整理一下，并且在我的基础上帮我完善并且补充一下任务要求（我目前的要求都是简单的初步想法，你可以提出更好的方案和建议），让它更完整专业，我需要确认你是否已经理解了我的任务，我确认后可以实际操作

收起 ^

把相关讨论归在一起

我提出要保存有意义的互动，GPT 随后建议按决策事件组织。一个问题分散在几轮里，也可以沿着它的变化一起阅读。

GPT 建议按决策事件组织

二、过程汇报不能变成聊天记录流水账

这是我建议新增的一条重要规则。

不应该这样：

截图1：聊了十几屏
截图2：又聊了十几屏
截图3：继续聊

老师最后根本不知道哪句话重要。

我建议以**决策事件（Interaction Episode）**组织。

每一个高价值互动单元都形成：

问题背景
↓
GPT提出方案/假设
↓
用户质疑、修改或否决
↓
GPT重新分析
↓
GPT提出新的方案/假设
↓
必要时设计实验
↓
得到结果
↓
用户参与最终判断
↓
形成决策

讨论清楚后作简短确认

关键问题形成结论后，再用简短确认记录选择和理由。这样既保留真实推进过程，也方便后续回查。

自然讨论结束后的简短确认

十四、从现在开始，我建议正式采用“Interaction Checkpoint”

以后每当我们完成一个重要方案判断，我不会让对话无限拖长。

我会提示：

这个决策值得进入过程汇报，要不要现在做一次简短 Interaction Checkpoint?

你同意后：

- 我帮你把你刚才真实表达的意见压缩成一句适合截图的口语化表达；
- 你自行修改后发送；

让图帮助发现和解释轨迹问题

我希望智慧城市报告有更丰富的可视化，重点是让图与数据和研究问题对应。我关心图能否解释异常、参数变化和结果取舍，也希望图能帮助我们发现下一步需要研究的问题。

我提出可视化要求

📄 智慧城市与位置服务

还有一件事，你要强调智慧城市的文档里需要更多的可视化图表，而且要高级的（按照我们之前说好的那些，你再复述一遍，特别是告诉我打算用什么形式的可视化模式，如何做到高级美观，不是针对这一次的作业，而是针对这个项目！我需要让人眼前一亮，觉得很高级的可视化表现形式，举例比如多维图（六维图）等这种，我这只是举个例子，不是让你一定要用多维图，我的意思是类似这样的高级可视化表现形式）现在请你仔细理解我的要求并且整理一下，并且在我的基础上帮我完善并且补充一下任务要求（我目前的要求都是简单的初步想法，你可以提出更好的方案和建议），让它更完整专业，我需要确认你是否已经理解了我的任务，我确认后才可以进行实际操作

思考了 27s

理解，而且这一点应该成为《智慧城市与位置服务》相对于《软件系统优化》的一个非常明确的文档差异。

《软件系统优化》的正式报告主要靠“代码/终端截图 + 简短技术回答”建立证据；而《智慧城市与位置服务》的 Experiment Report 应该采取更强的 **visual-first（可视化优先）** 思路：

能用高质量地图、轨迹图、统计图或多维可视化清楚表达的数据和结果，就尽量不要退化成控制台截图、简单数字表或大量文字。

但这里的“高级”不能理解成“图越花越好”。我们要追求的是：

图也参与研究

我希望图既展示结果，也帮助理解数据、发现问题和比较方案。GPT 据此展开了不同图型的研究用途。

可读性优先

图型和复杂度都服从要解释的问题。技术图使用真实数据或明确结构，读者应能直接看清关键关系。

GPT 把图的研究职责展开

一、我建议把智慧城市项目的可视化定位提升到正式核心要求

以后不是：

做完实验
→ 有数据
→ 随便画几张图

而是：

研究问题
→ 判断数据结构
→ 选择最合适的视觉编码
→ 设计高级可视化
→ 用图发现/验证现象
→ 写结果分析

也就是说，可视化不只是展示结果，还应该参与：

- 数据理解；
- 异常发现；
- 参数选择；
- 方法比较；

同一阶段：复杂度服从可读性

这样更容易做到你说的：

让人眼前一亮。

三十、但是绝不能让“高级图”损害可读性

我们最终仍然坚持：

信息表达
➢
可解释
➢

给关键互动足够的阅读空间

我希望关键上下文能够完整保留，因此提出按内容安排篇幅。原始截图先保存下来，正式页面再选择与判断相关的窗口；一般过程简要呈现，核心决策则展开说明。

我对证据页面的补充

大部分内容我都觉得合理，这是我目前想到的和你有点出入的地方（可能还有别的，我这里暂时想到这么多）：

- 1.我觉得一次长真实交互截图可能不止两页，可能会更多，然后我认为除了旁边的分析和批注，如果需要，在图片上面下面还可以加说明，不局限于旁边的分析批注
- 2.一般过程也需要截图，我们最后确定的东西也都要截图，但是一般过程可以类似汇总后再一块截图那种
- 3.不同颜色承担不同的语义我觉得合理，非常的不错，大量文字本身可以使用比如黑色字体，然后再额外在需要的地方用不同的荧光色把截图中的内容划出来，旁边的批注颜色也是如此
- 4.然后我认为我们都会需要头脑风暴图，以及多张流程图等，每张图展示我们的思维过程和内容演变过程等

然后你说的那种大的图来展示演变过程，在我这里就是把多张流程图合并在一块，这样如果能画出来当然更好，而且能展示逻辑性，但是如果实在画不出来，或者有额外的需要画的逻辑图，流程图也是不能漏掉的。现在请你仔细理解我的要求并且整理一下，并且在我的基础上帮我完善并且补充一下任务要求（我目前的要求都是简单的初步想法，你可以提出更好的方案和建议），让它更完整专业，我需要确认你是否已经理解了我的任务，我确认后可以实际操作

收起 ^

证据内容决定篇幅

我要求关键互动可以跨必要页数，并保留最后的确认。GPT 随后把分页依据改为实际内容和阅读需要。

先保存，再组织阅读

原始发言与回应先保存完整，再安排节选、页序和侧注。这样后续修改版式时仍有可靠的原件可用。

，Process Report 的定位要进一步调整：它不仅是“几个关键决策案例”，而应该是完整过程档案，但正文仍然需要经过设计，不能退化成长聊天记录合集。

GPT 改为按实际内容分页

一份可追溯的人机协作研究过程档案，但正文仍然需要经过设计，不能退化成长聊天记录合集。

我建议把你新增的 4 点正式吸收后，将 Process Report 的核心设计原则修正如下。这一轮只确认规则，不开始制作模板。

一、长真实交互不能预设“两页上限”

这一点我同意。之前我说“两页连续截图”太保守。

以后应该定义为：

一次重要真实交互需要多少页，就使用多少页；页数由内容完整性和可读性决定，不人为限制为 1-2 页。

例如一个核心讨论可能包含：

GPT 提出 3 个方案
↓
用户逐项质疑
↓
GPT 重新分析
↓
用户补充课程约束
↓
GPT 提出 A/B 实验
↓
用户修改实验设计
↓
最终确认

如果真实对话需要 3、4 甚至更多页才能清楚展示，就允许：

用 LaTeX 建立两份报告的共同视觉基础

我提出统一使用 LaTeX，让字体、图注、颜色和引用有稳定基础。Experiment 与 Process 分别围绕结果和过程组织内容，在共同视觉体系下保留各自的阅读方式。

我的 LaTeX 与两份报告要求

1. 给我一个完整专业详细可以发给智慧城市与位置项目的对话的提示词，让它确认当前状态，我会把它的结果返回给你，看看是否完全理解我们的要求和任务了，以及skill是否正常读取且生效
2. 然后再给我一个完整专业详细可以直接发给codex的提示词，让它确认当前状态，我会把它的结果返回给你，看看agents.md是否正常读取且生效（我的skill的zip需要放到codex的文件夹中吗？，如果需要的话你先告诉我需要，然后我会放在其中，然后让codex自己把skill放到合理且合适的位置，你的提示词需要包含让codex看看skill是否正确读取且生效，这取决于我们的这些图表到底由谁来制作）
3. 最后一点需要补充一下，我觉得我们的文档全部用latex来撰写比较好，然后我需要好看的高级精致美观的，没有ai味的latex模板，你先给我几组选择，告诉我它们的特点，也可以不固定，根据任务来适当更改，如果可以的话你的选择最好配上例图或者示例pdf，我需要根据真实的情况来选择，我选择后我们再对应修改项目设置，agents.md等设置
我们先完成latex模板的事吧，然后把这些东西改好后一起检查，确认当前状态
现在请你仔细理解我的要求并且整理一下，并且在我的基础上帮我完善并且补充一下任务要求（我目前的要求都是简单的初步想法，你可以提出更好的方案和建议），让它更完整专业，我需要确认你是否已经理解了我的任务，我确认后可以实际操作

收起 ^

共享视觉，分别叙述

两份报告沿用相同的视觉身份；实验方法与研究决策，则分别按各自的内容组织。

保留可修改的生成源

LaTeX 正文、图形与构建方式一起保存。后续修订可以回到这些源文件，继续维护已经确认的表达。

GPT 区分共享系统与报告布局

README 仍然可以使用 Markdown，因为它承担 GitHub 导航与运行说明，不需要强行 LaTeX。

这样更合理：

GitHub README
→ Markdown，项目导航和系统说明

正式报告
→ LaTeX → PDF

代码 / Notebook
→ 原生文件

正式科研图
→ SVG/PDF/高分辨率图片插入 LaTeX

二、我不建议 Experiment Report 和 Process Report 使用完全不同的模板

它们应该让老师一眼看出：←

这是同一个项目的两份正式报告。

因此最好建立一个统一视觉系统，两种版式变体。

共同部分：

从实际页面调整配色与留白

看过实际页面后，我觉得大面积色块和卡片太多。于是我要求减少装饰，让正文保持中性，把颜色留给真正需要强调的判断和对应关系。

我对实际页面的反馈

1.头脑风暴那页中不用那么多颜色的框，我觉得2-3个就可以，根据内容来决定颜色
然后内容方面我不知道是不是这次是示例，两份正式报告 Experiment / Process 像这种明显就不用加，你理解一下我的含义和要求，老师真正需要的是什么，而且我刚刚想了一下头脑风暴是不是不适合放在这个文档中，应该放在另一个文档中对吧
2.一般过程那页也是如此，一页中框的颜色尽量不要超过2种，特别是占据大面积的框，如果你是用荧光色简单把对应的文字涂一下可以允许超过2种，这种占据比较大面积的框如果有大量颜色只有一种使用情景，就是这是重点，我们额外画出来，而不是每个框都需要颜色
3.核心交互那页也是如此，框本身不要颜色其实，把里面的重点文字上色
4.核心交互2/3和3/3那页的排版是什么情况，有明显的大问题
5.你的局部流程图也太简单了，只用简单的箭头和方框连接是不行的，一点都不美观不精致，你好好想想并且告诉我有哪些更高级的流程图表达方式，这个点我们额外提取出来，我们要仔细选择和设计，然后那个框的颜色犯了一样的问题
现在请你仔细理解我的要求并且整理一下，并且在我的基础上帮我完善并且补充一下任务要求（我目前的要求都是简单的初步想法，你可以提出更好的方案和建议），让它更完整专业，我需要确认你是否已经理解了我的任务，我确认后可以实际操作

收起 ^

根据阅读效果作修改

我的反馈来自实际页面：颜色和卡片抢走了注意力。GPT 据此调整了大面积填充色与强调方式。

让重点更容易找到

P2 视觉体系继续保留，正文以中性色为主，颜色集中标明重要判断和对应关系。

GPT 补充克制的视觉规则

以后一般过程汇总页更应该类似：

【真实截图 A】

资料确认

一句话说明

【真实截图 B】

数据理解

一句话说明

【真实截图 C】

指标讨论

一句话说明

【真实截图 D】

参数讨论

一句话说明

基本采用：

白/米白底；

深灰正文；

统一细边；

一种浅色作为阶段标识。

如果其中某一次互动特别关键，可以用第二种颜色做局部强调。

而不是四个大块分别蓝、黄、粉、紫。

6. 一般过程截图本身应该更大

上一版第 2 页还有一个问题：

两张真实截图本身太小，而下面四个彩色说明框反而成了视觉主体。

让流程图呈现我的判断过程

我逐一看过候选图型，淘汰不合适的，要求把候选树改成横向。我还希望图里呈现我发现了什么、怎样理解问题、提出了什么修改，以及证据怎样支持最后的选择。

我的图型反馈与 GPT 回应

我感觉有些问题：

1.文字我觉得最好还是用框框起来，1,5肯定不行

2.2有点乱

3.3不好，我觉得横向比较好

4.4没有明确展示出我（用户）提出的建议和想法，这个证据我觉得应该改为就是我根据什么/发现什么问题，然后提出什么建议

现在请你仔细理解我的要求并且整理一下，并且在我的基础上帮我完善并且补充一下任务要求（我目前的要求都是简单的初步想法，你可以提出更好的方案和建议），让它更完整专业，我需要确认你是否已经理解了我的任务，我确认后可以实际操作

进一步收窄了。上一轮 5 种流程图里，1 和 5 可以直接淘汰，2 只保留“分角”
横向，4 需要把“用户的思考与建议”放到真正的中心位置。

5 种图上小修小补，而是建立一套更适合这门课的 **Process Diagram**

规则

GPT 补充人的推理链

“Evidence”太抽象，看不到用户到底为什么反对、发现了什么、提出了什么建议。

这不符合我们这个项目的核心目的。

以后不能简单写成：

把判断过程画具体

我关心发现、解释和修改之间的关系。GPT 随后将这些环节接到证据与决定前面，让图能顺着真实思路阅读。

让流程图呈现我的判断过程（续）

接前页，继续阅读这组对话。

GPT 补充人的推理链 · 续页

GPT Proposal
→ Evidence
→ Decision

而应该变成：
Human Reasoning–Evidence–Decision Graph
核心链路应该明确展示：

GPT原建议
↓
用户观察 / 发现问题
↓
用户形成判断
↓
用户提出具体建议
↓
需要验证的问题
↓
资料 / 数据 / 实验
↓
最终决定

分别选择合适的图型

一般过程、人的推理与证据、横向候选树分别保留，各自解释不同类型的问题。

后续：我选择保留的图型

相比1我更喜欢2，3有自己的适用场景，保留，2和4可以都不以都做候选，增加多样性

系收得比较清楚了。
理解偏。

让 GPT 对照真实仓库检查成果

我进一步要求 GPT 检查真实远程成果。重要阶段先保存并发布代码、运行记录和报告，再回来对照证据审核；仓库也由此成为持续复现和检查的入口。

我的原始补充：上传后审核

```
2.仍然要求上传到github仓库，然后由你（gpt来审核），这是github仓库：🔗 woobowen/Smart_Cities_and_Location_Services.git，这是我们的codex的目录：addaswsw@LAPTOP-KI0GT6AJ:~/lab/Smart_Cities_and_Location_Services$
```

审核要找到实际产物

我要求代码、输入、输出和图表都能被读取。GPT 据此把远程检查接在 Codex 发布之后。

GPT 整理真实远程检查链

九、GitHub 工作流继续保留

这个从《软件系统优化》迁移。

仓库：

woobowen/Smart_Cities_and_Location_Services

本地 Codex 目录：

~/lab/Smart_Cities_and_Location_Services

我已经进行了只读核验：仓库当前真实存在，默认分支为 `main`，而且连接具有读取与写入权限。

正式流程建议：

```
GPT + 用户完成方案
↓
GPT生成 Codex Goal Prompt
↓
Codex真实实现图
↓
本地运行/实验
↓
Codex自验
↓
必要信息
↓
commit / push GitHub
↓
GPT直接读取 github真实文件
↓
代码审核
结果审核
图表审核
报告审核
```

让 GPT 对照真实仓库检查成果（续）

接前页，继续阅读这组对话。

GPT 整理真实远程检查链 · 续页

```
交互流程审核
↓
FINAL REVIEW
↓
PASS
```

Codex 的文字汇报仍然不算最终完成证明。

完整工程与教师提交包分工

十、我建议继续保留“GitHub完整版”和“老师提交版”分离

这一点和软件系统优化一样有价值。

GitHub

保留完整可复现工程，包括：

代码

Baseline

必要数据说明

实验脚本

结果

正式图表

报告

必要 evidence

具体结构后续根据第一次实验决定。

Teacher Submission Package

严格按老师要求整理。

不能把：

内部审计

GPT Prompt

Codex日志

requirement matrix

debug过程

大量中间文件

一起交给老师。

但老师要求的人机交互证据属于正式报告内容，不属于内部垃圾。

分别组织工程与提交包

仓库保留复现与审核所需的完整工程；教师提交包则按作业要求整理必要文件。

把理解检查安排进协作过程

在旧课程里，我就注意到工程进度与自己的理解可能不同步。迁移后我继续保留这项安排：检查可运行的成果，也请 GPT 帮我讲清原理、方法和结果。

我提出进度不同步，GPT 调整

你的理解是合理的，但是要注意一点，就是我们的工程验收时间和理解验收时间可能不同，意味着可能我们完成了下次的任务后我会让你继续完成上次任务理解验收之类的

记忆已更新

这个补充很重要，我已经理解了。后面不能把每个任务做成“工程做完 → 立刻理解验收 → 才能进入下一任务”的单线程，而应该改成**异步双轨制**。

以后每个任务都维护两套独立状态：

• **工程轨**：未开始 → 执行中 → 待证据 → 工程验收通过/需修复

• **理解轨**：未开始 → 学习中 → 待口试 → 理解验收通过

例如完全允许出现这种状态：

A1

工程：PASS

理解：NOT_STARTED

A2

工程：IN_PROGRESS

理解：NOT_STARTED

用解释检查我的理解

我需要能自己讲清方法和结果。GPT 因此保留讲解与答辩准备这一职责，和工程核查一起推进。

分别跟进各项进度

后来我们把成果、理解和提交分别记录。我可以先检查工程结果，再安排方法复盘和文档审阅。

新项目继续保留独立状态

二十、我建议智慧城市项目采用新的“双轨状态”

《软件系统优化》的：

Engineering Understanding

不太合适。

这里我建议改成：

Deliverable Understanding

例如：

Deliverable:

NOT_STARTED

IN_PROGRESS

LOCAL_COMPLETE

FINAL_REVIEW

PASS

Understanding:

NOT_STARTED

LEARNING

VIVA_PREP

PASS

因为这门课最终课程设计也要求答辩。

所以：

智慧城市与位置服务 / 实验一过程报告 / Part I

19

带着已有规则进入真实实验

进入实验一之前，我已对证据、图形和文档形成基本要求。接下来，我希望在真实任务中检查这套做法怎样处理研究判断、执行反馈和失败，再据此继续修改工作流。

我要求看到真实页面效果

合理，给我看看实际效果！要用真实的标准和效果的页面来给我看！

先看实际产物

我要求看到真实页面，再检查内容和对应关系。GPT 据此安排局部证据与总体说明的制作顺序。

真实可查看的 Process Report 页面原型，不是只画示意框。

局部决策与总体故事的分工

十三、“大演变图”应该理解为局部图的 Overview

你说：

你说的大图在我这里就是把多张流程图合并在一块。

我完全理解。

以后我们可以建立：

Local Diagrams


每个具体决策自己的流程。

然后：

Global Decision Evolution Map

把这些 Local Diagrams 中的核心节点连接起来。

例如：



所以“大图”不是重新发明一套内容，而是：

把局部决策图组织成整个研究故事。

由具体决定归纳整体

先看清每个问题怎样形成决定，再归纳总体演化。实验一随后为这套工作方式带来了新的检验。

从完整读题开始推进实验一

带着前面形成的分工和研究规则，我开始与 GPT 推进实验一。我先交给它老师材料、原始数据和已有工程，要求读清任务，再分别核对 Notebook、Agent、模板和历史输出的实际用途。

我发出的研究初始化提示词节选

```
# TASK 1 RESEARCH CONVERSATION INITIALIZATION PROMPT
# 《智慧城市与位置服务》实验一
# 轨迹数据预处理 + LLM增强轨迹数据质量提升Workflow / Multi-Agent System

你现在进入《智慧城市与位置服务》项目的：

# Task 1 Research Conversation

这是一个真实研究与任务执行对话。

你的第一目标不是为了Process Report制造互动，也不是直接把作业做完，而是：←

> 与用户共同研究、设计、实现、验证并最终完成Task 1，
> 同时形成一套真正用于轨迹数据质量提升的
> Workflow / Multi-Agent System。

你负责：
- 读老师正式材料；
- 研究问题；
- Source Audit；
- 提出候选；
- 和用户讨论重大研究Decision；
- 设计Workflow / Multi-Agent System；
- 为Codex编写详细可执行Prompt；
- Codex push后读取真实GitHub成果审核；
- 根据真实实验和用户反馈继续迭代；
- 最终完成Task 1全部真实成果；
```

先把任务理解完整

我要求共同研究、设计、实现和验证。GPT 先完成材料阅读与任务梳理，为后面的方案讨论准备依据。

从完整读题开始推进实验一（续）

接前页，继续阅读这组对话。

我发出的研究初始化提示词节选 · 续页

- 在过程中自然产生Original Human-AI Evidence Candidate。

你不是最终决策者。

重大研究Decision必须经过用户真实审核。

按用途核对现有材料

真实输入、可复用代码和历史演示分别整理；分段、去噪、简化之外，评价、参数、顺序和 LLM 工作流也进入任务清单。

GPT 的 Stage 0/1 阅读反馈

STAGE 0 / 1 REVIEW

本轮核查后的核心判断是：Task 1 既不是“只填三个预处理函数”，也不是“现成 Agent 跑一次就算完成”。基础预处理、评价设计、参数实验、顺序讨论和 LLM 工作流，需要分别落实；现有工程提供了较完整的复用基础，但其中的教学说明、Notebook、实际调用链和历史结果并不完全一致。

下面区分三类内容：材料明确要求、本轮实际核查到的事实、尚未决定的方法问题。

1. 我实际读取了什么

Project Sources

本轮可访问的顶层附件是 9 个文件。你列出的两个 Notebook 都在 作业.zip 内，已经找到并逐单元读取，因此不存在“缺少两个 Notebook、需要重新上传才能继续”的问题。

同一轮：确认事实而非冻结方法

8. 当前已确认事项

这里的 CONFIRMED 是“事实或任务范围已确认”，不是“方法已批准”。

当前已经确认：所需 11 项逻辑来源均能读取；远程 main 快照和关键 starter 内容已核对；基础 Notebook 的实现空缺和三组参数实验仍在；原始数据能够读取且存在需要处理的时间与位置重复现象；现成 Agent 有较丰富的复用基础，但不能直接作为完整 Task 1 成果。←

同时已经确认：两份 P2 PDF 是模板，旧图表和旧消融不是本轮结果；正式架构、参数、指标、顺序与结论尚未冻结。

GPT 先解释依据，我再判断方案

GPT 列出了坐标、参数、顺序和评价等问题，但这些专业问题需要先讲清楚。我因此要求它解释依据、给出推荐和风险，再由我判断，同时继续沿用 GPT 与 Codex 的分工。

我的补充与 GPT 的直接回应

教师第 8 页工具建议：忽略，不用管不能使用codex，最好使用 deepseek的要求，我们就打算gpt+codex的组合
关于任务本身的理解方面可以再和我确认，然后关于任务内部的事我无法确认，需要你给我你推荐的理解，然后我来审核是否合理
关于工作流和multi-agents:可以考虑在数据处理上使用multi-agents体系
现在请你仔细理解我的要求并且整理一下，并且在我的基础上帮我完善并且补充一下任务要求（我目前的要求都是简单的初步想法，你可以提出更好的方案和建议），让它更完整专业，我需要确认你是否已经理解了我的任务，我确认后可以实际操作

我需要推荐及其理由

面对专业问题，我希望先知道为什么要讨论、已有证据是什么，以及不同选择会怎样影响实验。

解释帮助我作判断

GPT 把问题、影响、证据、推荐与风险一起说明。重要选择集中讨论，已经确定的普通动作继续执行。

思考了 5m 25s

你的核心要求是：由我先把任务解释清楚，形成有依据的推荐方案，再由你审核其合理性；而不是把一串专业问题交给你，让你在尚未理解时替我作决定。

同时，需要把两件事分开：**我们用 GPT + Codex 完成研究与工程开发；我们要开发的轨迹处理系统，可以采用实质性的 Multi-Agent 体系。**前者是协作方式，后者是实验研究对象，不能互相替代。

下面整理为一份**《Task 1 任务定义与协作要求——待审核稿》**。老师和项目已经明确的要求，与我建议补充的设计原则分别说明；本稿不冻结具体算法、参数或 Agent 架构。

一、你这轮已经明确的调整

1. 工具组合确定为 GPT + Codex

本项目采用 **GPT + Codex**，不再把第 8 页的工具建议作为阻碍，也不要求为了该建议改用 DeepSeek。

具体分工保持为：GPT 负责研究、解释、设计和审核；Codex 负责经过批准的工程实现与真实运行；你负责理解、质疑、修改和批准重大决定。

这是你的项目工具选择，不需要再次确认。正式记录中如实说明实际使用的工具，不将其写成“教师已经批准使用”的事实。

同一回答：先研究、解释和推荐

2. 专业问题由 GPT 先提出推荐，不要求你先给答案

上一轮列出的 CRS、参数、处理顺序、评价指标等，是**我需要继续研究的问题**，不应变成要求你现在回答的问卷。

后续我应当先说明：

这个问题是什么 → 为什么影响实验 → 材料和证据支持什么 → 我推荐怎样理解或处理 → 有什么代价和风险 → 哪部分需要你判断。

确有多多个合理方案时，我给出少量实质性候选，并明确当前倾向；不能只罗列 A/B/C 后把判断责任全部交给你。这也符合研究协议关于“GPT 提供候选与依据，用户审核，无法裁决时再设计实验”的规定。

SMART_CITIES_RESEARCH_PROTOCOL

你不需要先成为轨迹处理专家才能参与决策；但我需要把重要依据解释到足以让你判断的程度。

让 Multi-Agent 从一开始参与实验任务

最初 GPT 把任务理解成先完成分段、去噪和简化，再建立 Agent。我马上纠正：Multi-Agent 应当帮助我完成实验，从研究、数据处理到实验和检查都要参与，而不是最后补一层解释。

我纠正任务定位，GPT 重新定义目标

⊕ 网页搜索 有一个很重要的问题，就是multi-agents不是在老师提供的真实轨迹数据和 starter 为基础，完成分段、去噪、简化及其评价、参数实验和顺序分析 基础上，而是为了解决分段、去噪、简化及其评价、参数实验和顺序分析 multi-agents是要协助解决我们的问题和完成任务的，包括数据处理等，而不只是提供想法和方案的
我建议你用multi-agents体系搜索一下有关这个任务的优秀论文（要顶会顶刊的），然后看看有没有什么可以对我们的这次任务有用的想法，策略等，或者是发现有什么注意点重点，都可以
现在请你仔细理解我的要求并且整理一下，并且在我的基础上帮我完善并且补充一下任务要求（我目前的要求都是简单的初步想法，你可以提出更好的方案和建议），让它更完整专业，我需要确认你是否已经理解了我的任务，我确认后可以实际操作

我修改了任务组织方式

我把体系的职责扩展到任务拆解、资料研究、真实处理和结果检验，要求这些工作就在协作过程中完成。

思考了 13m 41s

这次需要修正的是任务的整体结构：Multi-Agent 是用来完成实验一的执行体系，而不是实验一做完以后，再附加的一层 AI 建议或解释。

上一轮“先完成分段、去噪、简化及实验，再在此基础上建立 Agent 系统”的表述，应当撤回。你要的是：

围绕实验一的问题构建并实际使用 Multi-Agent 体系，让它参与任务分解、资料研究、数据诊断、真实处理、实验执行、结果核验和调整，最终协助我们把任务完成。

老师提供的数据和 starter 仍然是输入材料与可复用资源，但“先把预处理任务独立做完”不再是引入 Multi-Agent 的前置条件。

本轮我已完成第一轮文献检索，核对了相关论文的发表信息，并读取了与本任务有关的方法和评价内容。需要说明：**实际执行的是分方向网页检索与原文交叉核查，没有启动多个独立研究 Agent，也没有运行轨迹实

让 Multi-Agent 从一开始参与实验任务（续）

接前页，继续阅读这组对话。

我纠正任务定位，GPT 重新定义目标 · 续页

验。****下面把文献支持的内容、对我们任务的启发，以及我建议修订的要求分开说明。**

一、现在应当怎样定义我们的任务

我建议将 Task 1 的目标改为：

设计、实现并实际使用一套面向轨迹数据质量提升的执行型 Multi-Agent 工作流，在人类批准的研究目标、方法范围和质量约束内，协同完成数据理解、轨迹分段、去噪、简化、效果评价、参数实验与顺序分析，并通过真实工具执行、结果反馈和必要的人工审核，形成可复现的处理结果、实验结论与课程交付物。

这里三个重要变化。

同一回答：必须真正采取行动

2. Agent 必须能够采取行动，而不只是交出方案

“建议使用某个阈值”只完成了提议，不等于完成处理。

我们要的系统应该能够在批准范围内：

发起处理或实验任务，调用工具，读取真实输出，检查失败，调整后再次执行，并保存可检查的结果。

至于底层距离计算、Douglas-Peucker、指标计算由 Python 实现，并不妨碍 Agent 实际完成任务。关键是这些计算是否进入了 Agent 的行动—反馈闭环，而不是由系统外的人独立完成后，再让 Agent 写一段总结。DS-Agent 的真实代码执行与反馈机制，以及 DeepPrep 对中间数据状态的实际操作，都提供了这种组织方式的参考。  [a2XN · 1](#)

3. GPT + Codex 的开发协作，不替代运行时的 Multi-Agent

GPT 负责研究、解释、提出推荐和审核；Codex 按批准方案实现、测试并启动工程；你负责重大判断。这是我们的开发协作关系。

而实验中的 Multi-Agent，需要在真实运行时承担任务。**Codex 不能先把全部处理和实验独立完成，然后仅给这些结果补一段“Agent 协作过程”。**

必要的工具实现、单元测试和基线检查当然可以先行；它们是在建设执行能力，不是在系统外提前完成全部研

开发与运行的分工

GPT 与 Codex 负责研究和工程开发；实验中的 Agent 则需要发起任务、读取真实结果，并据此决定下一步。

我的回看

这轮讨论把设计重点转向了职责、行动与核验，也为后续原型明确了需要检查的内容。

把结果反馈接回下一轮研究

我又补充：体系在第一次形成结果后，还要能够继续检查和改进。理解任务、实际完成、审查结果、找出下一步问题，再继续验证，都应属于同一个 workflow。

我的持续改进要求与 GPT 修订

🔍 网页搜索 你的理解还是错的，multi-agents不仅要协助我们把任务做出来，也要帮助我们不断迭代和循环优化，你可以理解为我们的工作流和multi-agents是协助我们从开始任务，到完成任务，到优化任务，这个循环，然后重复这个循环，然后你要有审核的标准，来确认我们确实在优化这样，这里面的任何一条都是我们的工作流和multi-agents的任务
其中优化任务并且循环这一步是最需要我们先想好如何构建工作流和对应的multi-agents体系的！从而才能确保让这个体系循环进行优化
现在请你仔细理解我的要求并且整理一下，并且在我的基础上帮我完善并且补充一下任务要求（我目前的要求都是简单的初步想法，你可以提出更好的方案和建议），让它更完整专业，我需要确认你是否已经理解了我的任务，我确认后可以实际操作

让改进贯穿任务

我希望从开始到完成再到改进都在同一体系里。GPT 因此把结果检查和下一步选择接回主循环。

思考了 7m 46s

上一轮的偏差在于：我仍把 Multi-Agent 主要理解成“把任务执行完的系统”，把优化理解成执行中的重试或后续附加工作。你要求的是：整个任务从启动、研究、执行、完成，到审核、发现改进空间、落实优化、验证优化，再进入下一轮，都由同一套工作流和 Multi-Agent 体系协助推进。

因此，“做出一版合格结果”只是一个阶段节点，不是系统职责的终点；“判断有没有变好、决定下一步改什么”本身也是系统任务。

下面将这一要求整理为“《Task 1 全生命周期循环优化工作流——需求修订稿》”，本轮已按你的要求补充检索和核对相关研究；这里只整理需求、提出推荐原则，不开始实现或运行实验。

一、任务的核心定义应当这样修改

构建并实际使用一套由人类监督、以真实执行和证据审核驱动的 Multi-Agent 协作工作流，覆盖实验一从任务理解、资料研究、数据分析、方法设计、工程实现、实验与评价，到结果审核、问题诊断、改进实施、复验、经验积累和成果交付的全过程。

系统不仅协助完成当前任务，还要在阶段完成后主动检查改进空间，形成有依据的优化假设，实施并比较候选方案，依据预先认可的标准判断是否真正改善，保留有效改进或拒绝无效改动，再进入下一轮。循环可以改进处理结果、实验方法、工程可靠性、成果表达，也可以改进工作流与 Agent 协作机制本身；但不能自行改变任务目标、降低审核标准，或把未经验证的改动宣布为优化。

把结果反馈接回下一轮研究（续）

接前页，继续阅读这组对话。

我的持续改进要求与 GPT 修订 · 续页

这不是三个独立项目——“先做实验，再做 Agent，最后做优化”。它是一个贯穿全程、能够反复执行并接受审核的研究与工程体系。

教师要求的轨迹分段、去噪、简化、预处理评价和 LLM 工作流，仍是这个体系需要完成的具体任务；程序、评估报告和包含 AI 批判的过程报告，仍是应当交出的成果。

二、完整循环中，哪些事情都属于我们的工作流

同一回答：把反馈接回下一轮

我建议用下面这条主线表达，而不是只在三个处理函数之间画箭头：

理解当前任务与状态 → 研究和制定计划 → 实际执行 → 审核当前成果 → 发现问题或改进机会 → 提出并实施改进 → 对照复验 → 接受、拒绝或继续验证 → 更新当前版本与经验 → 下一轮。

其中，“当前状态”既可以是刚开始时的空白，也可以是已经完成一版实验、已经有合格报告，或者已经运行过几轮优化。

工作内容	工作流与 Multi-Agent 应当承担什么	进入下一轮时应带走什么
理解任务、检索资料	核对要求，研究方法，发现假设和资料冲突，提出推荐解释	已确认要求，来源依据，仍待解决的问题
分析数据、设计方案	实际检查数据，形成诊断，提出算法、参数，评价与实验候选	数据事实、可检验假设、批准的执行范围
实现和执行	实现或调用工具，处理数据，运行实验，处理工程故障	真实代码，处理结果，运行记录和失败信息
审核成果	检查是否完成、是否正确、证据是否充分，结论是否成立	明确的审核结论，而不只是“看起来不错”
发现并落实优化	即使当前版本合格，也检查薄弱环节；提出有理由的改动并实施	相对于当前版本的改动、预期收益和风险
验证优化、选择版本	在可比条件下复验，判断收益与退化，接受、拒绝或要求补充证据	经审核的保留版本，失败候选及其原因

由具体问题引出下一轮

当前结果、失败原因和待验证假设成为下一轮输入。体系需要说明准备改什么，以及怎样检验。

从轨迹任务反推研究问题

当讨论越来越像在搭通用 Multi-Agent 平台时，我把方向拉回实验一：先列出实际需要完成的工作，再围绕这些任务确定该检索和验证什么。

我要求先明确实验的实际任务

理解是完全正确的，但是这套工作流和multi-agents不能脱离我们这次的任务来做，反而是完全依赖于这个实验一的，甚至是针对于实验一来构建。我需要你搜索的顶刊顶会的优秀论文是关于实验一的有关部分的，你先把实验一的基础任务列举出来（实际任务，而非llm， workflow构建的那些任务），然后告诉我你要搜索哪些方向的，哪些板块，哪些点的？（先不用实际搜索）
我举个例子，比如我们该如何更好的处理我们的数据，如何量化我们的优化之类的等等等等（我这个只是举例子，你要搜索的完全方向，板块，点就是要这样的）

先问实验需要什么

我关心怎样处理和优化轨迹数据，因此要求 GPT 先说明实际任务及其困难，再寻找相关方法。

思考了 8m 43s

****研究主线应当是“怎样把实验一的轨迹数据处理得更好，并可靠地证明改进”，而不是“怎样构建一个通用 Multi-Agent 平台”。****工作流和 Multi-Agent 的职责、工具、反馈信息及循环条件，都应从这些具体技术问题中推导出来。

下面先列出不含 LLM 和工作流建设的实际任务，再给出对应的文献检索方向、板块和具体问题。这是一份检索计划，不是已经选定的算法或指标。

一、实验一的基础实际任务

这里将“老师明确布置的任务”与“正确完成任务所需的前提工作”分开。老师的选做和思考讨论，继续按照项目规则纳入必须完成的 T2。 SMART_CITIES_RESEARCH_PROTOCOL

实际任务	具体要做什么	最终需要回答什么
1. 理解原始数据并建立正确的计算口径	核查字段、轨迹记录含义、坐标与时间语义；统计采样间隔、重复、缺失、跳变等现象；明确距离、速度和方向怎样计算。这是处理任务的必要前提，不是新增一门独立实验。	我们拿到的是什么数据？哪些现象有问题？哪些计算和处理有可靠依据？
2. 轨迹分段	定位相邻点之间异常的时间间隔或位移，切分为子轨迹；按教学要求处理距离过短或点数过少的子轨迹。	应该在哪里断开？有没有过度切分或错误连接？短片段过滤丢掉了什么？

从轨迹任务反推研究问题（续）

接前页，继续阅读这组对话。

我要求先明确实验的实际任务 · 续页

3. 轨迹去噪	实现老师讲解的漂移点识别与处理，核查其适用条件和边界情况；如需改进，再研究有依据的候选。	哪些点确实不可信？怎样减少异常，同时避免误删正常运动？
4. 轨迹简化	完成 Douglas-Peucker 简化，按距离阈值保留形态关键点，并检查简化后的信息损失。	能减少多少点？保留了什么、损失了什么？误差是否满足要求？
5. 设计并计算预处理评价指标	分别评价分段、去噪、简化及整体效果，说明指标的设计逻辑、计算方式和结果含义。	什么叫“处理得好”？指标能支持哪些结论，不能支持哪些结论？
6. 完成三组参数实验	分别研究分段、去噪、简化参数对结果的影响，形成参数依归与敏感性分析。	参数为什么这样选？结果是否稳定？是否存在明显权衡？
7. 分析三个步骤能否调换顺序	解释步骤间的相互影响；对不能仅先定义和依据裁决的问题，设计必要的顺序比较。	顺序改变了什么？哪些顺序适用于哪些条件？
8. 构造反例并验证技术假设	检查单位、坐标、插值、异常判定等假设，构造明确标注的反例，记录修改前后的结果。	方法会在哪里失效？修改是否真正解决了问题，又是否引入新问题？
9. 整理可复现结果与技术表达	形成处理代码、Notebook、真实结果、必要图表和实验报告，解释方法、参数、结果及局限。	别人能否复现？图表与结论是否对应真实处理结果？

把检索按问题组织

分段、去噪、简化之外，数据前提、评价、顺序和结果解释也各有问题。GPT 据此组织了任务导向的检索模块。

GPT 把检索拆成任务导向的模块

上表中，分段的教学内容明确包括“异常间隔定位—切分—短片段过滤”；去噪讲解的是前后方向关系；简化讲解的是 Douglas-Peucker 点到端点所连线段的距离判据。它们是本次方法研究的起点，不能被外部论文静默替换。

评价指标设计来自作业细则，三个参数实验来自基础 Notebook，顺序问题来自 PPT 第 42 页。反例与技术假设核查，则来自教师对准确性和隐含假设的要求。

因此，我们需要研究的不是只有三个算法，而是：数据前提、处理方法、评价依据、参数与顺序、改进验证这一整组相互关联的问题。

二、文献检索的总体结构

从广泛检索收敛到少量可用思路

看过新旧轨迹研究后，我补充了一条取舍原则：论文应帮助我们解决具体任务，真正进入实验的是少量可解释、可检验的改动。我在执行前收窄使用范围，并据此回看此前汇总的研究材料。

执行前的补充：收窄论文使用范围

4.不要尝试过多论文里的东西，最后我们大概只能用到2-4篇，太多的混杂在一块不会让效果提升，我们不是在复现论文，我们只是尝试论文里的东西是否能对我们的任务产生帮助，就算最后一篇都用不上，或者只是利用了思想没有利用里面的具体方法，也是能接受的

以适用性筛选来源

我在执行前强调少量有用的思路。论文是否值得采用，要看它与当前问题的关系、实现成本和可验证性。

回看此前的文献汇总：可迁移思路与适用条件

NIST: 多水平因子实验

讨论多水平设计、由串与交互，以及完整设计时间阈值、距离阈值、短片段过滤等联合的增长成本。 [NIST](#)

设计时间阈值、距离阈值、短片段过滤等联合实验；不强制大型全因子扫描。

这四项是实现与实验设计的权威补充，不是计入“最新论文数量”的材料。

四、新旧文献合并后，对实验一的推荐发生了哪些实质更新？

1. 数据处理：从“少改、守规则”完善为“多证据支持的最小必要干预”

旧研究保留了约束和修改代价的价值；新 SHoTClean、TAV、PED 让我们进一步考虑：

硬规则与软规则不同；时间与位置可以同时不确定；改动少并不保证清洗好。

因此，我建议首版研究重点不是立刻采用某个复杂修复器，而是把诊断证据、处置决定、修改记录和独立核验连接起来。实际采用哪些约束或修复方式，仍是待审核的方法选择。

2. 简化评价：从“容差与点数”完善为明确保真条件下的权衡

PILOT-C、DimWeaver 和 MLSimp 补充了不同层面的目标：

重建后检查、误差预算、存储成本，以及关键点任务贡献。

我建议优先形成“等误差比较点数”和“等点数比较误差”两类图，再决定是否需要时间保真或字节压缩。不能把三个不同目标混成一个没有清楚含义的综合分。

3. 反例与验证：从容易识别的单点异常，扩展到有机制的困难场景

SAVAGE 与清洗论文的实验设置提示，可以研究连续错误、部分维度错误和时间—位置耦合错误。

这里不是无条件增加大量实验，而是让教师要求的反例覆盖真正可能导致方法失败的机制。它们应帮助找出一轮该改什么，并明确哪些是开发测试、哪些是最终确认。

4. 循环优化：下一轮要能解释“为什么改这里”

PipeLens 使这一要求更具体：保存每步变化，围绕一个主要假设实施干预，再真实复验。

例如，保留点数下降时，应先区分切分、短片段过滤和去噪的贡献；不能立刻让 Agent 随机提高某个阈值。代理预测或 LLM 推理可以决定优先测试什么，不能代替最终执行结果。

5. 可视化：显示优化与数据优化分开

ILTS 带来的重点不是“再多做一种图”，而是防止为了画得清楚而改变分析输入。图形处理必须保留关键异常，并允许回到完整局部数据。

以上均是基于文献形成的迁移建议，还没有在我们数据上验证，也不自动成为实现授权。项目协议要求外部资

把每项来源的用途说清

后续分别记录实际采用、借鉴思想、风险提示和未采用，让查阅材料与实验中的具体做法对应起来。

用三个 Goal 组织连续推进

我确认三段安排：先建立可信基础和最小执行循环，再逐项验证候选，最后检查组合并收敛交付。我同时要求共同评价、针对性审核和先单项后组合，用实际证据决定取舍。

我对阶段安排的完整确认与补充

我认为整体的总方案是合理的，我来确认一下我的理解是不是正确的：第一份提示词负责确认完整任务，构建审核机制等然后完成最小闭环，第二份提示词负责把候选方案一个个拿出来尝试，好的保留差的抛弃，（每个候选方案都需要一样的评选标准和不一样的审核机制），第三份提示词负责利用我们保留的方案，在此基础上完成我们的循环优化，比如把方案1,2融合，尝试好不好，不好就再尝试方案1,3融合这样？直到最后不断循环优化后，融合成一个总方案和策略，完成了总任务

其中有几个点需要注意：

- 1.老师本身的实验1基础任务和附加任务是重中之重，我们需要以完美完成这个任务为基础，再去完成我要求的任务，其中附加任务我们现在已经就是在进行中
- 2.所有的审核机制和每一步结果都要有依据，都要被证实结果优秀才能进行下一步，所有的方案的好坏都要以结果为准，而不是凭空想方案的好坏
- 3.方案/策略之间的融合要多尝试，结果好的就继续，不好的就回退，要先把基础的方案和策略验证过，再去融合他们，而不要上来就去尝试复合方案和策略
- 4.不要尝试过多论文里的东西，最后我们大概只能用到2-4篇，太多的混杂在一块不会让效果提升，我们不是在复现论文，我们只是尝试论文里的东西是否能对我们的任务产生帮助，就算最后一篇都用不上，或者只是利用了思想没有利用里面的具体方法，也是能接受的

现在请你仔细理解我的要求并且整理一下，并且在我的基础上帮我完善并且补充一下任务要求（我目前的要求都是简单的初步想法，你可以提出更好的方案和建议），让它更完整专业，我需要确认你是否已经理解了我的任务，我确认后才可以进行实际操作

收起 ^

我确认的是推进方式

老师的基础与附加任务始终为中心。每个阶段接着已有结果推进，并继续负责尚未解决的问题。

GPT 对应修订第一阶段

可以复现、正式表达清楚，**不会用一个无法证实的“完美”标签代替这些检查。

二、三份 Codex Goal，按你的理解正式调整

Goal 1：确认完整任务，建立可信基线、审核机制和最小闭环

你的理解基本正确，但这一阶段不能只有清单、接口和架构。

它需要实际得到：

一套明确的任务与评价合同，一版正确实现的教师基础方法，以及能够真实执行、评价、拒绝和继续推进的

用三个 Goal 组织连续推进（续）

接前页，继续阅读这组对话。

GPT 对应修订第一阶段 · 续页

小 workflow。

具体包含：

- 核实材料、数据、已有代码和运行环境；无法确认的时空语义明确保留，不能靠默认值补齐。
- 建立处理工具、评价器和必要的独立测试，先证明“我们的尺子能测对”。
- 完成基础处理链，并得到小规模真实结果。
- 接入最小实质性 Multi-Agent 协作，验证真实调用、结果交接、审核与回退。
- 明确后续候选使用的共同评选标准、专项检查、数据划分与预算。

通过条件不是“有一个能跑的 demo”，而是“这套基础实现和审核机制足够可信，可以支撑后续方法比较”。

同一回答：单项验证、组合与收敛

这个阶段不要求已经找到最优参数，也不要求已有论文改进成功。否则会把本应由 Goal 2 回答的问题提前混进来。

Goal 2：完成规定实验，逐项验证少量基础候选

这一阶段的核心是：

先知道每项改动单独做了什么、在哪些情况下有效、会带来什么代价，再考虑与其他改动组合。

三组参数实验、必要顺序比较、真实 LLM / 搜索 / 记忆验证继续属于这一阶段的重要任务。论文候选只是其中有限的一部分，不能把 Goal 2 变成“把文献列表全部跑一遍”。

对于额外改进，采用共同基线下的单项比较。例如：

$$B_0, \quad B_0 + A, \quad B_0 + B, \quad B_0 + C$$

其中 B_0 是经过正确性审核、包含完整必要处理步骤的基线； A 、 B 、 C 是分别定义清楚的改动。

**这里的“单项”，指一次只引入一个主要研究变化，不是把分段、去噪、简化拆成互不关联的三个残缺程序。

**老师要求的基础处理链、合法性检查和评价工具，始终保留。

Goal 2 最终交出的是：

规定实验的真实结果 + 少量候选的独立效果说明 + 保留、条件保留和淘汰决定。

Goal 3：组合优化、循环收敛，然后完成最终确认和交付

你举的“先试方案 1 + 2，不好再试方案 1 + 3”可以成为这一阶段的实际行为，但需要有组合依据和完整对照，不是随机拼接。

这一 Goal 分为连续的两个部分：

前半部分：在开发与选择范围内进行组合优化，对经过验证的候选检查兼容性，实施必要组合，比较收益

先验证独立改动

先在可信基线上分别验证少量候选，再考虑组合。这样可以看清每项改动带来的作用和代价，后续组合也有可比较的父方案。

用三个 Goal 组织连续推进（续）

接前页，继续阅读这组对话。

同一回答：单项验证、组合与收敛 · 续页

与退化；好的保留，不好的回退，根据失败原因继续尝试。

**后半部分：停止修改方法，冻结后做独立确认、全量产出与正式交付。 **最终确认数据不参与前半部分的日常组合选择。

同一轮：共同评价与专项审核

三、“相同评选标准，不同审核机制”应怎样理解

你的这句话方向正确。我建议准确表述为：

同一研究问题下，所有候选共享相同的效果评判尺度；不同方法根据各自的假设、承诺和风险，接受相应的专项核验。

不是每个方案自己决定什么叫好，也不是所有方案都必须执行完全一样的内部测试。

3.1 共同评选标准不能随候选变化

同一组比较应固定数据范围、参考对象、指标定义、统计口径、必要保护项和合理实验预算。除了正在研究的因素，其他关键条件保持可比。项目协议明确禁止偏向性调参、事后改变条件和选择性报告。

例如，两种去噪方案不能分别这样评价：

- 方案 A 用“删掉多少点”证明优秀；
- 方案 B 用“保留多少点”证明优秀。

它们需要接受同一套与任务有关的评价：有参考时检查异常残留与正常点误删，没有完整参考时就如实使用相应的约束、保真和案例证据，并说明结论边界。

分段与简化不是同一个子问题，不需要强行使用同一个数值主指标；但最终接入完整流程以后，都必须接受共同的端到端保护检查。

3.2 专项审核检查方法是否兑现自己的承诺

候选改动	专项核验重点	仍然必须接受的共同检查
改变分段条件	切分边界、短片段过滤、时间与距离规则是否按定义执行	有效信息保留、结果覆盖、下游影响
增加去噪判断或保护规则	是否正确识别适用情况，正常转弯和异常片段怎样处理	异常残留、误伤风险、修改代价
增加简化保真条件	几何或时间误差是否真的满足其声明	精简程度、整体信息保留、可复现性
组合两个策略	接口是否兼容、特征是否重算、组合是否产生新失效	同一组质量指标与保护项

专项检查可以更有针对性，但不能降低共同门槛。新发现一个普遍适用的检查缺口时，应补入公共审核并重评受影响候选，不能只给某个不喜欢的方案增加难题。

共同评价配合专项核验


候选共享效果与保护条件；分段、方向处理和 DP 则分别检查自己的定义与承诺。

我的回看

有效的比较会留下采用、保留或淘汰的依据。后续任务接着这些结果推进，负结果也保留下来。

共同评价与专项核验怎样配合

各方法分别检查自己的实现，同时在相同原始参考和保护条件下比较结果。



分段、方向规则和简化各有专项检查。进入效果比较后，覆盖、几何偏差和保留情况回到同一原始参考，形成可比较的采用依据。

第一次核验发现：包装层改变了检查对象

我把提示词交给 Codex，再把回复和仓库交给 GPT 检查。第一次审核追到了工具包装层：错误输入可能在核验前就被改掉，结果错误列表也被放行。

我批准执行并要求真实远程检查

这次的理解非常准确，请完全按照我们这次确认的计划和要求，给我完整详细专业的可以直接发给codex的提示词，提示词中别忘了包含验收的部分，我会把codex的完整回复给你，同时让codex把内容上传到仓库中去，你通过仓库的实际内容进行二重验收

保留进展，继续追查问题

材料保护、诊断和几何工具已有进展。GPT 在此基础上继续检查审核器，把新发现的漏洞交回修复。

思考了 12m 23s

下面是 Goal 1 的完整执行提示词，可以直接发给 Codex。本轮结束后，Codex 必须提交完整自检结果、实际推送仓库，并停止等待二重验收；不得自行进入 Goal 2 的单项候选筛选或 Goal 3 的组合优化。仓库中的工程规则也明确要求：推送后核对本地与远程 SHA，Codex 自报通过不能替代 GPT 对真实远程成果的审

工程返回后的首次审核结论

二重验收结论

Goal 1 本次不通过，继续在原 Goal 1 内修复和补充，不进入 Goal 2。

Codex 报告的 PARTIAL_BLOCKED 总体判断是准确的：它没有把诊断、构造测试或离线复算冒充真实清洗，也没有补造缺失的 Agent 输出。不过，实际检查源码后，我发现了原验收表没有覆盖的审核误放行和异常处理问题，因此不能原样保留所有 PASS。

下一轮的重点不是推倒重建，而是：

修复审核与异常处理 → 补齐条件满足后可实际运行的处理入口 → 修复并验证模型调用边界 → 完成真实反馈闭环；研究前提获批后，再完成同一批 pilot 的完整基线。

第一次核验发现：包装层改变了检查对象（续）

接前页，继续阅读这组对话。

同一轮：包装层让错误列表通过

三、本次发现的具体问题

问题 1：审核接口会把错误记录先丢掉，再宣布审核通过

这是本次最重要的新发现。

tools.py 在调用独立审核前，先执行了类似下面的处理：

</> Python

↻

📄

▶ 运行

```
by_id = {
    p["record_id"]: p
    for p in previous_profiles
    if p["record_id"] in subset
}
```

****重复 ID 被字典覆盖，多余 ID 被过滤，然后才检查覆盖情况。****因此，独立审核器本来能够识别的输入错误，被外层工具提前消除了。

我实际测试了“应有一条记录，却提交两行相同 ID”和“额外加入一个 foreign ID”：

调用方式	实际结果
直接调用独立审核器	REJECTED，报告覆盖错误
经过 verify_profiles	VERIFIED
经过 recompute_check	VERIFIED，甚至 exact_match=true

修复应当是：****先检查原始列表的唯一性、完整性和作用域，再允许重排。****不能通过“清理审核输入”把错误变成通过。

这不是指控已发布的七条结果存在重复，而是说明审核接口仍可能错误放行，**G1-A08 必须重开**。


先检查原始提交

重复 ID 被覆盖、额外 ID 被过滤后，错误输入会看起来完整。修复需要把唯一性和范围检查放在这些处理之前。

把独立参考接到真正需要核验的产物上

列表问题修好后，我继续转交结果。GPT 的新检查发现两个缺口：请求检查的产物没有真正进入核验；baseline 又把候选自己的输入、参数和账本当成独立参考。

我转交的 Codex 阶段回复



我把 Codex 的阶段回执和仓库交给 GPT。新的核验继续追到产物范围及参考来源，找出了此前未覆盖的问题。

GPT 发现核验范围与请求不一致

三、还必须补齐的两个审核问题

问题一：有了正确引用，不代表工具检查了对应产物

C05 的真实请求是检查时间边界、等值不切、分区索引和原值保留；但它选择的 `recompute_check` 只接收并检查 `previous_profiles`。C03 对重复详情的请求也存在类似的范围超出。

Codex 已经主动说明这一点，并保存了后补的离线检查，所以不能把它说成隐瞒或伪造。但系统仍然需要解决这个实际问题：

以后 Agent 请求“审核时间分区”，控制器不能因为另一个只审核 profiles 的工具返回 `VERIFIED`，就关闭

把独立参考接到真正需要核验的产物上（续）

接前页，继续阅读这组对话。

GPT 发现核验范围与请求不一致 · 续页

这项审核任务。

当前结束逻辑仍主要根据阶段完成情况产生整体状态，缺少对“最后一个新产物是否被相应审核覆盖”的明确约束。

最小修复不是增加更多 Agent，而是让核验回执明确包含：

目标产物 ID / 哈希、可信参考、实际检查内容、未检查内容及原因。

然后把已经实现的时间分区、重复详情独立检查接入运行时。某项输出没有被检查，就保持待核验，不由模型

同一轮：候选自证被反例揭穿

参考要来自候选之外

时间分区需要对应的检查入口；baseline 需要独立绑定原始输入。平移 clean 和 final 仍过关的反例暴露了自证问题。

问题二：新增 baseline 独立审核仍然在使用候选自己提供的“原始输入”

这是我本轮新发现并实际复现的问题。

`review_baseline(output)` 从 `output` 内部的 `segment.input` 建立审核输入；随后又根据这些输入值重建分组账本，而不是逐项核对实际 `clean`、`final` 与独立原始数据的关系。审核参数也来自待审结果自身。

我使用四点构造轨迹测试，得到：

构造情况	正确的独立审核应当怎样	当前实际结果
正常结果	通过	VERIFIED
只改变最终输出一个坐标	拒绝	REJECTED
同时平移去噪后与最终坐标，原输入和账本不变	拒绝	VERIFIED
删除所有结果记录和账本，汇总仍声称输入四点	拒绝	VERIFIED
又把汇总输入 / 保留数量改为 999	拒绝	VERIFIED

通过 `verify_baseline` 工具提交一个与当前原始记录集合不同的候选，也没有被该审核拒绝。工具虽然读取了原始 JSON，但没有将这份独立参考交给 `review_baseline`。

“这不表示已发布的真实 pilot 被改过坐标。”完整真实 baseline 尚未运行；生产 runner 自带的原始点检查也能够发现部分错误。这里的问题是：独立重审产物时，第二道审核仍可能接受错误结果。

把修复和任务恢复留在当前 Goal

几轮交接后，我发现每个普通工程错误都要由我转发下一条修复提示词。我因此要求把修复、回归、重建和恢复原任务都纳入当前 Goal，让体系接着处理这些已经定位的问题。

我指出反复外部转发的問題

我已经把这次的提示词发给了codex，但是我发现一个问题，如果我们每次codex的回复发现都没有完成我们的任务，然后要一步一步修复的话，会花很多很多时间，我认为我们的提示词里应该之后要包含修复的事情，以及我们的 workflow 和 multi-agents 体系也应该包含修复的事情。在完成 goal 任务之前就不应该停下来返回，除非遇到无法解决的阻碍，不然我们的 workflow 就是不完整的。不能拆分的。 ←

现在请你仔细理解我的要求并且整理一下，并且在我的基础上帮我完善并且补充一下任务要求（我目前的要求都是简单的初步想法，你可以提出更好的方案和建议），让它更完整专业，我需要确认你是否已经理解了我的任务，我确认后才可以进行实际操作

减少反复外部交接

我希望能够自行定位的普通工程问题由当前执行过程继续解决，把我的参与集中在真正需要判断的研究问题上。

思考了 4m 2s

你的要求是：修复必须成为每个 Goal 的内部执行责任，也必须成为 workflow 和 Multi-Agent 体系的正常路径。只要问题仍能在批准范围内解决，系统就应继续诊断、修复、验证和推进，而不是把“发现问题”或“完成这一小段修复”当成任务结束。

这需要调整的不仅是提示词措辞，还包括任务结束条件、修复权限、角色交握和内部验收方式。

我前几轮的提示词虽然包含自检、修复和回归测试，但仍偏向“完成这次列出的任务项，然后返回”。这容易让工程停在局部清单完成，而不是持续检查整个 Goal 是否已经具备交付条件。这一点需要修正。

同时，要区分：此前某些停止是必要的研究阻碍，例如缺少文件对应的坐标事实；另一些原本应更多地在内部发现并解决的工程缺陷。不能把两者都笼统称为“未完成”，再反复交给你转发。

下面是我提议的修订方案，供你确认：本轮不修改文件，也不向正在执行的 Codex 追加指令。

GPT 改为对 Goal 完成负责

一、将执行方式改为“对 Goal 完成负责”，而不是“对动作清单负责”

以后每个 Goal 的主要请求应当是：

在已批准的方法、范围、权限和资源内，持续执行当前 Goal。发现可修复问题时，自主完成定位、修复、专项验证、必要回归和重塑产物重量。只有达到该 Goal 的工程交付条件，或出现必须由外部解决的实质阻碍，才提交阶段总结回置。

这意味着，下面这些情况都不是单独的结果理由：

“代码已经写完了”；“这次列出的两个问题已经修好了”；“所有测试都通过了”；“五个角色调用执行完了”；“已经 push 了”；“还有几个问题，下一轮再修”。

必须能续问：

当前 Goal 还缺什么？缺口是工程问题、研究问题，还是证据不够？有哪些可以继续执行的动作？

把修复和任务恢复留在当前 Goal（续）

接前页，继续阅读这组对话。

GPT 改为对 Goal 完成负责 · 续页

现有 `WORKS.md` 已经要求新测试验证、Debug、自校验和后续修复，但没有充分明确“可自行解决的失败应在本 Goal 内持续优化”这一结束条件。我们要补的是这层责任，而不是另建一套与本协议平行的流程。

AGENTS

“三个大 Goal 的划分保持不变。”Goal 1 内的持续修复，不授权它提前进行 Goal 2 的候选比较，更不能授权进行 Goal 3 的组合优化。

后续明确 B-Repair 与恢复原任务

B-Repair: 工程修复模式

当实现与批准定义不一致、接口错误、记录遗漏、工具异常或审核覆盖不足时，进入具有受限写权限的 Codex 工程上下文。

它需要实际完成：

复现 → 定位原因 → 修改实现 → 补测试 → 回归 → 重建受影响产物 → 交回 C 复核。

B-Repair 不是新增一个常驻研究 Agent，而是 B 的工程权限模式。运行模式不能随意改代码；修复模式也不能擅自改变研究目标或放宽指标。

修复交接必须真正执行

这是新要求在架构中最重要的落点：

运行时产生修复请求后，同一个 Goal 的执行上下文必须接管并落实修复。只写出 `repair_needed` 文件，然后结束任务等待用户，不算闭环。

修复时，受影响运行暂停；新代码通过验证后形成新版本，再重跑受影响部分。不能在一项实验中途悄悄换实现，然后仍当作同一次有效实验。

“为什么需要这个 Agent？”它不只是运行一个固定命令，还要判断执行依赖、定位工程原因、选择合理修复并组织复验。但它只能修复已批准定义的实现，不能以 Debug 名义创造新方法。现有工程协议也保留了这条研究权限边界。

AGENTS

2.4 Agent C: 质量核查与反例

它回答的核心问题是：

实际结果支持了什么？有没有遗漏、错误、退化或尚未验证的部分？

“输入与状态。”读取独立绑定的原始数据、批准的方法与指标合同、实际待审产物、执行记录和历史回归案例。不能只读取 B 写好的总结，也不能使用候选自行声明的“原始输入”作为唯一参考。

“可用工具与行动。”调用独立数值核验、账本检查、反例测试、结果对照和必要的图表检查。它可以要求补充验证，也可以指出某项工具没有覆盖本次审核请求。

“输出与交接。”输出明确的核验范围、结果和问题记录：检查了哪个产物版本、哪些内容通过、哪些未检查、失败位置、影响范围和关闭条件。

修复后接着完成原任务


GPT 把 B-Repair 明确为执行角色的修复模式：实际修正、重跑受影响结果，经 C 复验，再恢复父任务。

我的回看

早期由我多次转发修复提示词，后来才逐步形成内部接管。这次反馈改变了任务的停止条件。

研究优化与工程修复分别怎样继续

早期由我转发修复提示词；在我的反馈后，普通工程问题逐步改为在当前 Goal 内修复和恢复。



左侧修正偏离既定定义的实现，经过回归和复验恢复任务；右侧检验有效候选的作用，按比较结果决定保留、回退、补证或停止。

用正反例和真实试运行检验修复结果

我前面已要求在当前 Goal 内继续修复。随后交付的结果让这项要求可以被实际检查：关键漏洞通过正反例回归，七条试运行记录也得到了可独立复算的处理结果。

回引前期要求：在当前 Goal 内继续修复

我已经把这次的提示词发给了codex，但是我发现一个问题，如果我们每次codex的回复发现都没有完成我们的任务，然后要一步一步修复的话，会花很多很多时间，我认为我们的提示词里应该之后要包含修复的事情，以及我们的工作流和multi-agents体系也应该包含修复的事情，在完成goal任务之前就不应该停下来返回，除非遇到无法解决的阻碍，不然我们的工作流就是不完整的。不能指标的 ←

现在请你仔细理解我的要求并且整理一下，并且在我的基础上帮我完善并且补充一下任务要求（我目前的要求都是简单的初步想法，你可以提出更好的方案和建议），让它更完整专业，我需要确认你是否已经理解了我的任务，我确认后才可以进行实际操作

可信基线开始形成

七条试运行记录把实际处理、输出检查、修复和复验接了起来，为后续参数与方法比较提供了基础。

思考了 4m 2s

你的要求是：修复必须成为每个 Goal 的内置执行责任，也必须成为工作流和 Multi-Agent 体系的正常路径。只要问题仍能在批准范围内解决，系统就应继续诊断、修复、复验和推进，而不是把“发现问题”或“完成这一小段修复”当成任务结束。

这需要调整的不仅是提示词措辞，还包括任务结束条件、修复权限、角色交握和内部验收方式。

我前几轮的提示词虽然包含自检、修复和回归测试，但仍偏向“完成这次列出的修事项，然后返回”。这容易让工程师在局部清单完成，而不是持续检查整个 Goal 是否已经具备交付条件。这一点需要修正。

同时，要区分：此前某些停止是必要的研究阻碍，例如缺少文件对应的坐标事实；另一些是本质应更多地在内部发现问题优化的工程缺陷。不能把两者都笼统称为“未完成”，再反复交给你转发。

下面是我提议的修订方案，供你确认：本轮不修改文件，也不向正在执行的 Codex 追加指令。

后续：Goal 1 限定范围内通过

思考了 23m 44s

Goal 1 二重验收结论

本轮 Goal 1 通过二重验收——通过范围是你最新批准的“工程基础、可信审核、真实条件化 pilot，以及执行—修复—复验闭环”。可以结束 Goal 1 的反复修复，转入 Goal 2 的实验方案制定。

这不是把原来的 PARTIAL_BLOCKED 换一个名称：这次确实补齐了此前缺失的真实处理结果，两个关键审核缺陷也通过了我的独立反例复验。

但阶段通过不等于实验一全部完成，也不表示坐标基准已经证实、去噪准确率已经得到验证，或者当前方法和参数已经最优。

我实际读取的远程 main 为：

版本用途	SHA
实际计算代码	f229d9a4113bcb6dd763e1b418f1f5fb73983a62

用正反例和真实试运行检验修复结果（续）

接前页，继续阅读这组对话。

关键审核反例的关闭记录

二、此前两个关键审核问题，本轮可以正式关闭

1. C2-F01：审核对象与实际遮盖范围已经对应起来

此前的问题是：Agent 请求审核时间分区，但工具只检查 profiles，最后仍可能宣布整个任务通过。

本轮的审核接口已经区分具体产物及其检查范围。我实际验证了：

输入 / 请求	本轮实际结果
正确的时间分区	通过
漏掉时间切分边界	拒绝
将恰好 30 的时间间隔错误切分	拒绝
正确的重复事件详情	通过
遗漏重复事件	拒绝
正确 profiles	通过
重复 profile 记录	拒绝
用 profiles 审核关闭“时间边界 + 点覆盖”要求	拒绝，并保留未检查范围

这说明系统不再仅凭一个笼统的 `VERIFIED`，就认定其他产物也被审核过。

2. C2-F02：baseline 不再仅依靠候选自身提供的参考来证明正确

此前能错误通过的情况，本轮已经被拒绝：

构造情况	当前实际结果
手工构造的正确四点处理结果	通过
只改最终输出坐标	拒绝
同时改动 clean 与 final，原输入和账本不变	拒绝
删除全部结果记录，却仍声明处理了非空输入	拒绝
把汇总数量改为 999	拒绝
候选自行放宽 DP 容差	拒绝

核验对象要逐项对应

新的检查分别覆盖时间切分、重复事件、原始输入和点数账本。正常输入通过，错分、缺失、错误版本和候选自证都有对应的拒绝结果。

用正反例和真实试运行检验修复结果（续）

接前页，继续阅读这组对话。

关键审核反例的关闭记录 · 续页

换成不属于规定输入范围的记录	拒绝
使用错误父版本	拒绝
缺少外部可信原始参考	拒绝
17 项检查全部得到预期结果。这不是只让错误案例全部失败：正确案例也能通过，避免审核器退化成“全部拒绝”。	
这些测试不表示真实 pilot 曾被篡改；它们验证的是审核器能否发现相应错误。这两项旧问题不需要再单独发	
同一轮：修复、复验和任务恢复	
求你批准已经批准的条件化路径，也不能在后续报告中把这个限制删掉。	

五、 workflow 这次确实推进了任务，不再只是生成下一份修复提示词

这是本轮与前几轮最重要的区别。

1. 旧问题进入了实际修复和恢复

仓库记录了 C2-F01、C2-F02，以及执行中暴露的数值比较、坐标敏感性方向计算、时间范围文案等问题。它们有实际的：

问题登记 → B 修复 → C 拒绝或重开 → 再修复 → 独立验证 → 恢复父任务。

旧的 pilot01 / 02 被保留并标为失效版本，最终有效结果绑定 pilot03 和最终计算代码，而不是覆盖失败运行。

同时，AGENTS.md 已经加入“同一 Goal 内持续闭环”的规则，明确子角色返回、局部修复和内部 commit 都不是父 Goal 的结束条件。这次不只是口头上同步了新要求。

2. 后续动作有具体结果依据

独立 C 检查发现：最大 DP 误差距离 5 工作米上限只有约 0.06168 工作米。

随后实际产生的后续请求，是对同一批记录、同一冻结模型、已有实际区间和决策进行坐标敏感性检查，而不是随意换参数寻找更好分数。请求中明确写了触发案例、父产物与检查范围。

这个例子说明：

结果被读取了；结果触发了合理的新任务；工具实际执行了新任务；新产物又接受了对应审核。

正例与反例一起回归


正确输入仍能通过，旧漏洞有对应的拒绝测试。七条已经用于检查的记录，随后保留为开发和回归材料。

我的回看

坐标来源与计算模型继续分开记录。基线建立后，下一阶段再比较参数、顺序和处理效果。

任务、判断职责与确定性工具

我与 GPT 先明确研究原则，再由诊断、执行和核验角色配合确定性工具完成任务。



任务计划、实际产物和核验结果在角色之间传递；控制器管理依赖、预算和恢复，共享状态保存相应的输入、输出与判断依据。

先确定比较条件，再开展参数实验

进入 Goal 2 前，我要求在原体系中完成规定实验、共同评价和持续修复。结果回来时，GPT 先核对实际运行的配置、开发与评价数据的用途，再分析不同设置带来的变化。

我要求在原体系中完成 Goal 2

我理解了目前的状态，接下来我会新开一个codex对话，你需要给我完整详细专业可以直接发给codex的提示词，里面要包含我们的要求和计划，要包含详细的工作流和multi-agents体系的有关部分，让它完整完成goal2，在完成goal2之前都要利用我们的工作流和multi-agents体系持续循环修复，完成后要审核，最后审核通过后再上传到github仓库并且把结果返回给我，我会把结果返回给你，同时你检查github的实际内容，现在给我提示词吧

实验与审核一起执行

我要求沿用原有体系完成 Goal 2，交付前实际审核，再把真实仓库返回检查。后续比较由这些实测记录承接。

思考了 18m 13s

下面是可直接用于新 Codex 对话的完整提示词。它承接已经通过的 Goal 1，执行范围限定为 **Goal 2：规定实验、顺序比较、四模式验证和单项候选研究**；继续沿用现有 A / B / C 角色与确定性控制器，不另建一套脱离实验任务的平台。仓库中的三阶段划分和持续修复规则与此一致。

完成后的审核：数据用途与覆盖

二、规定实验已经完成，数据与评估阶段也有明确隔离

1. 数据规模与用途对应

仓库中实际登记的是：

分区	记录数	本轮用途
已暴露 pilot	7	回归与已知案例检查
示范记忆集	60	建立可核验经验
开发集	120	参数实验、顺序比较和候选选择
Goal 2 阶段评估集	120	冻结后的候选与顺序确认
Goal 3 保留区	11,079	未进入本轮方法选择与正式模式评测

四模式分别使用开发集和评估集内预先固定的 **24 条共同记录**。分层依据是原始跨度、时间异常和重复等描述性指标，不是经过标注的“静止 / 行驶真值”；报告没有把等额分层样本直接称为总体代表。

我核对的 7 / 60 / 120 / 120 四组原始记录 ID 没有交集。这支持记录级隔离，不意味着已经证明不同记录对应不同真实用户或车辆。

2. 实验覆盖与原计划一致

本轮完成了：

实验板块	实际完成范围
参数实验	59 个去重后的开发配置，覆盖三组实验、单因素及两个小型联合网格
顺序比较	六种顺序在开发集实际运行；四种被共同保护条件拒绝，两种进入阶段评估

先确定比较条件，再开展参数实验（续）

接前页，继续阅读这组对话。

完成后的审核：数据用途与覆盖 · 续页

阶段参数与单项确认	14 个冻结配置×120 条评估记录
示范记忆	60 条示范记录，按共同有限搜索建立核验过的快照
真实四模式	开发阶段各一次 episode；评估阶段 24 条×4 模式×3 次 episode

后续理解复盘：解释参数范围

4.1 事先固定的实验域

参数	实际比较值
时间差 / 秒	15、20、30、45、60
距离 / 工作米	95、200、400、600、800
最少点数	2、3、5、7、10
最短长度 / 工作米	0、32.5、65、97.5、130
方向差 / 度	15、25、35、45、60
DP容差 / 工作米	0、0.5、1、2、5、10、20

其中还包含时间×距离、点数×长度两个5×5网格。重复配置按实验身份去重后，开发集实际是59个唯一S-D-P配置，不是把六个参数做无边界笛卡尔积搜索。

这些值是批准的离散实验域，包含教师 / starter参考与有意设置的对照；不是全部都有已经证明适用于本数据的物理上限依据。

4.2 得到了什么

以方向阈值为例，120条开发记录上，15°、35°、60°分别剔除1,649、669、278点；共同覆盖均为8,408点。

这能说明阈值放宽后规则剔除减少，但不能凭这条单调趋势判断准确率变好。

另外，在相邻已测试的单因素取值中，没有出现阶段索引、覆盖集合和终态计数全部相同的精确稳定区间。因此我们没有把相近的平均值包装成“存在稳定最优平台”。

4.3 单项候选的阶段结论

候选	改动范围	G2留出结果	如何处理
C-S	5分段 / 过滤参数组	120条全保护，53条严格改善	保留为G3备选
C-D	方向阈值	未证明统一替代参考的收益	保留参考
C-P	DP容差	未证明共同预算内的新压缩收益	保留参考

保留参考是操作性选择，不是证明参考具有全局最优性。

从读数变化追问原因

59 个去重配置覆盖三组参数实验与联合网格。后续复盘继续解释：方向阈值改变删除量，还需要检查正常信息是否被保留。

用六种真实顺序比较回答老师的问题

我在完整任务要求中保留了顺序讨论。执行时实际改变三步的排列，再检查断点、完整输入和最终几何关系；通过、存在权衡与被拒绝的结果都留下记录。

我要求逐项对应老师完整任务

网页搜索

现在我希望你实际帮我完成实验1的任务，你来指挥codex一步步来完成，你先列出一个你的完整计划和方案：我需要在里面至少详细看到以下的内容，你不一定要立刻给出完整的计划和方案，但我要看到你的想法和你是如何去完成我的要求的：
0.老师的完整要求和任务是什么（不只是基础任务，而是包含附加任务和我的要求和任务），我们的完整方案和策略是什么（应该有——对应），如何按照要求切割成2-4个板块，即2-4个大/长的codex的goal任务，板块太多会增加我们的交互工作量
1.如何针对我们的实验1构建工作流和multi-agents体系
2.如何构建每一步的审核机制和循环优化机制，确保每一步是真正优秀完成了，而不只是完成了，无法审核和确认其结果
3.如何把我们搜索到的论文的内容/方案/策略/重点实际加入这个实验
4.我们是如何完成老师的附加任务的，以及我要求你在附加任务基础上想一些额外的任务或者是想法，我们的是什么？把搜索到的论文的内容/方案/策略/重点实际加入这个实验可以算作额外的任务，还有别额外任务吗？
5.最后codex审核并且循环优化后你该如何审查结果
我审核通过后你再给我完整详细可以直接发给codex的提示词，先不用给我提示词
现在请你仔细理解我的要求并且整理一下，并且在我的基础上帮我完善并且补充一下任务要求（我目前的要求都是简单的初步想法，你可以提出更好的方案和建议），让它更完整专业，我需要确认你是否已经理解了我的任务，我确认后可以实际操作

收起 ^

要求实际比较

我要求完整覆盖老师任务并说明怎样检验。顺序实验逐一记录可用结果和失败原因，供后续解释与取舍。

GPT 审核六种顺序及失败原因

四、顺序实验已经回答了老师的问题，但答案是有条件的		
独立重算得到以下结果：		
开发集顺序	违反共同安全保护的记录数	阶段判断
S-D-P	0	参考

用六种真实顺序比较回答老师的问题（续）

接前页，继续阅读这组对话。

GPT 审核六种顺序及失败原因 · 续页

S-P-D	0	有权衡，保留比较
D-S-P	46	拒绝
D-P-S	87	拒绝
P-S-D	87	拒绝
P-D-S	87	拒绝

读清各顺序的代价

四种顺序触发保护条件；S-P-D 虽然通过部分检查，最终共同几何偏差仍高于 S-D-P。GPT 据此追查步骤怎样改变后续输入。

其中 S 包含分段及紧随其后的短段过滤。结果与阶段分析一致。

这些不是“为了让默认顺序赢而在其他组里故意放错代码”。实际原因包括：先简化会移除原始断点触发信息；先去噪可能在间断两侧构造方向窗口；过滤作用于不同阶段的点数和长度，可能改变覆盖。

不过，正式结论应当是：<

三步不是可以无条件交换的操作；在当前数据、定义、参数和共同保护条件下，四种朴素顺序出现了实际失败。

不能上升为“所有轨迹处理任务永远只能采用 S-D-P”。

还有一个值得在报告中重点解释的现象：“S-P-D 通过了覆盖 / 断点保护，并不意味着最终几何保证与 S-D-P 一样。”我复算其留出结果得到：

- S-D-P 的共同原始最大几何偏差约 136.118 工作米；
 - S-P-D 约 377.727 工作米；
 - S-P-D 的 P 阶段即时误差仍在约 4.993 工作米。
- 原因是 P 之后的 D 又改变了轨迹。中间一步满足 5 工作米容差，不代表后续继续删除后的最终轨迹仍满足这个保证。

用六种真实顺序比较回答老师的问题（续）

接前页，继续阅读这组对话。

后续复盘：顺序为何改变结果

S-D-P	0	参考顺序
S-P-D	0	存在权衡，不作为统一替代
D-S-P	46	约束拒绝
D-P-S	87	约束拒绝
P-S-D	87	约束拒绝
P-D-S	87	约束拒绝

所有六种顺序在开发范围实际比较；只有开发阶段通过安全条件的顺序进入后续留出评估。没有为了宣称“六种都通过”，在D或P前偷偷加一个未登记的预分段。

为什么顺序会改变结果

D在S前：方向窗口可能跨越本来应断开的时间 / 空间空档。

P在S前：简化可能删除触发原始断点的信息，使后面的S看到的已不是原始邻接。

P在D前：P改变邻居，D的方向判断随之改变；而D后续删除的点，不能继续算作P本身的压缩结果。

所以我们的回答不是：

“所有任务都天然必须S-D-P。”

而是：

在当前算法定义、原始断点保护和实际数据下，不能无条件交换三步；已测试顺序中，S-D-P作为参考保留，其他顺序有实际失败或权衡证据。←

结合本次条件解释顺序

在当前定义、数据和保护条件下，部分顺序被拒绝；S-P-D 虽部分通过，其最终几何偏差仍与 S-D-P 有差异。

用真实权限和动作区分四种模式

我要求真实执行与共同审核。四种模式因此按实际能力区分：一次提议、确定性搜索、允许反馈，以及读取冻结记忆；每种模式的信息、动作和结果都分别检查。

前期要求：共同评价、结果为据

经就是在进行中
2.所有的审核机制和每一步结果都要有依据，都要被证实结果优秀才能进行下一步，所有的方案的好坏都要以结果为准，而不是先空想方案的好坏
3.方案/策略之间的融合要多尝试，结果好的就继续，不好的就回退，要

分别检查模式的能力

search-only 使用确定性搜索；其他模式按配置获得结果反馈或冻结记忆。实际调用记录说明各模式怎样完成任务。

实施后的审核：模式实际不同

这是一项有价值的实际结论，而不仅是六种顺序的分数排名。

五、真实四模式与记忆实验成立，但暂不能宣布哪一层带来因果优势

1. 四种模式不是只换了标签

源码中可以确认：

模式	实际决策差异
lln-only	一次真实提议；锁定后执行与评价，不反馈结果让它继续修改
search-only	不构造模型 Provider，使用冻结的确定性候选序列
lln+search	真实提议，自己的实测反馈、预算内后续候选
lln+memory+search	在相同搜索框架上额外读取冻结示范记忆

每记录候选上限、决策回合、缓存、原始提议、锁定输出和回退分别记录，不能从不同模式窃取中间结果。

实际模型事件也体现了“看到结果再提出下一步”。例如评估阶段的建议明确引用此前降低 DP 容差没有改善共同误差、降低方向阈值反而退化的结果，再请求尝试方向 60，而不是预生成的一套固定回答。

用真实权限和动作区分四种模式（续）

接前页，继续阅读这组对话。

后续复盘：权限与 84 次有效实验

留，其他顺序有实际失败或权衡证据。

6. 四种模式确实结构不同，不是同一程序换标签

模式	决策时可以看到什么	决策机制	有效实验模型派发：开发 + 评估
llm-only	诊断卡、合法参数域；没有搜索反馈和记忆	一次提议锁定，再由外部执行评价	3 + 9
search-only	原始诊断与确定性规则	固定有界搜索，不调用实验模型	0 + 0
llm+search	自己已经执行的真实反馈	最多3轮，候选总上限20	9 + 27
llm+memory+search	同上，加冻结示范记忆	最多3轮、同一候选上限	9 + 27
合计			84

共同模式子集为每个分区24条记录，开发1个episode，评估3个episode；每次请求最多批量8张诊断卡。一次批量派发不能写成8次模型请求。

公平比较并不意味着所有模式做完全相同的事

搜索型模式有共同候选上限，但允许提前停止，因此**预算上限相同，不代表实际候选数相同。**

确定性搜索使用预先固定的20项序列；LLM可以在批准六参数网格内提出完整向量。因此比较的是这些**完整决策策略在明确权限与上限下的表现**，不是一个完全隔离所有搜索空间差异的“LLM智力纯增益实验”。

我们如何防止标签造假

search-only设置了一调用模型就失败的接口检查；治理A/B/C调用与实验记录级调用分账。

llm-only没有在锁定前偷偷得到搜索成绩；之后的独立评价不等于它在决策时看到了答案。

旧失效或中断的15次真实派发另行保存，不计入当前有效84次的效果统计，也没有从成本历史中抹去。底层不可见请求和费用保持未知。

把调用口径说明白

84 次统计的是记录级有效实验，开发与评价分别记录。各模式的共同预算上限相同，实际动作和消耗则按运行结果说明。

沿着送达、引用和动作检查记忆的作用

我提出的“结果必须有依据”同样适用于记忆。后续核验逐层检查经验来自哪里、是否送达、是否被引用，以及实际动作是否与引用一致，再判断这些证据能支持怎样的结论。

回引前期要求：所有结果都要有依据

经就是在进行中
2.所有的审核机制和每一步结果都要有依据，都要被证实结果优秀才能进行下一步，所有的方案的好坏都要以结果为准，而不是先空想方案的好坏
3.方案/策略之间的融合要多尝试，结果好的就继续，不好的就回退，要

分层检查实际使用

记忆的送达、引用与动作一致分别记录。这样能够看清经验在哪一步被使用，也能定位检索与实际决策之间的差别。

后续复盘：送达、引用与动作

7. 记忆做到了哪一步，为什么还不能说它提高了质量

7.1 记忆来自哪里

仅使用60条示范记录，经过确定性处理与核验后形成快照。

检索使用同描述层过滤和六个原始特征：点数、跨度、正时间差中位数的变换，以及零时间差比例、相邻重复比例、原始断点比例。归一化尺度只由示范集固定，最多取3个邻居。

评估阶段只读，不允许把当前评估记录的结果写回后再次检索。

7.2 实际观察到了什么

层次	实际读数	能说明什么
有效记录—episode收到条目	96 / 96	记忆信息确实被送入相应上下文
实际决策回合引用有效条目	60 / 241	存在可观察引用
引用日参数与条目一致	49 / 241	部分动作与引用内容一致

这些分母分别是检索机会与决策回合，不能互换。*送达、引用、参数一致都不等于因果质量收益。*模型之间的独立调用也可能有其他差异，不能把每个建议变化都归因于记忆。

因此，这个任务的结论是：

只读记忆机制及其实际消费得到了验证，但“记忆带来可归因质量提升”没有得到证明。

最终统一\$0没有依赖在线记忆，不是遗漏了记忆任务，而是没有把尚未证明的收益强行放进部署策略。

按证据决定是否保留

运行记录显示记忆已被使用，但本轮证据尚不足以确认它带来的质量收益。因此最终固定处理采用无记忆设置。

阶段审核保留的结论边界

记忆实现绑定示范记录、原始数据、合同和快照，返回深拷贝，拒绝评测写入，并排除同父记录、重复来源及不适用类型。

当前记录中的送达、有效引用、参数一致性是不同统计层次。检索命中不等于模型采用；模型采用不等于效果更好；与无记忆模式输出不同也不自动证明因果收益。

因此，“尚未证实记忆带来因果质量收益”是本轮正确的限制，不是必须继续加实验直到记忆获胜的理由。

用共同参考检验一条 AI 建议

记录 7764 提供了一个具体案例：模型建议可以执行，候选自身的 DP 检查也通过，但回到共同原始参考时，几何偏差增大了。我前面提出的真实执行与共同评价要求，在这里进入了实际判断。

我的前期规则授权

经就是在进行中
2.所有的审核机制和每一步结果都要有依据，都要被证实结果优秀才能进行下一步，所有的方案的好坏都要以结果为准，而不是先空想方案的好坏
3.方案/策略之间的融合要多尝试，结果好的就继续，不好的就回退，要

前期要求在案例中落实

我先要求结果经过共同评价；记录 7764 的问题随后在执行与核验中显现，成为检查建议采用依据的具体案例。

阶段审核中的真实建议核验

本轮公布的有效实验调用为 84 次：开发 21 次、评估 63 次。旧失效 / 中断调用另有记录，没有混入当前效果分母。这是可见实验派发口径，不是我独立测量的底层 HTTP 请求数或账单。

2. 有实际建议被结果否定，而不是所有建议都“成功”

我从原始模型事件中取出记录 7764 的一个合法建议，独立计算得到：

指标	参考	该建议
共同覆盖点	122	122
共同原始最大几何偏差 / 工作米	40.214764	69.145351
候选自身 DP 最大误差 / 工作米	—	4.826420

候选自身 DP 合格，但共同原始几何保护变差，因此不能据此接受为改善。

这与已保存的建议、实测结果和 TRADEOFF 判断一致。模型当时只是提出待验证候选，并没有宣称已经证明它更好；报告不应把这种正常试验改写成虚假的“AI 故意犯错”。

共同参考给出采用依据

共同几何偏差约由 40.215 增至 69.145 工作米。候选自身 DP 约 4.826 工作米，最终因共同几何保护未满足而未被采用。

后续复盘：局部与整链保证

8. 一次真实AI建议怎样被评价，而不是被盲目采纳

记录7764的一条真实建议，参数合法、能够执行，并且自己的DP检查通过：

指标	参考	AI候选
共同覆盖	122 / 122	122 / 122
参考覆盖集合上的最大几何误差	40.214764	69.145351工作米
原始断点跨越	0	0
候选自身P最大误差	—	4.8264199工作米

候选自身P误差小于5，但共同几何保护变差，因此不能作为改善方案接受。

这里也不能过度批判AI：原建议本身表达了“覆盖与保真仍需评价”，所以它不是必然在断言自己已经更好。

真正展示的研究能力是：

合法提议仍需实测；局部证书不能替代整链保护；不满足接受条件就拒绝。

另一个记录10232的建议，预先预测方向剔除数减少，实际从32降到10，方向预测得到了支持。但这也只证明那项预测正确，不自动使整个候选成为最后赢家。


我的回看

回看这条建议，我更能理解局部算法检查与完整处理效果的差别：采用决定还要检查前后处理对同一原始参考的影响。

先确定选择规则，再由结果决定方案

进入 Goal 3 时，我问能否让 Codex 依据实验完成候选、比较和选择。随后我与 GPT 明确了范围、预算和判定条件，把具体方案的取舍交给这些规则下的真实结果。

我提出结果驱动的下一阶段



先把选择条件讲清

候选需要明确的范围、预算、保护条件和可复查结果。重要方法或评价变化，则重新回到讨论中判断。

GPT 修订范围、规则和交付

我赞成你的倾向：让 Codex 依据真实实验结果，完成 Goal 3 内部的候选生成、比较、保留、淘汰、组合和最终工程方案选择，而不是由我们提前凭判断选定最终方案。

我上一轮说“集中确定 Goal 3 的候选和比较方案”，容易让人理解成“我们先把最终方法讨论出来，再交给 Codex 实现”。更准确的安排应当是：

我们提前确定允许探索的范围、判定规则和最终交付要求；Codex 在这个范围内根据结果决定具体走哪条路线，并持续执行到交付；我最后检查真实仓库，审核选择是否成立。

“需要提前确定的是“怎么选”，不是“选谁”。“项目协议本身也允许：批准方案已有明确自动判定规则时，由 Codex 按规则完成判断，不需要每次返回用户。

下面是我推荐的下一步计划。它是 Goal 3 的执行安排建议，本轮不启动实验，也不提前认定最终赢家。

一、职责这样划分：我们制定规则，Codex 完成结果驱动的选择

事项	我们提前明确什么	Codex 自主完成什么
目标与范围	完成实验全部基础，附加与已批准增强任务；不足超大型研究项目	核对剩余工作，组织实验和交付
候选	筛选现有方法，参数和有限策略可以探索；什么不得加入	从 Goal 2 的真实结果中筛选起点，提出有证据的后续候选
比较	共同指标、保护项、数据隔离、预算与采用规则	实际运行、分析差异、检查退化，决定通过或淘汰
循环优化	先单后组合；允许回退；不能改标准追求漂亮结果	根据每轮结果安排下一轮，而不是机械固定流程
方法冻结	达到什么条件才能进入最终确认和全量处	按预设规则选择并冻结工程方案，继续后续工

先确定选择规则，再由结果决定方案（续）

接前页，继续阅读这组对话。

GPT 修订范围、规则和交付 · 续页

理	作
最终验收	必须满足的代码、结果、报告、复现和真实性要求
	内部独立审核、修回、发布；随后由我审核真实性或成果
因此，我不会要求你现在回答“最终用 C-5，还是 C-5 加某个方向策略”。这些问题本来就应该通过实际比较来回答。	
同一回答：选择、冻结和确认分开	
已经使用过的 G2_EVAL 可以作为历史证据，但不能重新称为“从未看过的最终测试”。	
阶段 B：锁定候选与选择规则	
在查看新的最终确认结果前，锁定方法、参数、适用条件、模型模式、记忆状态和审核规则。	
这一步允许 Codex 按我们预先授权的判定规则自动完成，不必停下来问你“是否冻结这个参数”。	
阶段 C：在独立保留数据上确认	
最终确认用于检查已经选定的方案是否站得住，不用于边看结果边改方法。	
确认没有支持增益时，应如实报告，并按预先登记的发布 / 回退规则处理；**不能继续对同一批最终确认数据调参，直到通过。**如果发现的是实现错误，则修复并披露受影响范围和重跑情况，不能把已看过的数据重新描述为未见数据。	
阶段 D：全量处理与正式交付	
达到发布条件后，Codex 自动继续全量处理、结果核验、正式图表、Notebook、报告工程和提交包检查。	
全量处理不是额外一轮隐藏探索。执行全量时，方法应当已经冻结；出现异常按已批准的失败和回退规则处理。	
这些是自动工作流内部的阶段，不意味着每个阶段结束都需要你再确认一次。	

为最终确认保留数据

已看过的评价数据继续作为开发证据。方法固定后，再使用预先保留的记录检查选定方案。

六、系统组件也由结果决定，但不能混淆“处理方法”与“研究 workflow”

还需要把两个问题分开：

哪种处理策略适合最终输出？

哪种 workflow 帮助我们可靠地完成研究、验证和交付？

即使最终某些轨迹只需要确定性工具，整个研究过程中的 A / B / C，审核、修复和证据管理仍然有实际职责。

反过来，也不能为了证明 Multi-Agent 有用，强制最终每条轨迹都调用 LLM，或者明知记忆没有显示收益还宣称它是必要质量组件。当前结果已经要求我们区分记忆送达、引用、动作一致性与实际收益。

我建议：保留已经完成的四模式证据，让最终运行方式也参与有明确条件的比较；不预设“组件最多的模式必须成为最终模式”。

这样既满足老师的 LLM 工作流任务，也不会为了形式上的“智能”牺牲可解释性。

组合经历支持与退化，最后回到简单方案

我要求先单项、再组合，好的保留、退化回退。实际比较中，组合曾获得开发数据支持，但在新的选择记录上出现三条几何退化，于是按原定规则退出。

我的原始要求：先验证，再组合

3.方案/策略之间的融合要多尝试，结果好的就继续，不好的就回退，要先把基础的方案和策略验证过，再去融合他们，而不要上来就去尝试复合方案和策略
4.不要尝试过多论文里的东西，最后我们大概只能用到2-4篇，太多的混

新记录改变了选择

S0 与方向条件规则的组合在 3017、9311、9534 上退化。三条失败触发共同保护规则，组合因此被撤回。

Goal 3 真实结果：退化与回退

35"。它使用的是运行时可取得的原始时间特征，不是按记录 ID 记答案。

在 240 条开发记录上：

- S0 相对 R0，新增 6,704 个共同覆盖点，107 条记录严格改善。
- S0_G0 相对 S0，41 条记录的几何指数改善，全部开发记录通过保护。
- 因而系统曾将 S0_G0 接受为开发阶段的当前方案，并检查了两个父组件的作用。

这些关键读数与我的独立复算吻合。因此，它并不是只跑了 S0，然后直接宣布不用组合。

2. 组合在选择集上出现退化，系统据此回退

进入新的 240 条选择记录后，S0_G0 在三条记录上出现共同几何保护退化：

记录	S0 的共同最大误差	S0_G0 对应误差
3017	4.785506 工作米	4.957121 工作米
9311	3.953415 工作米	4.276002 工作米
9534	3.718470 工作米	4.464256 工作米

这三个失败记录和数值，我都独立复算到了。

按照事先登记的规则，其他记录上的改善不能抵消这三条保护失败，所以系统退回较简单的 S0。选择代码也确实同时比较固定参考和当前方案，而不是仅按某个总平均分挑赢家。

3. 其他组合没有被为了“融合”强行保留

P2、S0_P2 分别多保留 1,946、2,010 个点，没有共同预算下的压缩收益；P10、S0_P10 分别有 173、178 条记录超过共同 5 工作米预算。这些结果也独立复算吻合。

所以，本轮得到的是：

尝试了有依据的组合 → 开发阶段出现收益 → 新选择数据暴露退化 → 拒绝不稳定组合 → 保留已验证的简单策略。

这正是我们要求的循环优化过程。“最终没有保留更复杂组合”不是失败，也不需要再追加实验，直到某个复杂

组合经历支持与退化，最后回到简单方案（续）

接前页，继续阅读这组对话。

后续复盘：单项、父项与组合

内部C研究检查	全量可信raw对应检查，独立数学抽查、候选保护、选择与冻结核查	抽查不是每条轨迹都由第二套数学实现重算
此前网页GPT技术审核	已向你报告过关键源码与全量数学复算的范围性结论	本次复盘不把历史复算说成今天重新执行
本轮内部收尾审核	四次新内核FULL，身份与包回归、当前34页实际视觉检查记录	不等于用户已理解、Evidence已LOCK
最新网页GPT收尾检查	远程文件和版本、身份生成链、对账材料；8项身份专项检查通过	没有亲自重做四次FULL，完整PDF逐页目视与ZIP执行
用户最终审核	现在开始按四块进行	不能提前填写通过或虚构答疑成绩

当前内部CL矩阵是15项在登记工程范围内通过、1项正式互动证据受阻；这些状态不能抵消彼此。

四次FULL为什么不是四批新的实验样本

它们是同一已冻结内容在仓库与解压环境中的复算，验证的是：

换新内核、换目录、没有原工作区隐藏状态，结果是否仍能从真实输入得到。

不是将相同记录又运行几遍，就获得几倍独立样本量。

最终包后来只修改报告PDF与manifest，运行载荷保持相同的部分采用字节等价证据继承；这也没有被写成额外一次新的执行。

3. 你在整个任务中的真实贡献是什么

目前可以清楚确认的，是你逐步改变了任务与执行机制：

不只在基础处理做出来，要围绕任务持续优化；不凭想法逃优，要多策略实测；先单项再组合；不同方案共用比较标准；普通修复必须在Goal内部闭合；批准规则之后减少不必要的人工插手。

这些不是简单的“最后同意”，而是实质影响了研究组织和执行边界。

但是，以下内容不能倒写到你名下：

你没有逐记录选择所有参数；

A/C在已批准规则内作出的具体裁决，不等于每一项都由你亲自判断；

你还没有完成当前四块内容的深入理解审核。

****人类贡献应该按真实层次呈现，不通过伪造逐步确认把它“做多”。****这正是正式Process Report还需要原始互动证据的原因。

4. Process Report现在到底差在哪里

当前已经有技术过程事实：授权、模型建议、工具执行、研究裁决、失败、修复和恢复。

但正式Evidence计划仍显示没有登记完成的证据条目，19个事实候选也不等于19条已批准的正式截图。现有材料没有自动补齐完整原生上下文、呈现规格和LOCK。

回看我的研究要求


后续复盘把我的作用归到任务与判断规则：先单项再组合、共同评价、退化回退。具体候选由真实比较逐步筛选。

我的回看

S0 包含点数和长度两项过滤调整。后续分别检查它们的作用，再判断两项调整合用时留下了什么。

单项、组合、选择与回退的真实路径

先看各项调整的独立作用，再用新的选择记录检查组合；三条几何退化使方案回到 S0。



开发阶段曾支持 S0 与 G0 组合，新的选择记录随后触发保护条件。最终保留 S0，固定方法后完成 600 条确认记录与全量处理。

从冻结确认到全量处理，读清最终结果

Codex 完成 Goal 3 后，我把交付返回 GPT 核查。GPT 先确认选定方案与冻结时点，再核对 600 条保留记录和全量处理，并结合收益来源与边界案例解释这些数字。

我转交的 Goal 3 回复与审核开头

已发布发布审查检查点，Goal 3 状态为 PARTIAL BLOCKED。全部可自主完成的工程已通过独立验收；缺少可信姓名 / 学号及 Evidence Master 输入，尚不能直接提交教师。

🔒 固定版本审阅入口 · 🔒 完整中文 FINAL_RESPONSE

A. 总体状态

Technical: VERIFIED; Research: SUPPORTED_WITHIN_SCOPE; Reports: 工程通过、外部缺项; Package: REVIEW_ONLY; Publication: 已推送并核对。内部 C 验收通过，GPT_SECOND_REVIEW=PENDING。

B. 最终方案

采用确定性 S-D-P: dt=38秒、distance=400工作米、min_points=2、min_length=0、direction=35°、dp=5工作米。记录级处理不调用模型。预设 R0 回退未触发。

source crs 仍为 UNVERIFIED，结果仅支持已批准工作坐标下的条件

...

显示更多

分别核对确认与生产

我转交 Codex 的交付回执，GPT 继续检查冻结时点、600 条确认和全量结果，分别说明它们的用途。

思考了 27m 53s

Goal 3 二重验收结论

本轮技术与研究主体通过有范围的二重验收：候选比较、最终方案选择、冻结后的确认实验，以及全部原始记录的处理结果，都得到了实际盈利检查和独立数学复算支持。

冻结后的 600 条确认记录

方案获胜。

三、最终确认的安排和结果成立

我读取到的冻结时间为：

2026-09-27 05:23:51.350095 UTC。

从冻结确认到全量处理，读清最终结果（续）

接前页，继续阅读这组对话。

冻结后的 600 条确认记录 · 续页

实际最终确认运行在：

05:26:18.235190 UTC 开始。

冻结记录先于运行，执行代码还检查输入记录范围、策略列表及合同绑定。

我不仅核对了 600 个 ID 的数量与分区交集，还根据仓库公布的稳定哈希规则，从原始记录重新生成了最终确认名单，结果与冻结名单完全一致。

这支持当前记录级的数据隔离安排，但不意味着已经证明不同记录对应不同用户或独立行程。

最终确认的独立复算

600 条记录、62,284 点	R0	SO
分段过滤点	26,416	64
方向删除点	1,845	2,148
DP 省去点	23,032	47,958
显式保留点	10,991	12,114
共同覆盖点	35,868	62,220
无输出记录	255	0

600 条全部满足已登记保护，349 条存在严格改善。这些结果与远程产物一致。

本轮没有发现依据最终确认结果继续调参、再把同一批数据称作未见测试的证据。

因此，可以认可：

冻结之后再确认

GPT 核对冻结时点与 600 条确认记录：方案固定在先，运行在后。全部记录满足既定保护，其中 349 条记录有严格改善。

全量复算与收益来源

不能扩大为“已经证明对所有轨迹都量优”，也不能把后续全量生产再称为一次全新的独立测试。

四、全量处理结果，我已经独立复算吻合

这次最实质性的进展是：不再停留于 7 条 pilot 或几百条样本，而是完成了全部原始记录。

全量读数	R0	最佳 SO
------	----	-------

从冻结确认到全量处理，读清最终结果（续）

接前页，继续阅读这组对话。

全量复算与收益来源 · 续页

输入记录	11,386	11,386
输入点	1,173,410	1,173,410
分段数	25,963	25,963
过滤点	501,511	1,199
方向删除点	39,056	39,732
DP 省去点	435,373	911,330
显式保留点	200,470	221,149
共同覆盖点	671,899	1,172,211
无输出记录	4,959	0
原始断点跨越	0	0

这些数值与正式报告的生产章节一致。

S0 的互斥点终态满足：

$$1,199 + 39,732 + 911,330 + 221,149 = 1,173,410.$$

独立复算还得到：

11,386 条记录全部满足当前共同保护，6,522 条严格改善；新增共同覆盖 500,312 点，而显式保留点只增加 20,679 点。

这项改善应该怎样解释

当前最终策略与参考方案的主要区别，是把最少点数从 5 降为 2，把最短长度从 65 改为 0。大量原本被整段过滤的原始范围因此进入后续处理。

我进一步独立核对了新增覆盖的来源：

R0 原本过滤这些点的原因	新增覆盖点数
仅长度不足	492,513
仅点数不足	5,434

覆盖增加来自哪里

全量核对显示，共同覆盖增加 500,312 点，显式保留增加 20,679 点。GPT 继续按原过滤原因分解收益，把主要变化追溯到短片段过滤条件。

从冻结确认到全量处理，读清最终结果（续）

接前页，继续阅读这组对话。

全量复算与收益来源 · 续页

两项同时不足	2,365
合计	500,312
因此，主要收益确实来自减少短段过滤造成的信息丢失，而不是换了一种更强的 DP 算法。这与报告中保留的解释一致。	

同一轮：约 266 工作米的边界案例

还需要继续区分：
共同覆盖 ≠ 最终存储点数 ≠ 真实干净点数。
S0 的 DP 省点率约为 80.47%，R0 约为 68.47%，但两者的 DP 输入不同，不能把这个差值直接当作 DP 算法提升了约 12 个百分点”。

五、266 工作米的偏差不是隐藏错误，但必须保留在最终结论里

这是本次结果最重要的限制之一。我专门独立复算了它。

记录 352 的原始窗口为：

纯文本

[184, 185, 186, 187]

这个窗口只有 4 个点，但累计长度约 809.444 工作米。

R0 因为点数不足 5 过滤整段，并不是因为长度小于 65。S0 保留该段后，方向规则删除了索引 105；随后：

纯文本

clean 输入: [104, 106, 107]
DP 输出: [104, 106, 107]

即该局部 DP 没有再睡点。原始点 105 到最终夹持线段的偏差为：

266.01675442514176 工作米。

这与仓库报告吻合。

****它不违反 DP 对其即时输入的 5 工作米保证，因为点 105 在 DP 之前就被 D 删除了。**但它同样不能证明点 105 必然是真实噪声。**

全量结果中，DP 即时最大误差约为 **4.999964 工作米**，而共同原始参考到最终输出的最大误差约为 **368.707060 工作米**。两者参考集合不同，所以并不矛盾。

END OF THE REPORT .

把边界案例留在结论中

新增覆盖主要来自减少短段过滤损失。记录 352 的点 105 在 DP 之前被删除，它不在 DP 的 5 工作米保证范围内。

我的回看

本轮改善得到共同覆盖与几何保护的支持；真实定位精度仍受坐标来源和噪声标签缺失的限制。

完成研究后，我要求逐项讲清方法与结果

研究与工程收敛后，我要求完整复盘：老师的任务、我的补充、实际做法、检查方式，以及证据支持的结论，都要一项项说明。我希望借此真正理解每一步及其选择理由。

我要求完整对账与深入解释

姓名：吴博闻，学号：10245102410
你先不要直接给我提示词，给我详细过一遍我们目前都干了什么，完成了哪些任务，然后还差哪些需要收尾，每个任务是怎么做的，如何审核的，如何证明他们是优秀完成的，而不只是完成了，如何循环优化的，把老师的完整任务清单，我的额外任务，以及我的所有要求清单（就是我提的各种要求，我需要确认你都按照要求完成了）全部——列出来，每一项旁边对应我们完成了什么，怎么完成的等等，然后我们详细的过一遍后再进行最后的收尾和提交
现在请你仔细理解我的要求并且整理一下，并且在我的基础上帮我完善并且补充一下任务要求（我目前的要求都是简单的初步想法，你可以提出更好的方案和建议），让它更完整专业，我需要确认你是否已经理解了我的任务，我确认后才可以进行实际操作

把清单讲成具体方法

我需要知道为什么这样处理、为什么采用或回退，以及报告还需要怎样完善。GPT 据此组织了分块讲解。

思考了 11m 59s

姓名和学号已明确：吴博闻，10245102410。此前“缺少可信身份信息”这一信息缺口已经解决；但仓库元数

GPT 把复盘拆成关联的问题

你现在要做的，不是马上进入最后一次 Codex 收尾，而是一次提交前的完整要求对账、技术讲解与质量复盘：

先确认我们是否做对了全部任务，再确认每项成果的质量证据是否充分；把没有完成、没有证明、采用了调整方案的部分说明白，最后才修改报告、重建提交包。

我理解你的重点还有一层：你不仅要知道项目“通过了多少项验收”，还要能够判断这些验收究竟证明了什么，并理解我们为什么采用现在的方案。

本轮我重新读取了教师材料、原始 starter、当前任务导航、技术交接、文献合并稿和上一轮独立审核记录；远程 main 仍为 1a5e26b43189aef64a46f8986b3cc442fa50d2c5。下面先给出完整复盘框架和已有证据的初版总账，不修改仓库、不重跑实验、不生成执行提示词，也不宣布最终提交通过。

完成研究后，我要求逐项讲清方法与结果（续）

接前页，继续阅读这组对话。

GPT 把复盘拆成关联的问题 · 续页

一、这次复盘具体要回答什么

你提出的要求可以整理为六个相互衔接的问题：

要回答的问题	不能用什么代替
一、这次复盘具体要回答什么	
你提出的要求可以整理为六个相互衔接的问题：	
要回答的问题	不能用什么代替
任务是什么？老师明确要求、选做要求、你的额外要求分别有哪些？	不能只拿我们后来写的 Codex Prompt 当成老师原文
做了什么？每项要求对应哪个实现、实验、图表或报告内容？	不能只列目录、文件数量或一句“已完成”
为什么这样做？定义、参数、顺序、指标和系统结构	不能只说“starter 这么写”或“AI 推荐”

后续：我要求四块完整复盘

串起方法与结果

这轮讲解发生在主要实验之后，把任务、处理与评价、系统实验、报告交付放在一起，帮助我逐项审阅。

星期一 13:49

好的，我们来详细复盘吧，直接给我完整详细的复盘即可，我一次一块审核，复盘的要求按照之前我们规定好的来

思考了 16m 10s

实验一完整复盘

****复盘对象：****仓库固定版本 718e6d9eb69d3e47ee8929755cd3bd3c94526fab，包括此前三个 Goal 的研究、实现、实验与本轮收尾成果，下面按四个板块给出完整内容；你可以先审核第一块，其余部分保持待审，不需要一次确认全部。

先给出贯穿全文的结论：

我们已经完成了轨迹预处理、规定的参数与顺序实验、真实 LLM 四模式与记忆实验，以及结果驱动的候

从技术核查转向报告审阅（续）

接前页，继续阅读这组对话。

GPT 区分正文与内部追溯材料

我认为现稿有四个贯穿全文的问题，不只是你圈出的几个句子。

1. 报告的叙述主体错了

一名学生交给教师的报告，不应反复称自己为“用户”，也不应像第三方审计员一样说：

“在用户批准下”不能倒写成教师批准“本工程不代发邮件”。

合适的主体应当是实验及观察本身：

“采用了什么方法”“比较了什么设置”“结果显示什么”“为什么没有采用另一方案”。←

确需说明个人判断时，可以自然使用“我在检查中发现……”，但不必把每段都写成第一人称心得。

2. 把研究事实与管理约束混在一起

可以用下面的办法分流：

内容	应当怎样处理
数据规模、变量、实际质量问题	留在正文
分段、去噪、简化和评价定义	留在正文，先解释用途，再给必要公式
数据划分、关键参数、模型模式及重复次数	留在简洁的实验设置中
坐标来源不明、无噪声标签等会影响结论的限制	用正常报告语言保留，在相关位置说明
SHA、run ID、提交时间、文件校验、完整错误日志	移到仓库或复现说明，不必一股脑塞进附录
教师邮箱、ZIP命名、是否代发、当前审核状态	从正式正文删除，留在交付清单
用户批准了哪个执行权限	技术正文不写；确有研究意义的真实决定放入过程报告
未实现哪些无关扩展	通常删除；只有直接影响方法比较时才说明

删除的是不适合读者的信息，不是删除研究责任。代码、原始数据和检查记录照样完整保存。

3. 叙事按工程阶段走，而不是按实验问题走

“历史G2”“G3”“发布策略”“确认主候选”等词，要求老师先理解我们的内部组织方式。

可以改成：

当前说法	面向教师的表达
历史G2参数实验	参数设置对处理结果的影响

从全文组织入手

叙述改回我的视角；状态和长哈希移出正文。坐标未注明、缺少真值与边界案例，则用读者能懂的语言保留。

让研究要求自然进入方法与实验

修改工程口吻时，我担心审核、量化优化和先单项后组合也被一起删掉。因此我补充：这些要求要自然进入方法与实验，用具体检查、比较和取舍呈现出来。

我要求保留研究要求的实质

你的推荐是正确的，这个方向也符合我的预期，我发现我额外的要求我们没有很好的融合在文章里，有一些小的我希望加进去的点，有些是基础实验的板块，有些是llm附加实验的板块，你想想怎么加进去，比如：我要求我们有完善的审核机制，我们要能循环优化，我们要以结果为准等等，这些部分是可以自然融合在每个板块中的，比如每一步我们是怎么审核的，怎么确立标准的，怎么量化优化的，有些是我们的主旨，比如我们要以结果为准，将基础方案融合，而不是上来就尝试复合方案等等

我这里随便举了几个例子，不代表我只有这些要求

然后最后告诉我这个实验报告和图表的制作和优化，你这里能完成吗，还是交给codex去做？（你这里能完成尽量优先你这里完成，这次不用完成，我们还没有选好方法，确立好方案）

现在请你仔细理解我的要求并且整理一下，并且在我的基础上帮我完善并且补充一下任务要求（我目前的要求都是简单的初步想法，你可以提出更好的方案和建议），让它更完整专业，我需要确认你是否已经理解了我的任务，我确认后可以可以进行实际操作

保留要求的实际内容

我希望读者能看到怎样判断可靠、怎样比较、为什么回退。GPT 据此把这些内容放回对应的方法和实验段落。

思考了 7m 56s

需要保留并强化的，是你的研究要求；需要去掉的，是表达这些要求时的工程管理口吻。

“有审核”“能循环优化”“以结果为准”“先单项、后组合”不是适合全部移到附录的小事项，而是这次实验区别于“把三个算法跑通”的重要部分。它们应该成为报告的方法和论证逻辑，让教师从具体实验中看见，而不是在开头列成几条口号。

同时，**文稿与图表可以优先由我在这里实际制作，不必继续采取“我只给提示词，Codex包办全部成品”的方式。*我已经检查了当前环境，具备 Python 绘图、XeLaTeX 编译和 PDF 渲染工具。后面我会说明哪些可以

GPT 区分内容主线与研究主线

一、报告应当同时有一条内容主线和一条研究主线

让研究要求自然进入方法与实验（续）

接前页，继续阅读这组对话。

GPT 区分内容主线与研究主线 · 续页

1. 内容主线：始终围绕轨迹预处理

教师要求的分段、去噪、简化、评价及 LLM 辅助工作流仍然是主体，不能被我们的审核体系或协作机制挤到次要位置。

读者首先需要理解：

数据有什么问题，采取什么处理，怎样比较，最后得到什么。

2. 研究主线：这些处理不是凭直觉选出来的

你的要求应当贯穿这一过程：

先明确怎样判断处理是否可靠，再分别检验基础方法和参数；只有在单项作用得到说明后，才检查组合是否有额外价值。实际结果决定采用、修改或放弃，而不是方案越复杂越好。

这条主线同时适用于基础实验与 LLM 附加实验。不是基础部分按普通流程写，到了 LLM 部分才突然出现“反馈、审核和优化”。

现有项目规则本来就要求：每个指标解释评价对象、合理性、计算方法和含义，重要结论由数据、代码、实验及图表共同支撑。问题不是缺少这些原则，而是现稿没有把它们转化为好读的实验论证。

SMART_CITIES_RESEARCH_PROTOCOL

两条主线结合后的效果

教师读到分段时，能够理解为什么切、怎样确认没有错误连接；读到参数实验时，能够理解怎样排除其他变化的影响；读到组合时，能够理解新增部分贡献了什么、为什么最后又被去掉；读到 LLM 时，能够理解建议如何进入真实计算，又如何被实测结果纠正。

具体写法：用案例呈现核验与回退

1. 方法部分讲清循环怎样运行

可以用一个简洁的技术流程说明：

提出候选 → 实际处理 → 检查条件与指标 → 保留、继续比较或放弃。

如果发现的是实现错误，则进入另一条路径：

定位错误 → 修正实现 → 重新计算受影响结果 → 返回原比较。

用两条主线组织正文

GPT 把内容主线放在轨迹处理、比较与结果，把研究主线放在验证、取舍与回退。随后用具体案例说明这些要求怎样进入对应段落。

让研究要求自然进入方法与实验（续）

接前页，继续阅读这组对话。

具体写法：用案例呈现核验与回退 · 续页

这一处需要集中讲清两类循环的区别。后面的章节不再重复完整流程，而是用实际实验展示它怎样起作用。

2. 结果部分展示循环改变了什么决定

最有价值的例子不是“我们循环了多少轮”，而是：

某个方案为什么获得下一轮试验机会，又为什么最终没有采用。

现有组合结果很适合承担这个作用：加入时间诊断条件的方向规则，在开发数据上相对过滤调整方案有41条几何改善；但在另外的选择数据中，有三条记录出现几何退化，因此最终去掉了该规则。

它自然体现了你的多项要求：

先验证基础作用、再尝试组合；不凭复杂度选方案；新数据能够推翻早期优势；结果不满足条件就回退。

无需再在这一段旁边列出“已满足U08、U09、U10”。

3. 不把“持续优化”写成“每一轮都变好”

有些轮次带来的价值是确认一个限制、排除一个方向，或者发现原来的评价方式不够充分。

新报告应当允许这样的结论：

某项改动没有带来额外收益，因此不进入最终方案。

这比“系统通过多轮迭代实现持续提升”更具体，也更符合已有结果。**不能把工程修复次数、候选试验次数和处理质量提升画成同一条不断上升的曲线。**

五、这些要求融入后，正文会是什么写法

以下只是说明表达方式的短示例，不是本轮对正式文件的修改。←

例一：在基础实验中体现“单项先行”

为区分两项过滤条件的影响，先分别降低最少点数和取消最短长度限制，再检查二者同时调整的结果。开发数据中，两项单独调整均能恢复部分轨迹覆盖，但都不能保留联合调整所恢复的全部范围。因此，后续比较保留了联合设置，并继续检查它是否改变原有轨迹的几何表达。

这里同时说明了**为什么做单项、怎样比较、结果怎样影响下一步**，不必写“我们严格遵守先单项后组合原则”。对应单项和移除结果已存在于现有实验中。

例二：在LLM实验中体现“建议必须接受实测检验”

先看具体写法

GPT 用单项验证、共同参考和组合回退给出段落样例。我先检查这种表达，再决定怎样扩展成正式正文。

用实际文字和图型作出表达选择

我要求列出需要修改的文字类型，每类提供三种写法，再用真实数据制作候选图。看到具体段落和图形之后，我才能判断阅读效果，并选择适合这份报告的表达。

我要求完整文字与实际图型候选

你的理解无误，我已确认，现在请给我文字修改方案，先给我所有需要修改的类型，并且给出对应典型例子，每个需要修改的类型3个选择，然后我来具体挑选，图表也需要例子，我需要看到具体的例图才能确定，开始按照我们的要求和计划完成任务吧

为选择准备实际材料

GPT 提供 22 类文字、66 种写法和 6 组 18 幅候选图。我对照具体内容检查不同组织方式，再作选择。

思考了 36m 47s

GPT 提供章节与开篇候选

已分析

本轮已经做成 22类文字修改、66种具体写法，以及6组、18张实际例图。现在选择的是表达方式：正式报告尚未替换，实验方法、参数和结果没有改变。

先打开选型材料

完整文字方案：22类、66种写法 · 完整样稿与绘图源码包

选型页可以离线打开。 **A / B / C 是各项的局部选择，不要求整篇统一选一个字母，也允许组合。 **压缩包是选型材料，不是工程更新包，无须放进原项目目录。

下面先给文字方案，再展示图表。文字样例以当前报告为基础；其中“现稿问题”是对原文写法的归纳，不全部作为逐字引文。现稿中确实存在工程阶段标题、提交说明、哈希、授权口吻和密集状态术语等问题。

一、文字修改方案：22类，每类三种选择

三种选择都保留必要事实。区别主要是：从什么地方切入、解释多少、由文字还是图表承担主要信息。

W01. 章节标题与组织顺序

现稿问题：按“历史G2”“G3”等工程阶段组织，参数分析与方案选择被拆散。

A | 规范章节式

数据与实验方法 → 评价指标与实验设置 → 参数和顺序比较 → LLM辅助实验 → 方案选择与整体结果 → 讨论与总结。

B | 问题推进式

原始轨迹需要怎样处理 → 如何判断处理是否合适 → 参数与顺序带来那些变化 → LLM建议是否有效 → 最终方案保留了什么。

用实际文字和图型作出表达选择（续）

接前页，继续阅读这组对话。

GPT 提供章节与开篇候选 · 续页

C | 图文推进式

先用数据图提出问题，再依次围绕方法示意、参数响应、建议核验、候选比较和整体结果展开；章节仍采用规范名称，不用图号替代章节。

我的倾向：B组织内容，A提供正式章节名称。

W02. 开篇与实验任务介绍

现稿问题：一开始复述任务、范围和提交规定，没有让读者进入实验问题。

A | 直接介绍实验

我选择问题驱动，保留直接开篇

文字方面(我认为问题驱动，然后找解决方案会比直接平白叙述解决方案更好，除了在目录或者是开篇这种直叙的地方，以这个为准)
我没说的就用你的推荐方案
w01中，开篇可以用a，其他的推荐b
图表方面，g1-3都选a，g4b，g5b，g6我会更倾向于a这种框架图，但是你的框架图有点太简朴了，而且看不出逻辑关系

收到，你的选择逻辑我已经记录。整体方向现在基本冻结：

GPT 记录我的组合选择

只有目录、开篇、基础定义部分采用直接说明式。
这和我们之前确定的 Experiment Report 定位一致：回答“最终做了什么、为什么这样做、结果说明什么”。
同时，图表不追求“高级感”，而是服务于研究问题。Visual System 也明确要求：Signature Visualization 必须回答重要研究问题，而不是因为复杂而使用复杂图形。

一、文字方案最终选择记录

总体写作原则（新增冻结）

主叙事：

按不同内容分别选择

开篇和目录直接交代，主体从问题引出方法。图型分别选择，G6 则因看不清逻辑继续修改。

先审样章，再完成并验收整篇报告

我对 G6 的反馈是希望看清核验依据与判断关系。GPT 重构样章后，我检查实际页面，再要求整篇沿同一方向完成；完整 25 页报告交付后，我作出了验收确认。

我对 G6 的原始反馈

文字方面(我认为问题驱动，然后找解决方案会比直接平白叙述解决方案更好，除了在目录或者是开篇这种直叙的地方，以这个为准)
我没说的就用你的推荐方案
w01中，开篇可以用a，其他的推荐b
图表方面，g1-3都选a，g4b，g5b，g6我会更倾向于a这种框架图，但是你的框架图有点太简朴了，而且看不出逻辑关系

我要求看清核验逻辑

在报告图形审阅中，我指出框架过于简朴、关系不清楚，要求把检查依据和判断过程表达出来。

收到，你的选择逻辑我已经记录。整体方向现在基本冻结：

样章：核验逻辑与历史归属纠正

三、G6已经重画：不再只是几个框依次相连

这次的重点是**明确数据依赖和判断条件**，而不是增加装饰或节点数量。

现在图里可以看出：

****参考方案和候选方案使用同一原始记录。****两条处理路径并行进入比较，核验还另外取得原始参考，不由候选自己提供“正确答案”。**

****不同检查不能互相替代。****参数合法、DP即时误差合格，并不能覆盖共同几何偏差退化的问题。**

****结果决定是否继续采用。****记录7764的候选保持了原有覆盖，但共同几何偏差由40.215增至69.145工作米，因此没有采用；即使全部保护条件通过，仍需进一步判断是否有值得替换原方案的改善。这个案例及读数来自现有报告，不是本轮补造的实验。**

反馈箭头采用虚线，并明确只适用于允许反馈的模式。它说明机制，不冒充该案例还有一条未取得记录的后续模型回答。

****还有一处修正：****上一轮把G6概括成“用户发现隐藏假设—用户质疑—决定”，容易给这个技术案例补入没有逐条原始依据的人类行为。现在没有加入这类节点。真实人类判断仍由Process Report依据原件呈现；这张图负责解释技术核验逻辑。**

可编辑文件也已保存：📁 **G6 draw.io源文件**。其XML和连线引用已检查；本轮没有在桌面版draw.io中手动打开操作，因此不把那一项写成已验证。

用具体关系重画 G6

GPT 把共同原始参考、候选结果和分层检查画清楚。记录 7764 的实际核验为这张技术说明图提供了案例。

先审样章，再完成并验收整篇报告（续）

接前页，继续阅读这组对话。

我确认样章并要求完整重构

这次的很不错，请按照这份样稿的表达方式直接进行Experiment Report的完整重构，最后返回给我完整的 Experiment Report的pdf和原文件，开始完成吧

完整报告交付后：我明确验收

这次的我已经验收过了，非常的不错，我刚刚已经更改了一些项目源和项目设置（关于过程文档process report的语言风格部分），你可以先刷新一下，同步一下现在的状态，然后我们需要根据新确认的规则和要求，更改对应的项目设置以及项目源 告诉我我们要更改项目设置的哪个板块以及哪些项目源，先不要更改，先告诉我大体上你要更改哪些内容，怎么更改，然后我会给你发现现在的内容/文件，然后你再改（我建议把Experiment Report 的pdf和源文件都放进项目源中）

GPT 承接验收并限定规则更新

思考了 6m 35s

本次验收通过的25页 Experiment Report，可以作为今后报告写作、图表和排版的正式参考。接下来要做的是把这次确认的做法写进长期规则，同时保留你刚更新的 Process Report 语言要求，而不是再重写一遍过程文档规则。

我已重新读取当前可见的项目源。这一轮只确定修改范围，没有改写设置、文件或上传集合。

一、当前状态已经核对到哪里

1. Process Report 的新语言规则已经在项目源中

目前读取到的是：

当前文件

已经存在的新要求

从样章到全篇


我确认实际样章后要求完整重构，随后审阅并验收 25 页实验报告。GPT 再将这些表达做法整理为可复用原则。

我的回看

验收成品后，我和 GPT 将问题驱动写作、图文对应，以及已验收源文件的保护方式整理为后续可复用的规则。

我的报告审阅怎样落实到成品

我先指出文字和图形的问题，再看具体候选与样章，确认表达方向后完成整篇报告。



G6 的修改来自我的图形审阅，记录 7764 的实际核验提供了技术案例。样章确认后，GPT 将相同表达方向扩展到全篇，我再审阅完整成品。

回到我最初要求的“真实完成与持续改进”

回看这次实验，我最关心的几件事始终连在一起：依据是否清楚，任务有没有实际执行，结果怎样核验，以及发现问题后能否继续推进。下面回引我当时的要求，再看它怎样逐步落实。

Ⓜ 网页搜索 你的理解还是错的，multi-agents不仅要协助我们把任务做出来，也要帮助我们不断迭代和循环优化，你可以理解为我们的 workflow 和 multi-agents 是协助我们从开始任务，到完成任务，到优化任务，这个循环，然后重复这个循环，然后你要有审核的标准，来确认我们确实在优化这样，这里面的任何一条都是我们的 workflow 和 multi-agents 的任务

其中优化任务并且循环这一步是最需要我们提前想好如何构建 workflow 和对应的 multi-agents 体系的！从而才能确保让这个体系循环进行优化

现在请你仔细理解我的要求并且整理一下，并且在我的基础上帮我完善并且补充一下任务要求（我目前的要求都是简单的初步想法，你可以提出更好的方案和建议），让它更完整专业，我需要确认你是否已经理解了我的任务，我确认后可以实际操作

让反馈引出下一步

我要求体系完成任务后继续检查结果、寻找改进。后续讨论又明确了候选依据、有限预算和停止条件。


Multi-Agent 主要理解成“把任务执行完的系统”，把优化理解成执行中的重试或
：整个任务从启动、研究、执行、完成，到审核、发现改进空间、落实优化、验证
同一套工作逻辑 Multi-Agent 体系协助推进

我在这次任务中不断补充和修正要求：把 Multi-Agent 拉回真实轨迹任务，要求先验证单项、共用评价，让普通修复留在当前 Goal，并继续检查方法解释与报告表达。GPT 负责研究、解释、候选和结果核查，Codex 负责实现与运行；我的质疑和选择也持续影响着后续工作。

前期交接曾经反复，审核接口出现过漏洞，开发阶段有优势的组合也在新记录上退出。正是这些经历，让我们逐渐明确什么时候继续、怎样修复，以及为什么保留较简单的方案。

从共同基础到实验一，workflow 怎样改变

回看整个过程，我的几次关键补充逐渐把研究判断、实际执行、核验和任务恢复接在一起。



这次交互让我形成了更具体的工作习惯：先把问题和依据讲清，再用可检查的结果决定下一步；实现有错就修复，有效候选没有收益就保留结论并调整方向。方案和报告都在这种往返中逐步成形。

相关材料：原始对话节选见各章；算法、指标与完整结果见配套 Experiment Report；截图来源、裁切与箭头定义、构建方法和制作记录随 LaTeX 源包保存。