



实验二 - 任务分配 (2)

董宜滔

DaSE
Data Science
&Engineering

回顾与本次目标

实验二回顾

- 贪心（TBG）与批次匹配（KM）：单目标，最小化接驾延迟
- 每个批次只看眼前：不考虑多个目标的冲突，也不考虑派单对未来供给的影响

Part A　多目标派单
最大化总收入 vs 最小化接驾距离 → NSGA-II / NSGA-III

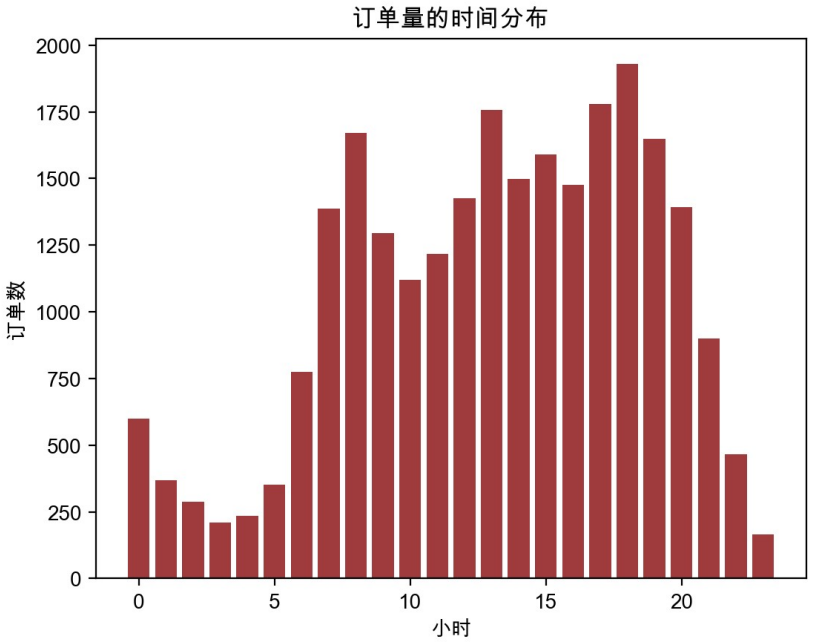
Part B　强化学习派单
区域长期价值 + KM → Q-learning + KM （Q-KM）

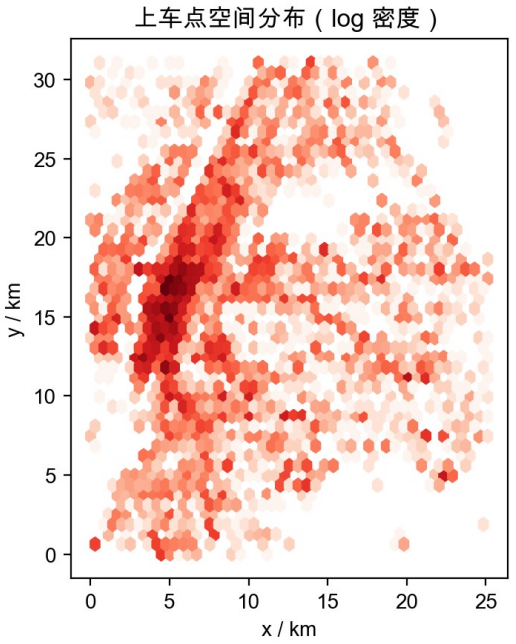
数据与仿真

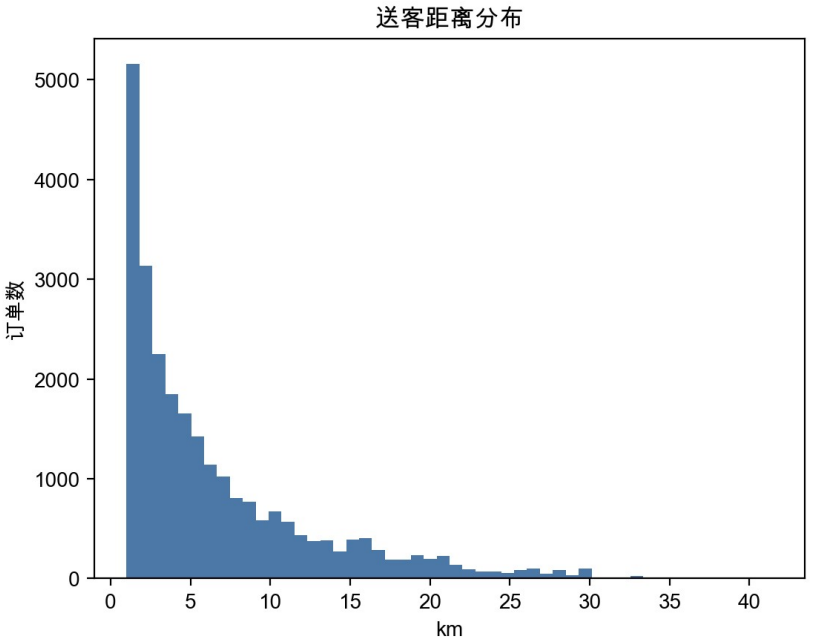
• Foursquare NYC 签到：同一用户同日相邻两次签到（间隔 10~180 分钟、距离 ≥ 1 km）视为一次出行，共 25,550 单

- 车费 = 5 + 2 × 送客距离（km）；派单半径 3 km （曼哈顿距离）；前 70% 日期训练、后 30% 测试

数据概览







- 早晚双高峰；上车点集中在曼哈顿；送客距离长尾分布 → 长途单价高，但会把司机带离热点



DaSE Data Science & Engineering
SCHOOL OF DATA SCIENCE & ENGINEERING
数据科学与工程学院

Part A 多目标派单

NSGA-II / NSGA-III： 平台收入与接驾距离的帕累托前沿

为什么是多目标

同一批次的两个目标

$$\max \ f_1 = \sum_{i,j} \text{fare}_j \, x_{ij} \qquad \text{(platform revenue)}$$

$$\min \ f_2 = \sum_{i,j} d_{ij}^{\text{pick}} \, x_{ij} \qquad \text{(total pickup distance)}$$

$$\text{s.t.} \ \sum_j x_{ij} \le 1, \ \ \sum_i x_{ij} \le 1, \ \ x_{ij} = 0 \ \text{if} \ d_{ij}^{\text{pick}} > R$$

冲突在哪里

- 长途单收入高，但上车点不一定离司机近
- 多派单收入高，但总接驾距离也增大
- 没有同时最优的解，只有一组“谁也不比谁差”的折中解

帕累托支配

a 支配 b： a 在所有目标上不差于 b，
且至少一个目标严格更好

不被任何解支配的解 = 帕累托最优解
它们在目标空间中的像 = 帕累托前沿

NSGA-II：非支配排序 + 拥挤距离

- 快速非支配排序：把种群分成第 1 层、第 2 层……；第 1 层是当前种群的帕累托前沿，层号越小越好
- 拥挤距离：同一层内，个体在每个目标上左右邻居的归一化距离之和；越大说明周围越稀疏，越应保留（边界点 = ∞ ）
- 精英保留 (μ+λ)：父代 N 个 + 子代 N 个合并，按（层号小，拥挤距离大）选出 N 个进入下一代
- 遗传算子：二元锦标赛选择 → 均匀交叉 → 随机重置变异（每位概率 1/m ）



Deb K. et al. A fast and elitist multiobjective genetic algorithm: NSGA-II. IEEE TEVC, 2002

NSGA-III：参考点引导的小生境保留

- 问题：目标数 ⩾ 3 时，几乎所有解都互不支配，拥挤距离区分不了好坏
- 保留非支配排序，把最后一层的“拥挤距离截断”换成参考点机制：

① Das-Dennis 方法在归一化超平面上生成均匀参考方向（H 等分 M 个目标，个数见下式）

② 自适应归一化：理想点平移 + 极值点超平面求截距

③ 关联：每个解关联到垂直距离最近的参考方向

④ 小生境保留：反复选“已关联解最少”的参考方向，从中补一个解

- 效果：解沿参考方向均匀铺开

$$|\mathcal{R}| = \binom{H+M-1}{M-1}, \qquad \tilde{f}_k = \frac{f_k - z_k^*}{a_k}$$

NSGA-II
拥挤距离 → 局部稀疏程度
适合 2~3 个目标

NSGA-III
参考点 → 全局均匀分布
适合 3 个及以上目标

Deb K., Jain H. An evolutionary many-objective optimization algorithm using reference-point-based nondominated sorting approach. IEEE TEVC, 2014

落地：派单批次如何编码

批次设定

- 18 点晚高峰： 40 个空闲司机、 80 个订单（司机少于订单）
- 每个订单只考虑最近的 K=6 个、且在 3 km 内的候选司机

整数编码（长度 = 订单数 m ）

- 第 j 位 = 0： 订单 j 本批次不派
- 第 j 位 = k： 派给第 k 近的候选司机

解码修复，保证可行

- 两单抢同一司机 → 后者顺延到下一个候选；都被占则不派
- 统一最小化：目标向量 = (– 收入， 接驾距离)

基因 [1, 0, 3, 1, 2, …]

解码 + 冲突修复 → 可行匹配

$$F = \left(-\sum \text{fare},\ \sum d^{\text{pick}}\right)$$

对照组：加权和 + KM

$$w_{ij} = \text{fare}_j - \lambda\, d_{ij}^{\text{pick}}$$

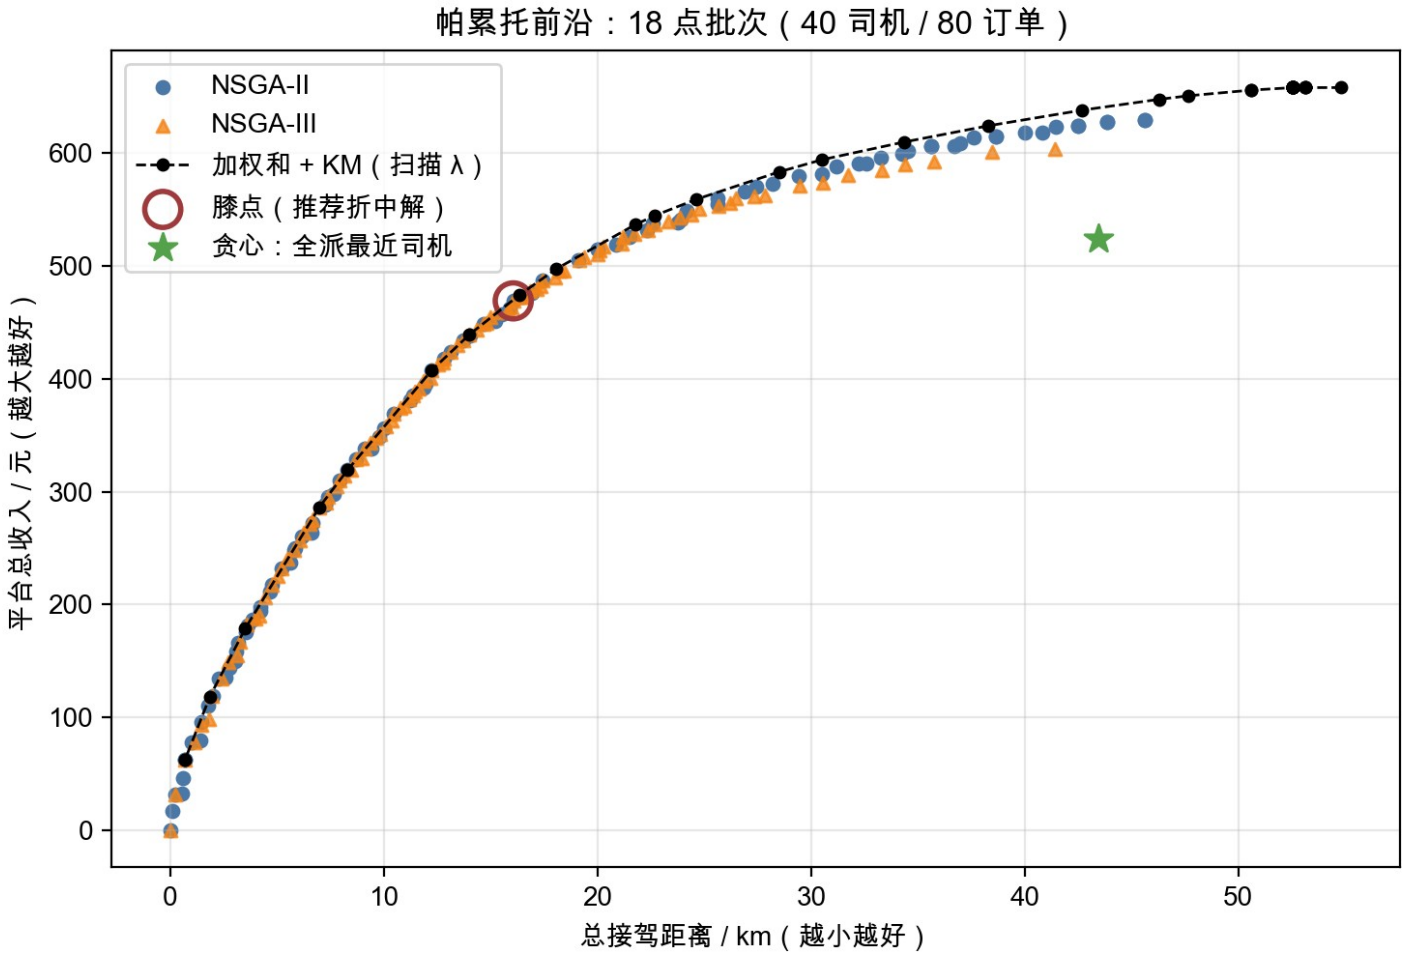
评价指标：超体积 HV

- HV： 前沿与参考点围成的目标空间面积 / 体积，越大越好；同时反映收敛性与分布性
  - 所有算法共用同一组理想点 / 最差点做归一化，参考点取 (1.1, 1.1)
- Spacing： 每个解到最近邻距离的变异系数，越小分布越均匀
  - 膝点（knee point）： 离两端点连线最远的解，边际收益突变处，常作为推荐折中方案

实验设置

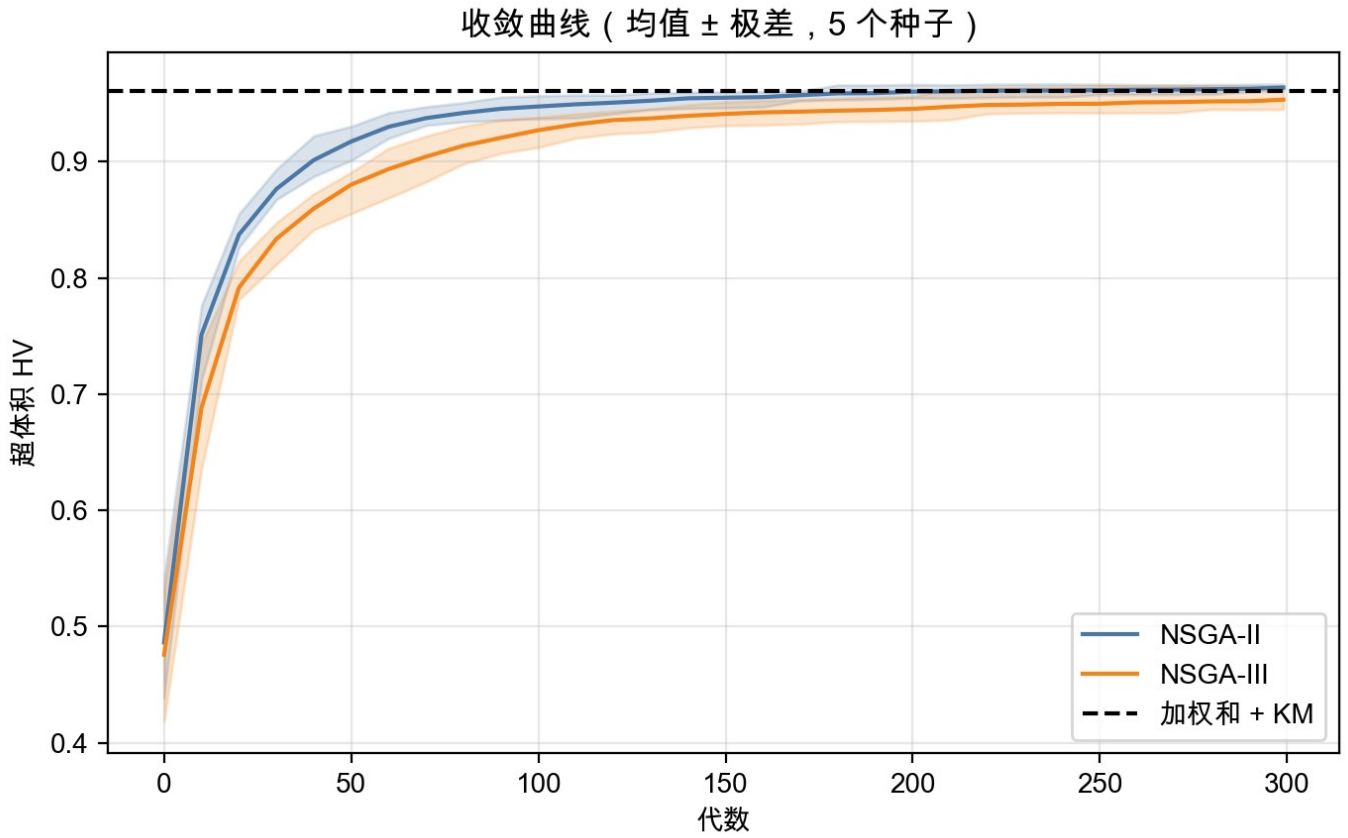
- 种群 100，迭代 300 代，交叉概率 0.9，变异概率 1/m； 5 个随机种子
- NSGA-III 参考方向： 2 目标 100 个， 3 目标 105 个

实验 1：晚高峰批次的帕累托前沿



- 前沿完全压在“全派最近司机”的贪心解上方：同样的接驾距离能多赚钱，或同样收入少跑路
- 贪心：收入 524 元，接驾 43.4 km
- 膝点：收入 469 元，接驾 16.1 km（− 63% 接驾，− 11% 收入）
- NSGA-II 收入最高解： 629 元，接驾 45.6 km
- **HV： NSGA-II 0.962 ，加权和 +KM 0.961 ， NSGA-III 0.945**

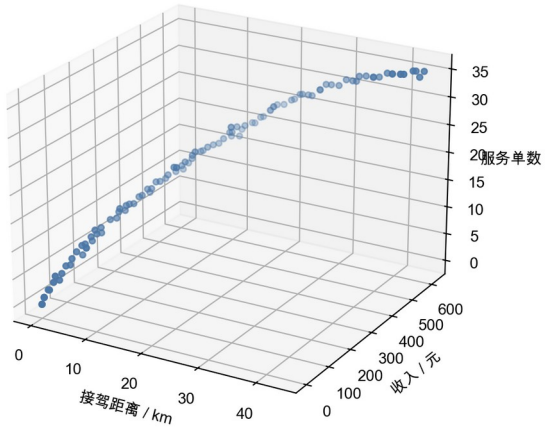
实验 2：收敛曲线（5 个种子）



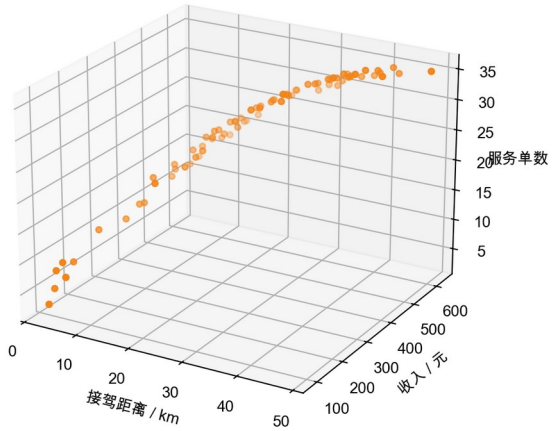
- 最终 HV： NSGA-II 0.964 ± 0.002；NSGA-III 0.953 ± 0.007
- 2 目标下 NSGA-II 收敛更快更稳
- 本问题前沿接近凸曲线，所以加权和 + KM 也很强
- 高收入端 NSGA 稍弱于 KM → 思考题：用 KM 解初始化部分个体（混合策略）

实验 3：三目标（加入服务单数）

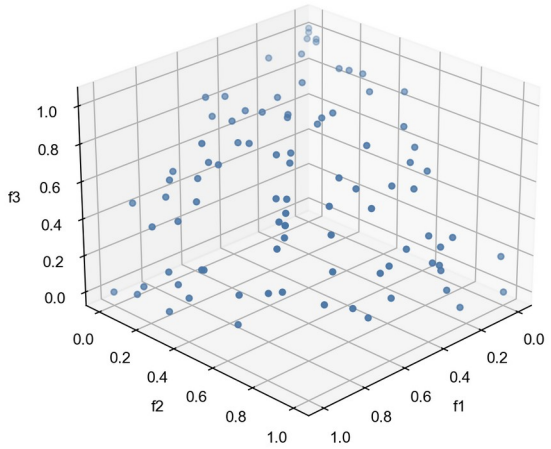
NSGA-II（HV=0.905，105 个解）



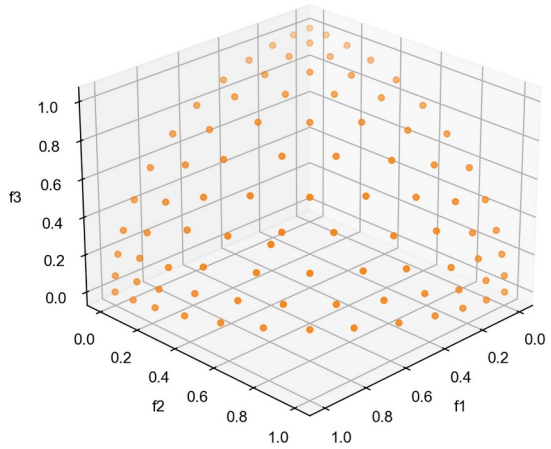
NSGA-III（HV=0.900，105 个解）



NSGA-II on DTLZ2（Spacing=0.51，越小越均匀）

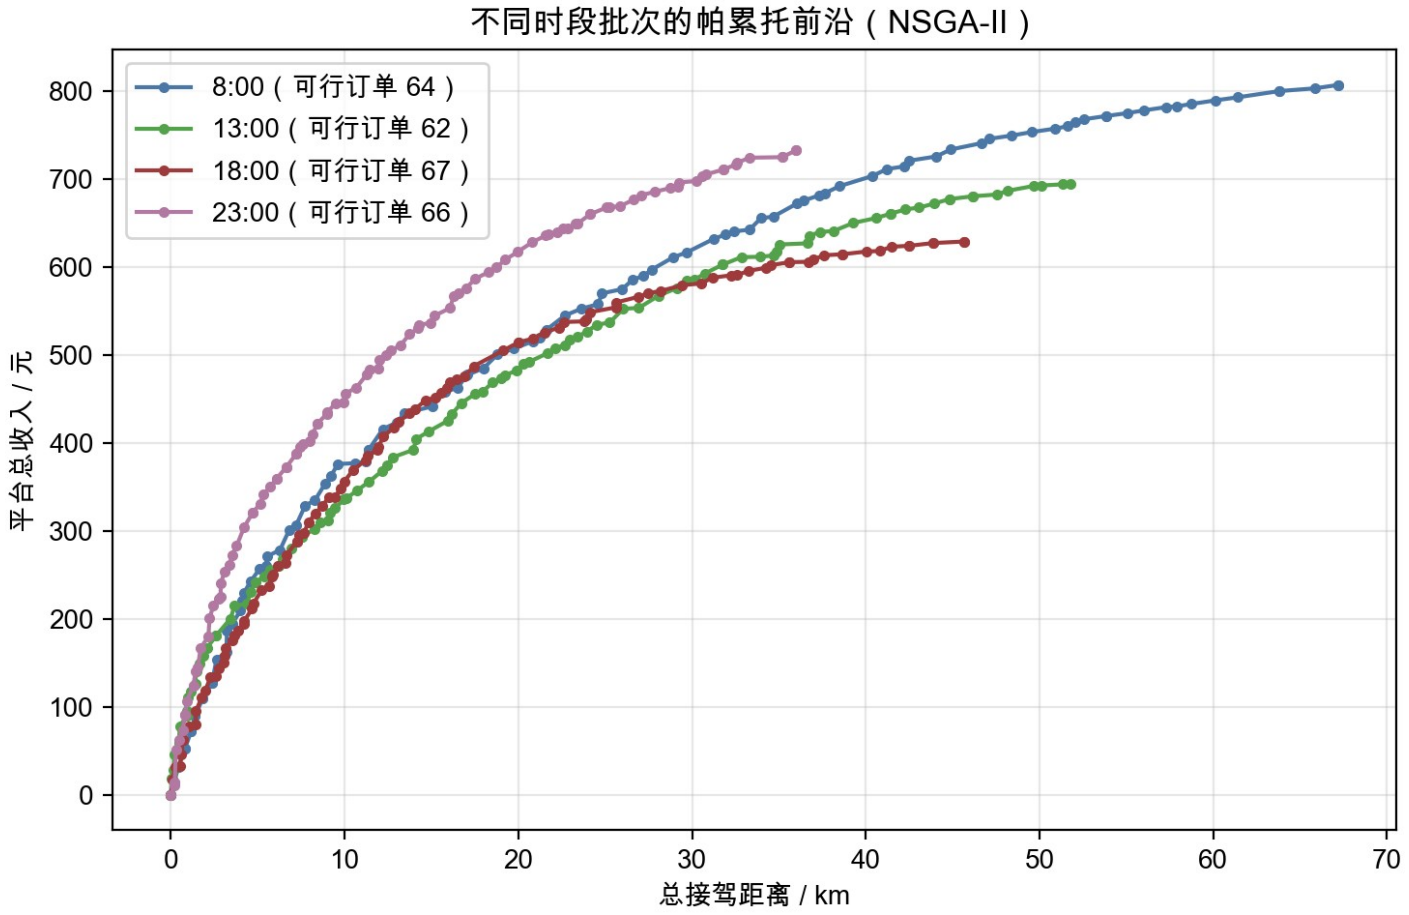


NSGA-III on DTLZ2（Spacing=0.30，越小越均匀）



- 派单 3 目标： HV NSGA-II 0.901， NSGA-III 0.896； Spacing 0.52 vs 0.69
- 原因：服务单数与收入高度相关，前沿是一条“细带”，很多参考方向上没有解
- 对照 DTLZ2（前沿铺满 1/8 球面）： NSGA-III 收敛误差 0.0006 vs 0.0078， Spacing 0.30 vs 0.51， HV 0.744 vs 0.700
- **结论：算法选择取决于前沿形状和目标数**

实验 4：不同时段的前沿



- 同样 40 个司机，在 8 点、13 点、18 点、23 点各抽一个批次
- 可行订单越多，前沿越高、越长，可选的折中空间越大



DaSE Data Science & Engineering
SCHOOL OF DATA SCIENCE & ENGINEERING
数据科学与工程学院

Part B 强化学习派单

Q-learning 学习区域长期价值，嵌入 KM 的边权（Q-KM）

为什么 KM 还不够：短视

- KM 最大化当前批次的收入，不管司机送完客后会在哪里
- 30 元的单把司机送到郊区，他可能 1 小时接不到单； 25 元的单把司机送回市中心，马上接下一单
- 平台真正的目标是全天总收入 → 序贯决策问题 → 马尔可夫决策过程（MDP） / 强化学习

订单 A： 30 元
去郊区，送完后空驶

订单 B： 25 元
去市中心，马上接下一单

KM 选 A， Q-KM 选 B
看的是 即时 + 未来

Q-learning 原理

- MDP 要素：状态 s、动作 a、奖励 r、转移 s → s'、折扣 γ
- 动作价值 Q(s, a)：在 s 做 a 之后，按最优策略继续能拿到的折扣总回报；满足 Bellman 最优方程：

$$Q^*(s,a) = \mathbb{E}\Big[\, r + \gamma \max_{a'} Q^*(s',a') \Big]$$

Q-learning 更新（时序差分，无模型）

$$y = r + \gamma^{\Delta} \max_{a' \in \mathcal{A}(s')} Q(s',a')$$

$$Q(s,a) \leftarrow Q(s,a) + \alpha \big(y - Q(s,a)\big), \qquad \alpha = \max\Big(\frac{1}{N(s,a)},\, 0.05\Big)$$

- 离策略（off-policy）：用 ε- 贪心探索收集经验，学到的仍是最优策略的价值
- 学习率：前期等于样本平均，后期保留一定的跟踪能力

落地：把整个平台当作一个智能体

- 不对每辆车建模（状态爆炸），而是学习区域级价值表，所有司机共享
- 状态 s = (t, i)： 10 分钟时间片 × 8×8 区域网格， 6:00~24:00 共 108 片
- 动作 a：接一个去区域 k 的订单，或原地空等（WAIT）
- 奖励 r：车费；空等为 0
- 转移：接单 (t,i) → (t+Δ, k)， Δ = 接驾 + 送客时间片；空等 (t,i) → (t+1, i)
- 折扣：动作持续 Δ 个时间片就折扣 Δ 次（半马尔可夫），γ = 0.92 / 10 分钟
- **Q 表规模 108 × 64 × 65 ≈ 45 万，与车辆数无关**

关键细节： max 只在 A(s') 上取

A(s') = 司机到达 s' 时
3 km 内订单的目的地区域 ∪ {空等}
在全部 65 个动作上取 max 会严重高估

状态价值

$$V(t,i) = \mathbb{E}\left[\max_{a \in \mathcal{A}(s)} Q(s,a)\right]$$

每算一次 max 就是 V 的一个样本

Q-KM：长期价值作为 KM 边权的附加项

$$w_{dj} = fare_j + \beta \cdot LT(t, i, k)$$

$$LT(t, i, k) = \gamma^{\Delta(i,k)} \cdot V(t + \Delta(i,k), k) - \gamma \cdot V(t+1, i)$$

fare_j
即时奖励：这单的车费

γ^Δ·V(t+Δ, k)
送完客后在目的地 k 的价值

γ·V(t+1, i)
机会成本：不派、原地等的价值

- i = 司机所在区域， k = 订单目的地区域； w ≤ 0 表示“派这单不如让司机等着”， KM 不连这条边
- LT 只依赖（时间片，起点区域，终点区域）：每个时间片查一张 64×64 的表，不对每辆车单独计算
- β = 0 退化为 KM- 即时收入；本实验 β = 0.5

训练流程

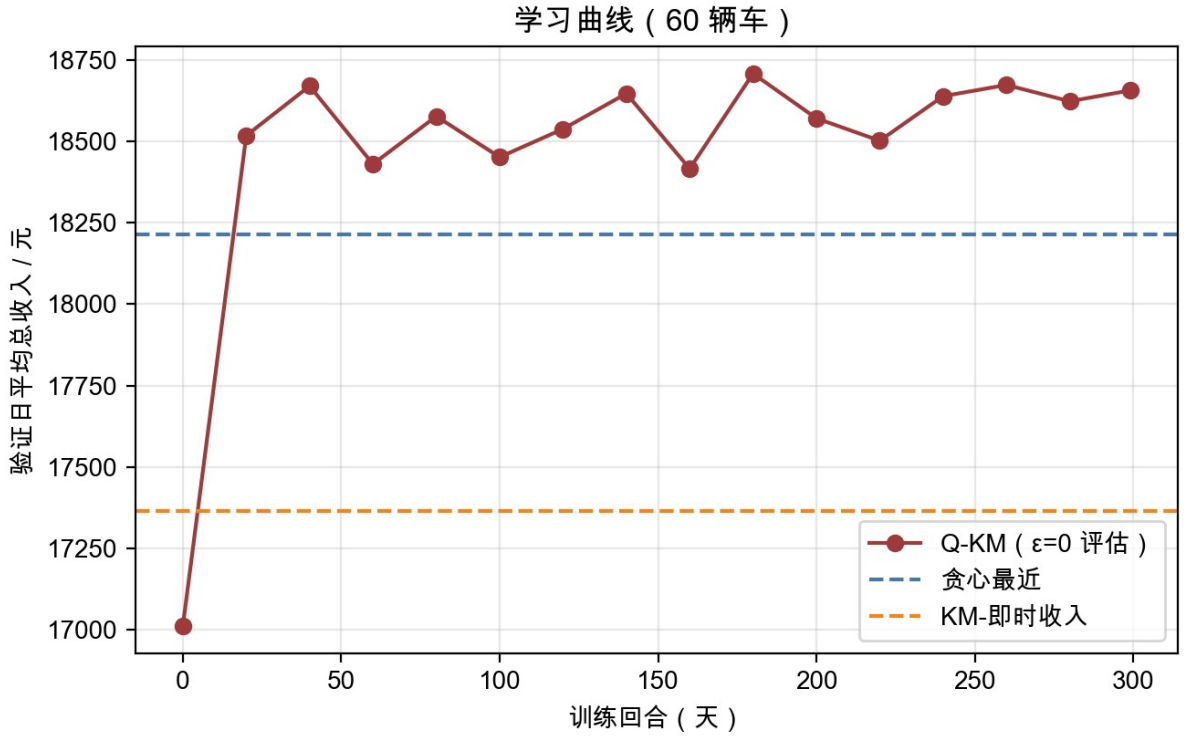


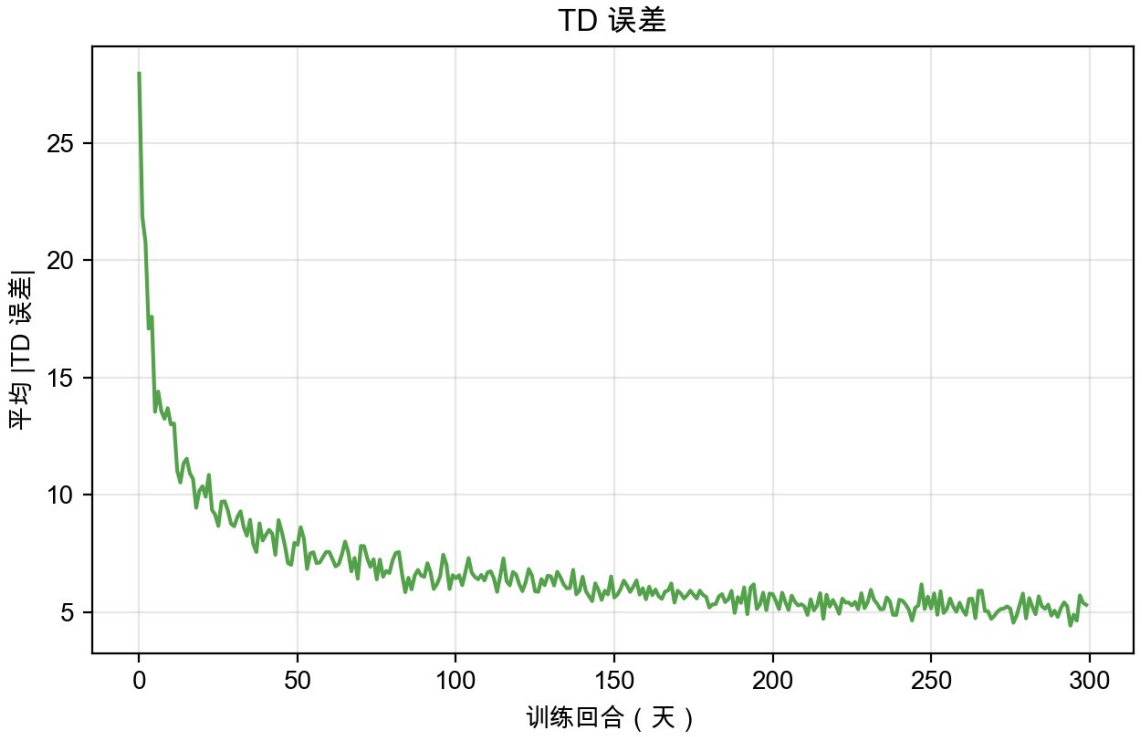
- 300 个训练日， ε 从 0.5 线性衰减到 0.05 ；订单从训练集按时间分布抽样，每天 1,500 单
- 逆序更新：价值从一天的结尾往开头传播，比顺序更新收敛快
- 经验 = (t, i, a, r, t', i', A(s')) ；仿真器在司机下一次空闲时回填 A(s')

学生需要完成的代码

- TODO 1 q_update： TD 目标、计数、学习率、 Q 和 V 的更新
- TODO 2 region_long_term_value： 由 V 计算 LT 表
- TODO 3 q_km： 查 LT 表、组合边权、调用 KM

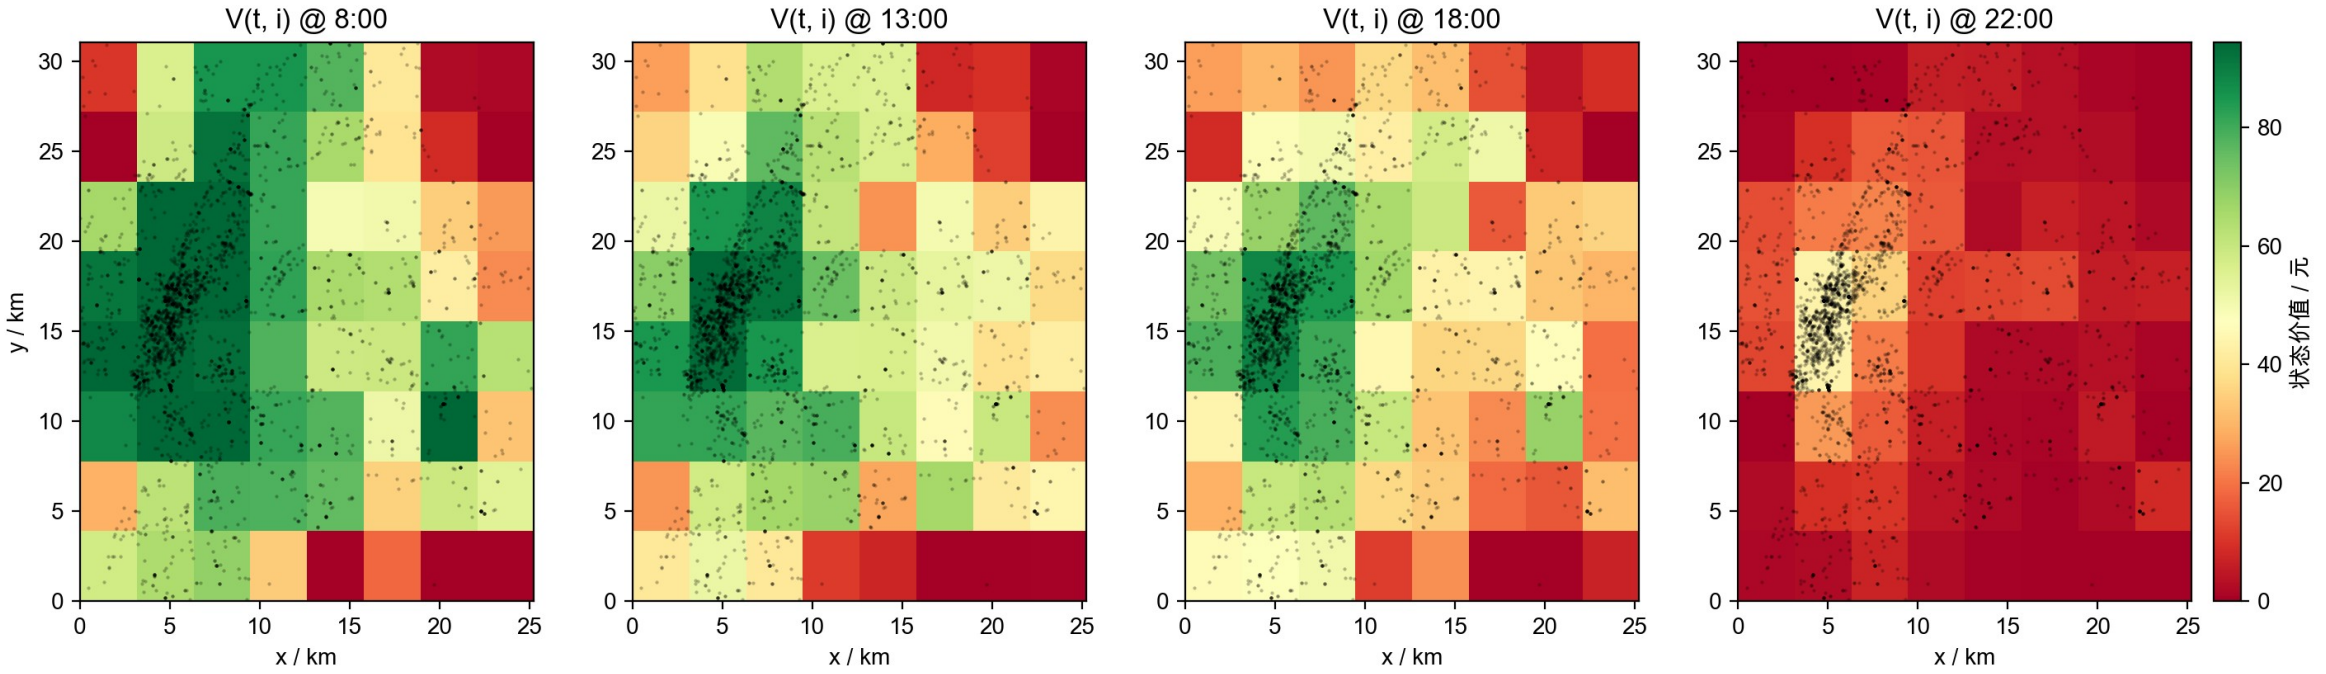
学习曲线





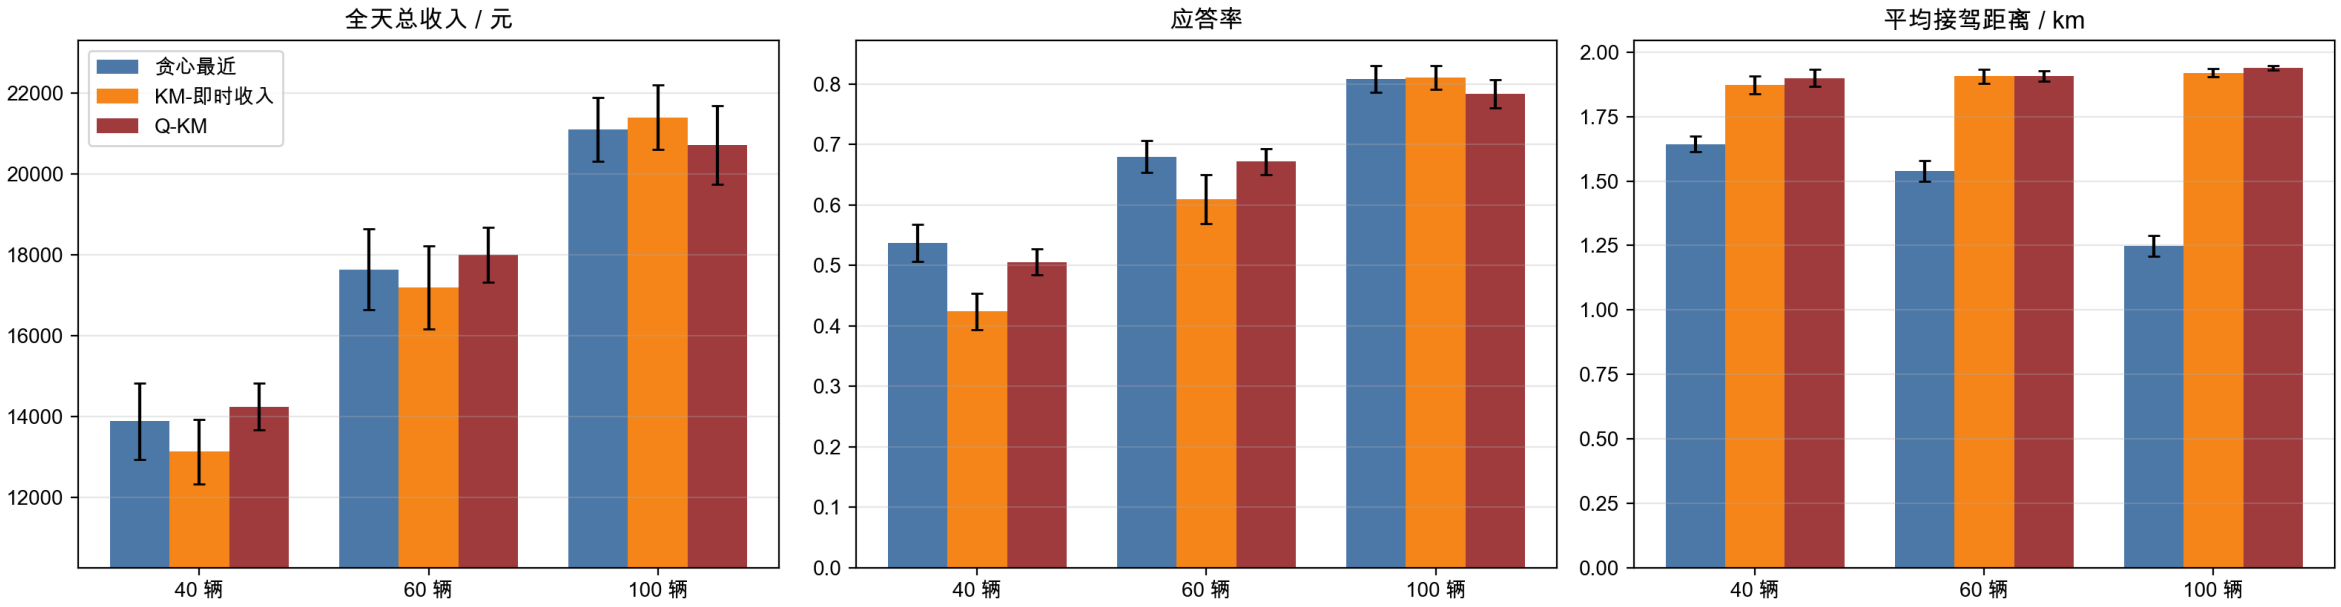
- 60 辆车： Q-KM 训练 20 个回合后就超过两条基线，此后在 18,400~18,700 元之间波动； TD 误差从 28 降到 5 左右
- 验证用纯 Q-KM （ε = 0），训练日与验证日不同

学到的区域价值 V(t, i)



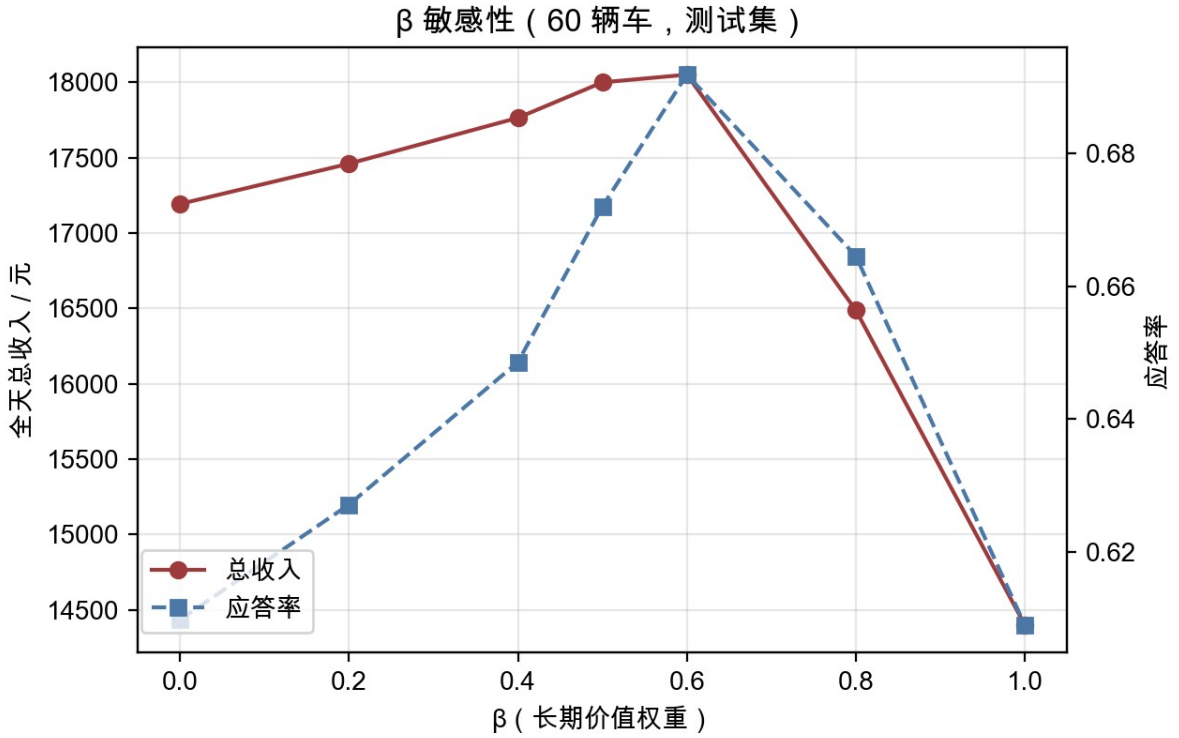
- 黑点 = 上车点。曼哈顿中城与下城全天价值最高；早 8 点北部与东部住宅区价值也高（通勤出发）
- 22 点价值整体下降：一天快结束，剩余可赚的钱变少（ V[T] = 0 ）
- 这张表就是 Q-KM 的“地图”：把司机派往绿色区域加分，派往红色区域减分

实验：不同车队规模（测试集 5 天）



- **Q-KM 相对 KM-即时收入：40 辆 +8.5%，60 辆 +4.7%，100 辆 −3.2%**
- Q-KM 相对 贪心最近：40 辆 +2.6%，60 辆 +2.1%，100 辆 −1.8%
- 车少时长期价值更重要（与 KDD'18 结论一致）；车多时到处都有空车，价值表的过估计带来的拒单损失超过收益

实验： β 的敏感性与讨论



- β = 0 即 KM- 即时收入（17,190 元）； β = 0.5~0.6 最好（约 18,000 元）； β = 1 跌到 14,400 元，拒单变多
- 为什么会过估计：每个司机独立取 max，默认“附近最好的单一定归我”，忽略了其他司机抢单
- 意外发现：本仿真中 KM- 即时收入不如贪心最近。长途单把司机带离热点，而空闲司机不会自己回来
- 改进方向： SARSA / 策略评估（KDD'18 的做法）、 Double Q-learning 、空车调度

作业细则

文件：实验 3 多目标与强化学习派单（学生版） .ipynb

• Part A （代码已给出）： 运行 NSGA-II / NSGA-III ，回答 4 道思考题；尝试混合初始化（用 KM 解作为初始个体）并报告 HV 变化

• Part B： 完成 TODO 1~3 ，通过单元测试后训练 Q-KM ，与贪心、 KM- 即时收入对比

- 报告内容：帕累托前沿图、 HV 收敛曲线、学习曲线、价值热力图、不同车队规模的对比表，并解释结果

加分项

- 用 SARSA 或 Double Q-learning 缓解过估计，比较 β = 1 时的表现
- 让空闲司机按 V 主动调度到相邻高价值区域
- 把 Q-KM 的边权和接驾距离做成双目标，用 NSGA-II 求前沿

参考： Xu Z. et al. Large-Scale Order Dispatch in On-Demand Ride-Hailing Platforms: A Learning and Planning Approach. KDD 2018



DaSE Data Science & Engineering
SCHOOL OF DATA SCIENCE & ENGINEERING
数据科学与工程学院

谢谢！

Email： 52285903012@stu.ecnu.edu.cn